ChatGPT

Requirements Spec (RS) v3.1 – QuantWin / 智能体研究分析系统

1. Overview（概述）

1.1 Problem Statement（问题陈述）

现代情报分析师面临着海量、异构的开源数据(OSINT)，需要在 **复杂多变的信息环境** 中快速提炼有 **证据支撑** 的洞察结论。然而现有流程往往耗时且缺乏可追溯性：从数据采集、清洗到分析报告产出需要人工串联多个工具，导致 **时效性不足**（新信息不能及时反馈）、**可靠性不足**（结论缺乏证据链支撑且难以复核）、以及 **安全性隐患**（潜在对抗投毒信息难以及时发现）。QuantWin 智能体研究分析系统旨在解决上述痛点，通过智能代理编排实现数据的 **“采集-融合-分析-决策”闭环**。本系统将多源异构数据在 **5 分钟内** 处理为可检索/分析的知识，并以 **结构化、证据化** 的方式输出结论，辅助决策者快速获取可信洞察。同时系统内置多层次检索、知识图谱推理和可信度演化机制，以 **东北亚领域** 为起点，保障跨语言、一致性的情报分析能力。系统需满足企业部署要求，包括 **多租户数据隔离**、**安全审计** 和 **可观测性**，并通过分级降级与弹性扩展机制保障在资源受限或遭遇对抗攻击时仍提供核心功能服务。

1.2 Objectives & Key Results (OKR)

- **O1：建立“5 分钟内可检索”的端到端情报处理闭环**（Ingest → Index → Retrieve）
- **KR1**：新内容从采集完成到进入检索索引的端到端延迟 **P95 ≤ 5 分钟**（内部 SLO）【5 分钟可检索】
- **KR2**：用户查询的端到端响应 **P99 ≤ 800ms**（含检索、融合和基础生成，但不包括长报告导出）
- **KR3**：系统支撑**在线查询吞吐 ≥ 100 QPS**，且请求成功率 **≥ 99.5%**

- **KR4**：在资源紧张或异常流量时系统可按 **L0-L3** 分级自动降级，仍保证核心检索和基本可解释输出（分级降级矩阵定义完备，并在压力测试中验证）

- **O2：输出“结构化、证据化、可审计”的研究结论，直接服务业务决策**

- **KR1**：所有面向用户的关键结论（Answer/Insight/Recommendation）**必须附带证据列表**（evidence_list），以 RecommendationCard 形式承载，确保结论可追溯【每条结论 100% 有来源】
- **KR2**：所有“行动建议”类输出均采用标准 **RecommendationCard** 模式，至少包含：风险等级（High/Medium/Low）、总结说明、evidence_list，及可选洞察内容字段
- **KR3**：证据融合调用统一的 **EvidenceFusion API**，默认取 Top-N 证据（N 默认值在策略配置中固定），并在融合结果中记录采用的 **策略版本** 和相关评分，以便事后审计和复盘

- **KR4**（待确认）：导出的审计报告（PDF）是否要求“每条结论必须可回溯到全文检索证据（Fulltext Verify）”？【当前假设】对于 **风险等级为 High** 的卡片，报告中需附上证据全文或索引，以支持人工复核。

- **O3：确保东北亚特定领域的语义一致性与跨语言支持**

- **KR1**：系统使用统一的领域本体(Ontology)定义实体类型、事件类型。所有模块输出使用一致的命名和分类体系，避免歧义【领域术语一致率 100%】
- **KR2**：支持跨语言信息检索（CLIR），实现查询翻译缓存和**双语证据**展示。跨语言翻译增加的平均延迟 **≤ 500ms**；翻译缓存命中率目标 **≥ 80%**（基于业务场景预估）

- **KR3：支持语言范围及阶段：初始版本至少支持中文(zh)和英语(en)** 的内容与查询处理；韩语(ko)、日语(ja)支持计划在第二阶段逐步推出。

- **O4：在复杂信息环境下保持“可信度演化 + 对抗攻击防御”的稳健性**

- **KR1**：实现对情报内容的**可信度评分**随时间和多维特征的演化，并提供可解释的组成部分（如时间衰减、社交网络扩散、域名可信度等分项），使系统能够输出“内容为何可信/不可信”的依据
- **KR2**：实现对 **对抗性攻击/投毒** 内容的检测和分级告警机制。初始目标将误报率控制在 **< 5%**（高优先级告警下），漏报率**逐步优化**（遵循“宁可漏报部分低风险攻击，避免大量误报干扰”的原则）。系统对可疑内容给出 Low/Medium/High 不同等级的告警，并支持后续阈值校准。

1.3 Success Metrics（关键成功指标）

下表列出了上述 KR 所对应的核心指标及其目标值。这些 **Success Metrics** 每一项均定义了明确的计算口径和目标，以便验收和持续监控。本规范中所有数值针对生产环境，指标统计口径如无特殊说明按自然月度或季度计算。同时要求各指标皆有相应监控和告警配置（详见第12章）。

Metric Name (ID)	Definition (测定方式)	Frequency / Window	Target Value (目标)
New Content Indexing Latency (MTR-001)	新内容从采集接收 (ingestion.received) 到可检索索引可用的延迟。统计入口事件和索引完成时间差的P95值。 **Labels**: tenant_id, source_type	日统计，月度评估（P95）	**≤ 5 分钟** (95%以上的新内容5分钟内可检索)
Query End-to-End Latency (P99) (MTR-002)	用户查询从请求到返回结果的端到端延迟（包括检索、融合、基础生成，不含长报告异步生成）。统计P99。 **Labels**: tenant_id, query_lang, query_type	日统计，月度评估（P99）	**≤ 800ms** (99%请求延迟800ms以内)
Query Throughput (QPS) (MTR-003)	系统每秒可处理的查询请求数（稳定并发）。通过压测获取最大稳态QPS。 **Labels**: env (prod/staging)	阶段性压测	**≥ 100** QPS (在生产环境配置下)
Query Success Rate (MTR-004)	查询请求成功率 = 成功响应次数 / 总请求次数。排除用户错误的请求，统计系统自身原因导致的失败。	实时监控，月度统计	**≥ 99.5%** 成功率
Degrade Function Preservation	分级降级时核心功能保持比例：降级L1/L2下核心检索应100%可用，L3下新内容暂停但已有内容可查询。通过演练验证降级期间关键用例仍可执行。	降级演练	**通过**（各级降级策略验证通过）
Evidence Attachment Coverage	关键结论附证据率 = 带 evidence_list 的结论数量 / 结论总数。期望所有Answer/Insight/Recommendation均有至少一条证据引用。	持续监控（抽样人工核查）	**100%** (关键输出全都有证据链)

Metric Name (ID)	Definition (测定方式)	Frequency / Window	Target Value (目标)
Standard Ontology Usage	领域本体类型使用覆盖率：输出内容中的实体/事件引用统一类型的比例。	抽样检查，各模块上线评估	**100%** (无歧义类型不一致情况)
Translation Overhead (MTR-013)	跨语言检索中翻译处理的平均额外耗时。通过日志记录翻译耗时计算。 **Labels**: language_pair	周统计，月度评估	**≤ 500ms** (平均)
Translation Cache Hit Rate (MTR-014)	翻译缓存命中率 = 使用缓存结果次数 / 翻译请求总次数。	月度统计	**≥ 80%** 命中率
Languages Supported	支持的语种数量及覆盖度。分阶段验收：Phase1支持中英文，Phase2扩展至中/英/韩/日四语。	里程碑检查	Phase1: **2 种** (zh,en) Phase2: **4 种** (zh,en,ko,ja)
Trust Score Explanation Coverage	具有可解释组成的可信度评分输出比率：系统生成的高风险结论均提供可信度分解列表。	抽样人工验收	**100%** (High风险输出均含分解)
Adversarial Alert Precision	对抗攻击告警精确度：高优先级告警的误报率。通过标注评估告警真假统计。	按季度评估	**< 5%** 误报率 (高优告警)
Cold Query Ratio (MTR-015)	冷查询占比：需要访问冷存储的数据查询次数 / 总查询次数。通过查询日志标记查询类型计算。	月度统计	**≤ 5%** (冷数据查询不超过5%)
Cost per Tenant (关键成本指标)	单租户平均月度资源消耗成本（如CPU小时、存储占用）。用于评估多租户场景成本效率。	按季度评估	**在预算范围内**（初始预算值在策略中定义）

注：上述 “P95” “P99” 表示第95、第99百分位数；所有指标的达标情况须通过仪表板监控并在里程碑验收时提交报告。如未特别注明，指标针对生产环境单租户完全负载场景。

2. Stakeholders & Personas（干系人及角色）

- **Persona-AN（Analyst，研究分析师）** – 核心诉求：发起研究任务、快速获得**可追溯证据链**支撑的结论；能够回溯至少8年历史背景，支持跨语言检索；一键生成报告（PDF）。典型权限：可创建查询和研究任务、生成RecommendationCard和报告、订阅主题和实体等。
- **Persona-DM（Decision Maker，决策者）** – 核心诉求：只关注“结论 + 风险等级 + 建议动作”，并可追溯查看证据；期望输出稳定且可审计，方便决策。典型权限：只读访问/订阅/下载报告（无权修改策略或数据）。
- **Persona-AD（Admin，系统管理员）** – 核心诉求：配置数据源、编排采集计划(CrawlPlan)、管理策略包(PolicyBundle)、控制预算和限流；管理租户、用户和权限；查看中控台监控和告警。典型权限：全局配置和治理权限（如创建数据源、调整策略、删除数据等）。
- **Persona-GOV（Governance，合规/治理负责人）** – 核心诉求：审批和管理策略版本、审计操作记录、响应对抗性投毒事件；对高风险输出进行复核把关。典型权限：策略审批、审计日志访问、内容隔离/解封处理权限。
- **Persona-SRE（Platform Ops，运维工程师）** – 核心诉求：在私有云 Kubernetes 集群中保障系统达到 SLO（如5分钟、P99 800ms、QPS、成功率等）；完善日志追踪和仪表盘监控，确保发布变更安全受控。典型权限：系统配置和维护权限（如调整资源配额、触发降级演练、查看系统状态等）。

- **Persona-DEV（Integrator，集成开发者）** – 核心诉求：依据插件合约扩展新的数据源类型；依据分析方法库接口添加定制的方法算法；根据 Schema 为前端或报告模板对接数据。典型权限：插件部署权限、方法库扩展权限、（通常无决策数据访问权限）。

3. Scope & Non-Goals（范围及非目标）

In-Scope（系统职责范围）：本系统覆盖从数据采集治理到分析产出的完整链路，包括： - **OSINT 数据采集编排**：由 Prefect 进行工作流调度与重试，Crawl4AI 执行具体爬取，FastStream 提供异步消息管道（采用统一的 topic 命名规范实现不同环境隔离和多租户隔离）。 - **数据源治理**：提供 CrawlPlan 管理（配置采集入口、频率、解析器、优先级等）和去重策略（URL Canonicalization + SimHash 内容指纹去重，保证幂等消费）；提供 SourcePlugin 接入合约（插件沙箱隔离、白名单审批、令牌/请求配额控制）。 - **知识检索与融合**：实现 **三层检索体系**（document/keyword 全文检索 + 向量语义检索 + 知识图谱检索）统一的查询 DSL 和 Query Planner 决策逻辑；确保文档、向量、图谱多存储写入顺序一致并最终一致性（提供自动校验机制）；维护知识图谱 Schema（节点/边类型），支持近实时社区摘要更新；提供 EvidenceFusion API，将图谱证据、向量相似证据和全文验证结果融合输出统一的证据列表。 - **分析推理与结论产出**：集成 GPT-Researcher 智能Agent执行 **ResearchPlan→工具调用路由→结果验证** 的分析编排；提供通用分析方法库接口（如命名实体识别、关系抽取、摘要、矛盾检测、事件聚类等算法）；以 **RecommendationCard** 统一结构输出分析结论（带风险标注和证据链）；支持报告导出（预定义 PDF 模板，自动添加水印和审计ID）。 - **可信度演化与安全**：实现多轮可信度评分演化API，对每条情报内容进行动态可信度评估并输出分解指标；实现对抗性攻击检测，输出 AdversarialAlert 告警及建议处置；提供策略治理机制（Rules Management Service / PolicyBundle）在检索规划、生成验证等环节注入自定义规则（如屏蔽特定来源、启用特定验证步骤），并支持策略的版本管理与快速回滚。 - **平台与运维**：支持私有云 K8s 多节点部署、CPU/GPU 资源池管理和弹性伸缩；提供多阶段部署迁移策略（本地→云端渐进迁移，保障数据一致性）；完善可观测性（OpenTelemetry Trace 全链路跟踪 + 预构建 Dashboard看板 + 关键指标告警）；实现分级降级阈值配置和自动触发；保障供应链安全（提供组件 SBOM、镜像签名，依赖版本锁定与CI安全门禁）。

Out-of-Scope（非目标/边界）：以下内容明确不在本系统责任范围内： - **GPT-Researcher Orchestrator 的基础数据存储**：本系统不负责长期爬虫的数据存储和管理（仅负责实时研究编排和工具调用）；对于长期批量数据存储，由外部数据湖或存储服务承担。 - **Prefect 工作流**：Prefect 仅用于调度编排，不负责消息传递或数据解析；消息总线由 FastStream 实现，数据解析和知识抽取由方法库组件承担。 - **FastStream 消息系统**：FastStream 仅提供 Topic/Queue 的异步投递，不参与具体业务逻辑处理或内容解析/模型推理，其可靠性（如至少一次投递）作为平台能力前提假设。 - **Crawl4AI 爬虫**：Crawl4AI 负责网页抓取和基础内容抽取，不负责高级知识推理、可信度判断或报告生成，这些由本系统分析层完成。 - **移动端原生 App**：V3.1 阶段终端以网页H5/PWA为主，未计划开发原生移动 App（如未来需要将另行规划），移动端支持限于浏览器访问。 - **其他缺陷/待确认点**：例如 **付费或封闭平台的数据获取** 不在默认支持范围。本系统假设只处理合法公开数据；对于受限/封闭平台，需要业务方提供授权接口或采用特定插件接入方案，超出本系统默认采集范围。

4. Glossary（术语表）

本节汇总了文档中的主要术语和缩写：

- **OSINT**（Open-Source INTelligence）: 开源情报，指公开来源数据的情报收集与分析。
- **SLA / SLO / SLI**: 服务级别协议/目标/指标。SLA指对外承诺的服务级别（违反可能需赔偿），SLO是内部运营目标，SLI是服务级别指标的实际测量值。本规范中**对外承诺均称 SLA，对内部性能目标称 SLO**。
- **P95 / P99**: 第95百分位/99百分位统计值。例如“P99 ≤ 800ms”表示99%的请求延迟不超过800毫秒。
- **L0-L3 降级等级**: 系统资源不足时的分级降级策略。L0正常；L1轻微降级（关闭非关键耗资源功能）；L2中度降级（暂停部分分析任务，保障核心检索）；L3严重降级（暂停新内容处理，仅提供已有内容查询）。

- **CrawlPlan**: 爬取计划配置，包括数据源 URL 列表、抓取频率、深度、解析器类型、优先级等。
- **SourcePlugin**: 数据源插件，用于扩展新类型数据源的采集。运行在沙盒环境，需注册签名和设定资源配额以防止插件影响主系统。
- **Prefect**: 开源工作流编排框架，这里用于调度定时爬虫、控制任务重试等。
- **FastStream**: 高性能消息队列系统，用于本系统内部异步事件传递（如新文档事件）。
- **HiRAG**（Hierarchical Retrieval-Augmented Generation）: 分层知识检索增强生成。一种将知识图谱的多跳推理与大模型生成结合的方法。HiRAG 在本系统中用于复杂推理场景，增强生成结果的逻辑一致性和可解释性。
- **RMS**（Retrieval Management Service）: 检索管理服务。用于管理和注入检索/分析策略规则（PolicyBundle）影响系统行为。RMS 可以控制查询规划决策、验证步骤等，实现人工策略对系统的干预。
- **PolicyBundle**: 策略包，一组配置规则影响系统检索和分析流程。例如黑名单词、优先数据源、验证逻辑开关等。支持版本化发布及快速回滚。
- **RecommendationCard**: 推荐卡片。本系统用来呈现分析结论的结构化输出实体，包含结论摘要、风险评估、证据链等内容，便于决策者浏览和纳入报告。
- **EvidenceFusion API**: 证据融合接口。用于将来自全文检索、向量匹配、知识图谱等多来源的证据进行相关性融合与去冗余排序，输出综合证据列表及评分。
- **PersonaSnapshot**: 人物/实体快照，记录某 Persona 在特定时间点的属性状态（如职务、影响力、可信度等）。连续的 PersonaSnapshots 组成时间序列用于检测变化 (Change Detection)。
- **Adversarial (Attack) Poisoning**: 对抗性攻击/投毒。指恶意构造或操纵输入数据使模型/系统产生偏差或错误结论的行为。本系统通过检测异常模式和可信度骤降来识别此类攻击并告警。
- **OpenTelemetry (OTel)**: 开放遥测协议，用于分布式追踪和度量。系统使用 OTel 统一跟踪跨服务的请求流程（trace），收集关键性能指标。
- **SBOM**（Software Bill of Materials）: 软件物料清单，列出系统所用开源组件及版本清单。用于供应链安全分析，结合镜像签名、漏洞扫描在CI中强制检查。
- **Quality Gate（质量门禁）**: CI/CD流程中的质量检查点。例如测试覆盖率、性能回归阈值、漏洞扫描等，未通过时阻止版本发布。

(注：更多业务术语在需求内容中有上下文解释。)

5. Use Cases（核心用例）

以下用例以 **UC-*** 编号表示系统的核心用户交互场景。每个用例提供触发方式、主要步骤、输出结果以及异常/失败处理方式，保证覆盖主要功能路径和异常路径。

UC-001: 发起研究任务（Deep Research Orchestration）

Trigger: 分析师 (Persona-AN) 在系统前端输入一个研究主题或具体问题（可包含实体名称、时间范围、地域等条件），并点击“开始研究”。

Main Success Scenario:
1. **[提交查询]** 系统接收到分析师的研究请求（例如查询文本和选定参数），记录请求的 trace_id 和 user_id 用于追踪。
2. **[任务规划]** 智能Agent（GPT-Researcher Orchestrator）解析研究问题，生成一个内部 ResearchPlan（可能包括需要检索的子问题列表、调用的方法模块等）。
3. **[检索执行]** 系统根据 ResearchPlan 自动执行检索和数据获取：调用 Query Planner 对接全文索引、向量引擎和知识图谱，获取与主题相关的候选证据文档集合。对于需要的最新数据，触发即时采集（如尚未在库的数据源，通过 FastStream 发送 high-priority 抓取任务）。
4. **[分析与验证]** 系统对检索结果应用分析方法库中的模型和规则进行处理：如提取关键实体事件、生成初步摘要。Verifier 组件交叉验证证据一致性，过滤掉冲突或低可信度信息。如有 PolicyBundle 规则（例如必须包含某类来源），在此阶段应用，可能增补额外检索或验证步骤。

5. **[结论生成]** 智能Agent 汇总分析结果，产出研究问题的回答/结论，以及支撑该结论的 Top-N 证据列表。若结果涉及行动建议或风险判断，系统生成对应的 **RecommendationCard**（包括 risk_level、summary、evidence_list 等）。
6. **[结果返回]** 系统将 Research Answer（文字结论）连同证据列表和可选的 RecommendationCard 一并返回给分析师。在前端展示：结论摘要 + 证据列表（支持展开查看证据详情）+ 如有 RecommendationCard 则以卡片形式显示风险评级和建议。

Outputs:
- **Research Answer**：针对用户问题的文字结论摘要。
- **Evidence List**：支撑结论的证据条目列表，每条包含引用的文档ID或来源标识、证据摘要片段等（参见 C-014 RecommendationCard Contract 中 EvidenceItem 定义）。
- **RecommendationCard**（如适用）：当系统判定需要给出风险警示或行动建议时，输出 RecommendationCard，对应包含 risk_level 等字段（High/Med/Low）以及系统建议的后续行动。
- 所有输出结果都附带唯一 trace_id，以便日后审计追踪。关键输出内容（如 RecommendationCard）的 policy_version 也在内部记录，确保可以追溯当时采用的策略规则版本。

Failure Handling:
- 超时/部分失败: 如果Agent在预定时限内未能完成所有分析步骤（例如外部模型响应超时），系统不会阻塞返回。**降级措施**：在达到超时阈值时返回**部分结果**（已完成的检索证据和可能不完整的结论）给用户，并在界面提示“分析未完全完成”。对应的错误码如 `5201` **分析超时** 将记录在响应中，用户可选择稍后重试。系统后台则继续完成剩余分析并记录日志，但不会延迟当前响应。
- 数据源不可用: 如果在检索阶段某关键数据源或服务（如向量检索服务）不可用，系统自动启用降级策略：跳过该来源或改用备用方案（例如只用全文检索）。用户端可能收到提醒“部分数据源暂不可用，结果可能不完整”。此情况下系统返回 **成功响应**（HTTP 200）但在结果中附带一个 Warning 代码（如 `2302` 向量服务不可用）提示。不影响已有结果的查看，并将在 AuditLog 中记录影响范围。
- 权限不足: 如果分析师请求访问其无权限的数据或项目，系统立即返回错误 `1002` **Access Denied**，提示无权执行操作。此时不会启动任何后续检索行为。
- 系统降级: 若当前系统处于 L3 降级（暂停新内容处理），系统仍尝试回答用户查询但**不触发新数据采集**。如查询所需的新数据不可获取，系统仅基于已有数据给出结果，并在界面醒目位置告知“系统繁忙，新数据暂未纳入”。返回码附 `2403` **Degraded Mode Active**（提示当前为降级模式）。当降级恢复后，系统会自动处理先前积压的数据，新数据的分析报告可在稍后获取。
- 其他内部错误: 若遇未预料的系统错误导致无法提供任何结果（例如关键模块异常），系统返回 `1500` **Internal Error** 通知分析师重试，并立即记录详细错误日志（包括 trace_id）。对于此类失败，建议Ops人员查询 Trace日志定位问题，恢复正常后由分析师重新执行任务。

UC-002: 人物/事件长期回溯（Historical Backtrace Timeline）

Trigger: 分析师 (Persona-AN) 在前端选择“回溯分析”，指定一个人物（Persona）或事件类型以及时间范围（如近5年），提交回溯请求。

Main Success Scenario:
1. **[提交参数]** 分析师输入待回溯的 Persona 标识（或事件关键词）以及所关注的时间窗口（可以是起止年份或特定事件发生后的时期）。系统接收请求参数，例如 persona_id=U-12345，time_window=2018-2023。 2. **[历史数据检索]** 系统在内部检索与该 Persona/事件相关的存档数据：包括知识图谱中该 Persona 节点及关联事件节点，在 ArcticDB 时序库中查询该 Persona 的 **PersonaSnapshots** 序列，以及全文索引中过去指定时间范围内涉及该 Persona 的文档集合。系统重点获取每年/月的关键状态变化数据。
3. **[变化检测]** 系统对 PersonaSnapshots 时间序列运行 **Change Detection** 算法：识别该人物在属性或影响力上的显著变化点（例如职位变动、观点转变、可信度大幅波动）。同时分析相关事件序列，找出峰值或异常点（如某月相关报道量激增）。
4. **[生成时间线]** 系统据此构建**时间线视图**：列出时间顺序的关键节点，每个节点包含该时间点的人物状态/事件摘要、变化说明，以及支撑的证据（引用当时的报道或数据）。例如：“2020年6月：职务从XX升任XX，可信

度评分下降20%【证据：新闻稿A】”。
5. **[衍生洞察]** 如果检测到潜在因果关系或矛盾点，系统在时间线相应位置标注**洞察**。例如：“某事件发生后人物态度产生转变”或“出现自相矛盾陈述”。这些洞察由知识图谱和方法库提供（如因果推断模块或矛盾检测模块），并给出证据。
6. **[结果呈现]** 系统将完整的时间线结果返回给分析师，包括：关键时间节点列表，每个节点的描述和证据来源、以及全局概览统计（如期间内主要关联事件及频次）。前端以交互式时间轴显示，允许分析师点击查看某节点的详细证据列表。

Outputs:
- **Timeline Events**：时间线上的关键事件/变化节点集合。每个节点包括 timestamp/时期、description（该时刻人物/事件的状态变化描述）以及 evidence_list（支持该节点的文档引用列表）。
- **Persona Insights**：系统发现的关于该人物/事件的额外洞察信息（如关联因果、矛盾点），附在相关时间节点或作为时间线总结部分。
- **Evidence References**：对于每个节点，证据列表中的条目包括文档ID、出处来源、摘要片段等，使分析师可进一步阅读详细内容。
- 时间线数据结构符合 **C-001 Document** / **C-010 PersonaSnapshot** 等契约定义，以确保后续算法或导出模块可重用。trace_id 贯穿整个回溯查询流程，确保可追踪。

Failure Handling:
- 无数据: 如果指定的人物/事件在系统中没有任何记录（如 persona_id 不存在或时间范围内无相关数据），系统返回 **空结果** 响应（HTTP 200），并在界面提示“无历史数据”。对于这种情况，不算错误，无特定错误码，但AuditLog记录查询条件和结果为空。分析师可确认人物名称是否正确或扩大时间范围后重试。
- 时间范围过大: 如果请求的时间窗口跨度非常长（例如数十年）导致数据量过大，系统可能**自动拆分**查询或仅聚焦较近年份细节。必要时会在结果中**折叠**过早期的事件，只给出概览，提示分析师缩短范围以查看更多细节。不会直接报错，但系统在响应附带 Warning 代码（如 `1103` QueryTooBroad）表示结果已简化。
- 查询过于笼统: 如果分析师仅给出一个通用实体类型或模糊名称，导致检索结果关联太多不同主体，系统返回 **`1101` Invalid Query** 错误，提示需要更明确的Persona标识或限定范围。这防止返回海量无关信息。
- 分析失败: 在变化检测或图谱查询阶段如果出现算法异常（例如ArcticDB读取失败或算法服务错误），系统返回部分时间线结果（例如仅基于图谱关系的事件列表），并在对应位置标注“分析暂不可用”。同时返回 Warning 代码如 **`2303` AnalysisPartial**。系统运维将收到告警检查算法服务。分析师得到结果但提醒可能不完整，可以稍后重试获取完整分析。
- 权限/隔离: 如所请求的Persona涉及跨租户数据（不应该发生，因为Persona应限定当前租户），系统检测到将立即终止查询并返回 **`1002` Access Denied**（多租户隔离保护）。AuditLog记录该异常请求。

UC-003: 配置长期采集计划（CrawlPlan Authoring）

Trigger: 系统管理员 (Persona-AD) 在“数据源管理”界面新增或修改一个 CrawlPlan，例如添加新的新闻站点爬取。管理员填写计划细节（入口URL、爬取深度、包含/排除规则、执行频率cron、解析器类型、优先级等），并点击“保存”。

Main Success Scenario:
1. **[提交配置]** 管理员填妥 CrawlPlan 表单并提交。系统进行表单验证（例如URL格式、Cron表达式合法性等）。通过验证后，系统创建一个新的 CrawlPlan 对象（或更新已有计划），赋予唯一 plan_id。
2. **[保存计划]** 系统将 CrawlPlan 配置存储到数据库（Contracts: **C-002 Project** / DataSource 内含该计划）。若计划为新建，状态标记为“Active”。如果是修改已有计划，版本号（version）+1 并记录变更人。
3. **[调度生效]** 调度模块（Prefect）检测到新计划后，在下一个计划时间点按 Cron 表达式安排任务。例如计划cron为每日02:00，则在明日02:00执行首次抓取。对于立即生效需求，管理员也可以选择“立即运行一次”，系统则立刻触发一次抓取任务。
4. **[执行采集]** 到达计划时间后，Prefect触发 Crawl4AI 执行实际抓取任务。Crawl4AI 根据计划配置去访问入口URL，按深度抓取页面，应用配置的解析器（如 htmlParser、pdfParser）提取正文内容等。对每个成功抓取的页面，Crawl4AI 发送 crawledPage 事件经 FastStream message **ingestion.newDoc** topic 投递到系统异步处

理管道。
5. **[去重与入库]** 系统 Ingestion 服务消费 newDoc 消息，计算内容指纹（SimHash）和URL规范化，以识别重复。若发现与现有文档重复（content_hash 已存在），则跳过该文档（记入重复计数）。否则创建新的 Document 对象并继续后续索引流程。这个重复策略确保相同内容不会多次进入系统。
6. **[完成通知]** 抓取任务完成后，系统在 CrawlPlan 管理界面更新该计划的最近运行状态（如“最后运行时间”、“新采集文档数”、“错误数”等）。管理员可以查看计划入库进度。如果该计划为一次性/临时任务，完成后状态可标记为“Completed”；如果是周期任务，则等待下周期继续。系统记录AuditLog：如管理员A创建了计划X，包含关键参数摘要。

Outputs:
- **CrawlPlan 配置状态**：新的或更新的 CrawlPlan 持久化存储后，在界面上可见其 plan_id，状态为 Active（激活）或 Pending（如果设定未来开始），下次执行时间等信息。
- **Schedule 执行结果**：每次计划执行时，系统产生运行日志，包括抓取到的新文档数量、新增 Document 数量、跳过重复数量、发生的错误列表（如某些URL无法访问）。这些结果在管理界面可查询（或通过 **C-014 AuditLog** 记录关键事件）。
- **新文档入库事件**：对于抓取到的新文档，成功进入索引的则产生 Document 记录（参见 C-001）并触发后续索引/分析；如果重复则不产生新Document但计入日志。

Failure Handling:
- 配置验证失败: 如果表单填写有错误，如URL格式非法、cron表达式无效或漏填必需字段，系统前端在保存时即时提示对应错误，不会提交到后台。管理员需更正后再提交。无后台错误码，因为未通过前端校验。
- 计划重复/冲突: 如果新增的计划与已有计划配置冲突（例如相同的数据源URL已经有一个活跃计划），系统返回错误 `1400` **PlanConflict**，拒绝创建重复计划。管理员可选择修改已有计划而非新建。
- 权限不足: 如果非管理员用户尝试创建/修改 CrawlPlan，系统禁止操作并返回 `1002` **Access Denied**。该事件也会审计记录。
- 执行错误: 在实际抓取过程中，可能出现网络错误或解析错误：例如某URL超时、解析器抛异常等。对于每个失败的页面，Crawl4AI 会记录错误并继续其他任务，不影响整体计划进行。执行完毕后，系统在计划运行结果中标明错误数和示例错误。若整体任务因为严重错误中止（极少情况，如Crawler进程异常崩溃），Prefect会自动重试根据策略。除非重试多次仍失败，否则系统不会生成全局错误事件。因此对管理员来说，会看到该次运行标记为失败（带错误详情），但**不会**影响已采集的数据入库。该情况下可以在下个周期等待重新抓取或手动重启计划。
- 幂等重复处理: 如果管理员重复提交了相同的计划（误点保存多次导致多条重复计划），系统利用 idempotency_key（例如根据URL+调度参数计算）识别出重复提交，将**拒绝第二次提交**并返回 `1400` **DuplicateRequest**错误，防止创建完全相同的重复计划。
- 停用/删除计划: 属于变更操作。如果管理员停止或删除一个计划，系统需等待当前执行完再停止后续调度。删除操作立即标记计划状态为“Deleted”，并AuditLog记录。关联的采集任务若正在运行则允许完成当次。计划删除后相关数据（如已采集文档）默认保留，只是不再更新。若管理员要求同时删除数据，则需执行数据删除流程（参见数据治理）。

UC-004: 近实时增量采集 → 5 分钟可检索（5-min Pipeline）

Trigger: 外部爬虫服务 Crawl4AI 抓取到新的网页内容时，通过 FastStream 发送一条 newDoc 消息到本系统的 **ingestion.newDoc** Topic。此事件触发系统的增量处理管道。

Main Success Scenario:
1. **[接收新文档事件]** 系统 Ingestion 模块侦听到 ingestion.newDoc 消息，其中包含新页面的元数据（source_id、抓取时间等）和内容（或内容存储位置引用）。系统立即记录当前时间作为 ingestion.received_at 时间戳。
2. **[解析与重复检测]** Ingestion 对消息中的原始内容进行解析（使用相应 Parser，将HTML等转为纯文本和结构化字段）。生成初步的 Document 对象（带内容摘要、metadata）。随后计算内容哈希（content_hash）并查询是否已有重复。如果content_hash已存在且来源URL相似，则认为是重复文档：记录

Document.dedup_ref指向已有文档ID，跳过后续索引（或根据策略更新已有文档的更新时间等）。若非重复，继续处理。
3. **[入库索引]** 对于需要纳入的新 Document，系统分配全局唯一 doc_id，并写入 **Document Store**（持久化存储原文或解析后的内容）。接着依次进行索引：
- **全文索引**：将文档内容索引到全文检索引擎，完成后标记 Document.indexed=true，并记录 index.search_ready_at 时间戳（表示可被检索）。
- **向量索引**：调用向量服务对文档生成Embedding向量，将向量写入向量索引库，并建立doc_id关联。
- **图谱更新**：解析文档中的实体、关系，将新事实融合到知识图谱：如创建/更新 Persona 节点、事件节点及关联边，并记录这些节点的来源和引用计数。如果有社区摘要节点则更新（例如重新计算人物在社交媒体的影响力指标）。
- **策略评估**：应用 PolicyBundle 对新文档内容进行检查：如根据策略决定是否触发额外验证（Verifier）或标记该文档风险标签（例如命中黑名单关键词则增加字段Document.risk_tag）。
4. **[分析准备完成]** 当上述索引和基础分析都完成后，系统标记 Document.analysis_ready=true，并记录 analysis.ready_at 时间戳。此时该文档已完全可用于复杂分析（如高级问答、图谱推理）。通常 **analysis.ready_at** 与 **search_ready_at** 时间间隔很短（几秒至几十秒）。
5. **[可检索通知]** 一旦 search_ready（索引完成），系统即可将该文档纳入用户查询结果。对于有订阅相关主题的分析师，系统可实时通知（如“新内容XYZ已可检索”）。
6. **[性能计时]** 系统持续监控从 ingestion.received 到 search_ready 的时间差，并计算统计指标P95等，以验证是否满足 5 分钟SLO。若本次处理超过阈值，将在Metrics中记录异常事件供运维调查。

Outputs:
- **Document 对象**：每条新内容对应一个 Document 记录（见契约 **C-001**），填充了 ingestion、索引、分析各阶段的时间戳。`indexed=true` 表示已进入全文索引，`analysis_ready=true` 表示已完成全部分析处理。
- **Index entries**：相应的全文索引项和向量索引项可供查询。对于知识图谱，可能产生新的节点和关系供图谱查询使用。
- **Ingestion Metrics**：系统产生日志和指标，如 ingest_pipeline_latency（本次文档从接收至search_ready用时）。这些数据用于计算5分钟SLO达成情况 (详见指标 MTR-001)。
- **User-facing**：正常情况下无直接用户界面输出（因为这是后台流程），但若有分析师当前正检索相关内容，则新文档将在其查询结果中即时可见；同时如订阅/提醒功能配置，会向订阅者推送新情报通知。

Failure Handling:
- 解析或索引失败: 如果文档解析出现异常（例如 Parser 无法处理格式），系统将记录 Document.processing_error_code（例如 `2101` ParseFailed），并将该文档标记为 analysis_ready=false但不进入索引。由于解析失败文档无法检索，系统可选择重试解析（基于策略，可能放入一个人工标记队列）。不会影响其他文档流程。该错误不会直接暴露给终端用户，但触发告警供运维介入。
- 存储失败: 如果Document写入数据库或索引写入发生错误（例如索引服务宕机），系统进入 **降级模式L3**：暂停后续 ingestion.newDoc 消息处理，将当前未完成的文档事件保存在队列。系统同时发出告警。降级期间，新内容堆积但**不会**丢失。恢复后，系统按先入先出顺序处理堆积消息，并计算恢复积压SLO（要求积压内容在恢复后**X**时间内处理完，详见NFR）。对于用户查询请求，在L3期间系统只能返回已有数据，并在需要时提示“系统繁忙，最新内容更新延迟”。这种情况下不会返回错误码给用户，而是在 DegradationStatus API 中体现 degrade_level=3。
- 重复内容: 如果content_hash已存在（识别为重复），系统**跳过索引**：记录Document重复引用并立即标记 analysis_ready=true（因为无需处理）。不会触发 downstream pipeline。这不是错误情景，无需告警。但AuditLog会记下跳过了重复doc_id。当重复率异常升高时，可作为数据源质量问题由运维关注。
- 降级处理: 在资源高负载导致主动降级场景下（L1/L2），系统可能 **延迟部分分析步骤**：例如仅完成全文索引 (search_ready) 而将向量和图谱处理延后。当系统降级至L2时，新文档依然索引以满足基本检索，但复杂分析（如向量计算）可能暂缓。这时Document.analysis_ready_at留空，analysis_ready=false；系统在DegradationStatus中记录触发“分析延迟模式”。降级恢复后，这些文档的剩余分析将补跑完成，并补记 analysis_ready_at。用户查询在降级期间可能只能检索到新文档的文本内容而无向量/图谱关联，提高系统生存性。降级情况下不单独对用户报错，但在后台Metrics标记SLO豁免。

UC-005: 社媒账号画像监控（Account Profile & Monitoring）

Trigger: 管理员或分析师（Persona-AD/AN）在系统中订阅了一个社交媒体账号或特定话题。订阅配置完成后，系统开始持续监控该账号/话题内容发布，并对画像和异常进行分析。

Main Success Scenario:
1. **[订阅配置]** 用户在“订阅中心”选择添加一个**社交账号**或话题。例如输入Twitter用户名 @example 或话题关键词。系统创建相应订阅任务，包括数据源（对应社媒API或爬虫）及频率。若需授权，则提示管理员提供API令牌等。订阅任务类似 CrawlPlan，将账号新内容定期抓取并入库。
2. **[账号画像更新]** 系统为每个社媒账号维护一个 **AccountProfile**（或作为 Persona 特例）。每当该账号有新帖子（通过抓取或Webhook获取），系统更新 AccountProfile 中的统计属性：如粉丝数、发帖频率、主要发布主题标签、内容立场倾向（通过NLP分类）、历史可信度评分等。更新通过对比新旧内容及调用分析方法（情感分析、主题聚类等）完成，并生成新的 PersonaSnapshot 或直接更新AccountProfile字段。
3. **[异动检测]** 系统对账号的内容序列运行异常检测。例如检测短期内该账号发布行为的显著变化：
- 内容量激增或骤减（可能被接管或沉默）
- 言论立场转变（例如观点突然与以往相反）
- 交互模式异常（如点赞/转发量异常升高，可能存在水军）
- 可信度评分显著下降（可能出现投毒内容）

一旦检测到上述**异动**，系统立即生成一条对应的 **AdversarialAlert / PersonaChange** 告警，标注变化类型和严重程度。
4. **[触发分析]** 对于高严重级别的异动（例如可信度跌至 Low），系统自动触发进一步分析流程：例如调用EvidenceFusion搜集近期相关讨论，或者生成一张 **RecommendationCard** 提示决策者采取行动（如“账号X可能被劫持，建议暂时停止采信该来源”）。
5. **[告警通知]** 系统将产生的告警推送给相关用户：对于Persona-AN，可能在分析工作台看到订阅账号的状态变化提示；对于Persona-GOV，严重告警还通过中控台或邮件通知。用户可点击查看该账号详情，包括最新Profile及变化图表，以及系统给出的建议。
6. **[持续监控]** 系统持续执行上述流程，AccountProfile定期更新。所有变更、告警均记录AuditLog，以供事后审计。用户可随时取消订阅，取消后系统停止特定账号的数据抓取和分析，但保留历史画像数据（按保留策略）。

Outputs:
- **AccountProfile**：每个订阅账号都有一份画像，包括静态属性（用户名、简介等）和动态指标（粉丝数、发帖数、主要主题、可信度评分等）。这些数据结构化存储，可通过查询或图表形式在前端查看。
- **PersonaSnapshots**（如适用）：如果AccountProfile通过PersonaSnapshots实现，则会存储多条时间序列快照，用于趋势分析。在前端可视化如折线图显示粉丝增长、情感倾向随时间变化等。
- **Alerts**：当检测到显著异动，会生成 AdversarialAlert 对象（见契约 **C-015**）或 personaChange 通知。Alert包含alert_id、类型（内容操纵/账号异常等）、严重等级和说明。它会以通知方式发送给订阅者，并在中控台“告警列表”中出现。
- **RecommendationCard**（如系统采取了生成）：对于高风险异常，如投毒嫌疑，系统可能输出一张RecommendationCard 建议采取措施。此卡片将出现在决策者界面或报告中，包含风险等级=High、summary描述异常以及证据（如近期可疑帖子示例）。
- **Audit Log**：订阅创建/删除、重要画像变更、告警推送等关键操作均写入审计日志，包括操作者、时间和详情字段。

Failure Handling:
- 数据源不可用: 若所订阅的社媒平台API失效或抓取受限（如被封IP或令牌过期），系统会在 AccountProfile 中标记“数据获取中断”，并对运维发送告警（低级别）。前端对用户提示“监控暂时中断，正在重试”。系统将按照指数退避策略重试数据抓取，或请求管理员更新令牌。失败不会影响系统其他部分。
- 误报/阈值调整: 异动检测可能产生误报（例如正常事件误判为异常）。治理负责人 (Persona-GOV) 可以在告警界面将某条 Alert 标记为“False Positive”（误报）。系统会记录此反馈，并在模型中调整（例如提高阈值）。该Alert随即从高优列表中移除。此操作AuditLog记录，包括alert_id和处理人。

- 并发监控性能: 当订阅的账号/话题很多时，系统调度频率可能需要调整以避免资源饱和。如果系统检测到监控任务积压，会自动降低非关键订阅的刷新频率（这属于降级策略的一部分）。不会直接报错，但运维Dashboard会显示“订阅任务延迟”。管理员可通过增加资源或调整频率解决。
- 权限/配额: 普通分析师可能无权订阅某些敏感账号（比如竞争对手高管账号可能只允许管理员订阅）。如违反权限，系统拒绝订阅请求并返回 `1002` **Access Denied**。对于每个租户设有最大订阅数量配额，如果超限返回 `1403` **QuotaExceeded** 错误，提示管理员提请增加配额或删除部分订阅。
- 取消订阅: 用户取消后，若再次订阅同一账号，在短期内系统应能恢复历史数据（如果仍在保留期内）。如因某原因没有保留历史，系统会重新全量获取近期数据。这不算失败场景但需用户知晓可能有短暂延迟重新构建画像。

UC-006: 推荐卡片驱动的行动建议（Recommendation Card to Action）

Trigger: 系统检测到某触发条件满足时自动生成一条 RecommendationCard。这些触发条件包括但不限于：Persona 异动（如 UC-005 告警）、事件聚类形成新的热点、某情报内容可信度跌至低、检测到对抗攻击等。生成的卡片将在系统界面中弹出或列表中展示，供相关用户查看。

Main Success Scenario:
1. **[触发事件]** 一项预定义规则或模型触发了推荐卡片生成。例如：
- **Persona 异动**：治理员订阅的重要人物发生高风险变化（风险等级High的 AdversarialAlert）。
- **事件聚类**：系统识别到短时间内大量报道聚焦同一新事件，且关联用户尚未关注。
- **策略触发**：PolicyBundle 规则定义了某种模式下需要提醒决策者（如连续出现某敏感词的报道N篇）。
2. **[卡片生成]** 系统调用 RecommendationCard 生成模块，传入触发事件的关键信息。模块会汇总相关证据（通常调用 EvidenceFusion 获取该主题下最相关的Top证据），并根据规则生成**行动建议**。卡片字段填充包括：summary 对当前情况的说明、evidence_list 列出支持依据、risk_level 评估风险等级、可能还有 insight 或 next_action 建议字段。
例如: “检测到账号A疑似被操纵发布不实消息，**建议**：暂时停用该账号数据并人工核查。”
3. **[审核发布]** 对于某些高敏感场景（如重大决策建议），系统可以要求治理负责人 (Persona-GOV) 审核卡片内容后再发布给所有决策者。治理人在中控台的“待审批推荐”列表中查看卡片详情，勾选通过或编辑后通过。一旦审核通过，卡片即刻标记为Active状态。(若策略设置不需要人工审核，此步骤跳过)。
4. **[通知分发]** 系统将 RecommendationCard 分发至相关用户：一般是决策者 (Persona-DM) 和相关分析团队。分发形式可以是在前端**通知列表**出现新卡片提示，或通过邮件/短信发送卡片摘要（根据系统配置）。同时，该卡片也在系统“推荐”板块中列出，供随时查阅。
5. **[用户查看]** 决策者点击查看卡片，看到结构化的信息：风险等级（用颜色/图标突出）、概要说明、证据链接列表、建议的行动项（如“Apply Policy Change”按钮）等。如需要更多上下文，决策者可以点击证据查看详情或要求分析师进一步调查。
6. **[一键采纳]** 如果卡片包含具体行动选项（如“隔离此数据源”或“升级监控等级”），且用户有权限执行，则界面提供相应按钮。用户点击后，系统执行对应操作（比如修改策略使某数据源隔离），并在卡片上标记“已执行 by UserX”。卡片状态更新为Completed或Archived以备审计。若卡片仅为建议，用户线下采取措施则由治理人员手动标记卡片处理完成。

Outputs:
- **RecommendationCard 对象**：完整的推荐卡片数据结构（见契约 **C-014**），包含 card_id、summary、evidence_list、risk_level、timestamp 等。可能还有 recommended_action 字段指示建议的操作（例如 `"action": "SuspendSource"`）。卡片附带 policy_version 和 trace_id 用于审计。
- **Notification**：用户界面的通知或消息推送，提醒有新的 RecommendationCard。包括卡片简要信息和风险级别。
- **Audit Log**：卡片的生成、审批、发布、以及后续执行操作等事件全部记录审计日志。例如生成时记录 trigger_event_id、生成人（系统）等；审批通过记录审批人ID；用户点击“采纳建议”执行操作记录具体动作和涉及对象。
- **状态更新**：卡片在系统中的生命周期状态（Draft/Active/Executed/Archived）。这些状态变化在数据库中存储，可用于后续报告导出或回顾分析。

Failure Handling:
- 卡片生成异常: 如果RecommendationCard模块本身出错（如模板渲染失败、缺少必要数据），系统捕获异常，记录错误日志 **2304 RecCardGenFailed**，此时不会向用户发布卡片。对于高优先的触发事件，系统fallback为发送一条普通告警通知，内容简单描述触发事件，让治理人员知晓（避免完全无反馈）。之后由开发排查生成模块问题。
- 审批超时/拒绝: 如果需要人工审核但治理负责人长时间未处理，系统将在卡片触发后一段时间（如30分钟）再次提醒。一旦超过设定时限仍未审核，系统可按预案选择**自动发布**（如果策略允许紧急发布），或者将卡片标记为Expired不再发布。审核被拒绝则卡片作废存档，AuditLog记理由。
- 通知失败: 若邮件或短信网关不可用，导致卡片通知未达，系统会在用户下次登录时以弹窗形式提醒未读卡片。同时对Ops告警 **9101 NotificationFailed** 以检查通知服务。
- 执行操作失败: 如果用户点击卡片上的行动按钮触发后台操作，但操作执行失败（例如试图隔离数据源但策略服务未响应），系统向用户反馈“执行失败，请稍后重试”，并返回相应错误码（例如 **5501 ActionFailed**）。卡片状态保持未执行，用户可重新尝试或交给管理员处理。系统会将失败原因记录AuditLog。
- 权限限制: 若用户尝试执行其权限范围外的建议动作（例如分析师尝试执行只有管理员能做的操作），系统立即提示拒绝（**1002 Access Denied**），并要求有权限的用户执行。卡片本身的查看不受限制，但执行按钮对无权限用户不可点击（灰化）。
- 重复卡片: 系统应避免同一事件触发重复卡片。如果检测到规则重复（如已存在相同内容Active的卡片），则新的触发不生成新卡，而是在已有卡片上记录发生次数或更新时间。使用 **dedup_key**（例如基于触发类型+对象）避免重复。这保证决策者不被相同警示刷屏。

UC-007: 生成可交付报告（PDF Export）

Trigger: 分析师 (Persona-AN) 在报告模块选择一套需要导出的内容（通常是一组 RecommendationCards 或分析结论片段），并选择一个预定义的报告模板和输出语言，然后点击“导出 PDF”。

Main Success Scenario:
1. **[选择内容和模板]** 分析师在前端勾选欲包含在报告中的项（如多张RecommendationCards、分析结论段落），并从模板库中选择一个报告模板（例如“标准情报简报模板”）。也可选择报告中使用的语言（如中文/英文）。
2. **[提交导出任务]** 用户点击“导出”，系统前端调用后端报告服务接口提交一个 **ReportJob** 请求（见契约**C-010**）。请求包含所选内容的ID列表、模板ID、输出语言等。系统进行权限和有效性校验：确认用户有权限访问所有所选内容，模板存在且可用。然后接受任务，返回一个 **job_id**。
3. **[队列处理]** 报告生成任务被放入报告导出队列后台异步处理，以免阻塞前端。系统立即向用户界面返回“报告生成中”状态（可能显示进度条或提示稍候下载）。在后台，ReportJob包含job_id、请求者、任务详情等被持久化，并标记状态 Running。
4. **[组装内容]** 报告服务根据模板定义组装文档：拉取每个所选 RecommendationCard/结论的详细内容插入模板相应部分（模板可能定义占位符如 {{summary_list}} 等）。同时附加系统生成的封面、目录、和审计信息页：通常包括**水印**（例如“机密，仅供XX使用”）和 **audit_id**。audit_id是此次报告导出的唯一标识，用于审计追踪。
模板合成过程中，系统根据所选语言执行必要的翻译（如果报告输出语言与内容语言不同，则调用翻译服务翻译卡片内容）。保证“准确传达原意”【在此使用双人工校对标准或高质量模型，详见FR-011质控要求】。
5. **[生成 PDF]** 系统使用排版引擎将组装后的内容渲染成 PDF 文件，添加页码、插入附录（如证据附件索引，如果模板要求附上High风险结论的全文证据）。报告每页底部自动加上水印和 audit_id 标记。生成成功后，将文件存储到临时下载存储，并更新 ReportJob 状态为 Success，记录完成时间。
6. **[下载交付]** 系统通知前端任务完成。分析师在界面上看到“下载报告”按钮激活，点击即可获取PDF文件。文件名通常包含日期和audit_id等信息。例如 Report_2025-12-18_Audit1234.pdf。用户下载成功与否也记录AuditLog（导出视为敏感操作）。报告完成品包含了所有结构化内容，决策者可以直接阅读或分享。

Outputs:
- **PDF 文件**：最终生成的情报报告PDF，按照模板美观排版，包含所选的所有结论卡片和内容。每页均有防伪水

印（如公司Logo+保密等级），并在页眉或页脚标注唯一 **audit_id**。报告封面/末页可能列出 audit_id、生成时间、策略版本等元数据。PDF文件可供下载，也可在系统内归档记录。
- **ReportJob 状态**：一个 ReportJob 对象（契约 **C-010**），记录此次导出任务详情：job_id、请求者user、创建时间、完成时间、状态码（Success/Failed等）、生成的文件路径或ID等。job对象用于在前端查询任务进度和结果。
- **Audit Log**：导出事件审计记录，包括执行导出的用户ID、时间、包含的主要内容项ID列表、audit_id、以及是否成功。任何报告下载操作也记录IP等信息以备合规检查。

Failure Handling:
- 模板错误: 如果选定的模板文件内容有问题（如占位符与实际数据字段不匹配导致渲染错误），系统捕获异常，标记ReportJob状态为 Failed，并返回用户一个错误通知 **5401 TemplateError**。用户将无法获得PDF。系统会建议尝试其他模板或联系管理员修复模板定义。该错误也告警运维去检查模板配置。
- 内容缺失: 如用户所选的某些内容ID找不到对应数据（可能内容已被删除或权限变化），系统在组装阶段发现后将跳过该条，并在报告中插入占位说明“内容不可用”。同时对用户提示部分内容未包含，但报告仍生成（Success状态，Warning标记）。AuditLog记录哪些项缺失。如果缺失内容属关键，系统也可以直接Fail任务，返回 **1200 ContentNotFound** 错误让用户调整选择。此策略视实现而定。
- 权限不足: 如果用户试图导出包含其无权限的数据（跨项目/租户数据），系统立即拒绝任务，返回 **1002 Access Denied**，不创建ReportJob。提示用户移除未授权内容。
- 生成超时: 报告生成通常数秒即可完成。但如果所含内容很多导致生成时间过长（例如>30秒），系统可能后台继续处理，但前端可能给出一个提示链接稍后刷新获取。若后台超过设定阈值（如5分钟）仍未完成，系统将中止生成，ReportJob标记Failed，并通知用户 **5402 ExportTimeout**。用户可选择缩减内容后重试。
- 文件下载失败: 如果PDF文件已生成但用户下载时网络中断，用户可在一定时间窗口内重新下载（系统保存生成文件例如24小时）。若过了保存期，点击下载会提示文件已过期 **1201 FileExpired**，此时用户需重新触发导出任务。
- 降级影响: 在系统 L2/L3 降级情况下，为保障核心查询，可能**暂停报告导出**（属于非核心操作）。如果用户尝试导出时系统正处降级，系统将立即返回错误 **2403 DegradedModeActive** 或简单提示“当前系统繁忙，请稍后再试”，不创建任务。AuditLog记录拒绝。等系统恢复后用户需重新操作。

UC-008: 策略发布与离线精炼（PolicyBundle Rollout & Offline Refine）

Trigger: 治理负责人或管理员（Persona-GOV/AD）在中控台发布了一版新的策略包（PolicyBundle），或者手动触发一次离线精炼作业（Refine Job）。策略包发布一般伴随新规则生效，而离线精炼用于批量重算已有数据的分析结果。

Main Success Scenario:
(A) 策略发布:
1. **[提交新策略]** 治理负责人在“策略管理”界面上传或编辑一套PolicyBundle配置（JSON/YAML规则文件），填写版本描述并点击“发布”。系统进行基本校验（语法、依赖关系），通过则写入策略存储，生成新策略版本号 policy_version（例如 v2025.12.18）。新版本状态初始为“Deploying”。
2. **[灰度下发]** 如果选择灰度发布（分阶段），系统根据配置将策略逐步应用：例如先应用于10%无关紧要流量或特定用户组进行验证，然后逐步放量至100%。对于简单策略也可直接全量发布。系统记录 effective_at 时间（应为发布后几分钟内，各服务加载新策略的时间）。
3. **[影响监控]** 新策略加载后，系统各模块开始使用新规则（如Query Planner改用新规则调整搜索策略，Verifier增加新检查等）。系统监控关键指标变化（如查询成功率、有无异常错误）。如果在定义的观察期内出现严重异常（例如错误量激增），系统可自动**回滚**策略：即通知各模块恢复使用旧版本policy，并将当前版本状态标记为“RolledBack”。回滚也可由治理人员在界面一键触发。
4. **[确认生效]** 如果观察期无异常或策略效果达标，系统标记新策略版本为“Active”，旧版本归档为“History”。AuditLog记录策略发布完成，以及生效范围、耗时等。

(B) 离线精炼:
5. **[触发作业]** 管理员在“维护”界面点击“执行离线精炼”，选择相应范围（例如“针对全部存量文档重新计

算可信度”或“对知识图谱进行完整校验重建”）。系统创建一个 **RefineJob** 任务进入队列。
6. **[批处理执行]** Offline Refine 任务在低峰时段执行，对系统已有数据进行批量处理：例如遍历所有Document，重新跑一遍更新的模型计算可信度评分并更新字段；或重新构建图谱社区，清理孤立节点等。此过程会消耗资源，因此系统在后台按批次进行，并对每批进度日志记录。如果Refine任务定义了阶段（Stage1,2等），系统依次完成。
7. **[完成应用]** 离线精炼结束后，系统将**更新的结果**整合：如批量更新了Document的 trust_score 字段，或生成报表列出因精炼调整的内容列表。RefineJob 状态标记成功，产生报告供治理人员审阅（例如“X篇文档可信度发生变化，其中Y篇从Medium降为Low”）。这些更新的数据现在可供查询分析使用，使系统知识库“精炼”到最新标准。

Outputs:
- **PolicyBundle 版本**：新的策略版本记录（参见契约 **C-012**），包含 version号、规则内容摘要、发布人、发布时间、rollout模式等元数据。该版本对系统所有后续请求立即或按灰度生效，并可通过 DegradationStatus 或专门接口查询当前激活的策略版本。
- **Rollout Log**：策略发布过程中的关键事件日志，包括各阶段百分比切换时间、发现的异常以及是否回滚。供Ops和治理复盘策略发布影响。
- **RefineJob 报告**：离线精炼完成后输出摘要报告（可能作为日志文件或AuditLog条目）。内容示例：“重新计算可信度完成：10000篇文档中512篇可信度分数有调整（详细列表见附件）。” 治理人员可据此检查变化是否符合预期。
- **数据更新**：根据Refine类型不同，相应数据被批量修改。例如 Document.trust_score 字段全量更新，KnowledgeGraph节点属性更新等。这些更改通过正常渠道（契约Schemas）可见，并遵循一致性（有事务或批处理确保模块间同步）。

Failure Handling:
- 策略校验失败：如果提交的PolicyBundle格式或内容有误（如规则冲突、不支持的字段），系统拒绝发布，界面提示错误细节并返回 `1400` **InvalidPolicy**。策略不会更改。治理人员需修正配置重试。
- 发布异常：在策略灰度发布过程中，如策略服务未能及时加载新配置或部分节点应用失败，系统立即中止发布并 **自动回滚** 到旧版本。AuditLog记录“vX部署失败，已回滚至vY”。同时返回治理界面一个错误状态，提示“新策略发布未完成，系统已恢复旧版本”。错误码 `5502` **PolicyDeployFailed**。运维需要检查失败原因（可能某模块不支持新规则，需要修复）。
- 策略回滚：回滚可手动触发。如治理人员发现新策略效果不佳，点击“回滚至上版本”，系统通知各模块恢复旧policy。回滚操作成功后，前端显示回滚完成信息，新版本标记为RolledBack。若回滚过程中出现问题（例如旧版本文件缺失），系统将告警并在AuditLog记录**需要人工干预**，返回 `5503` **PolicyRollbackFailed**。这种情况极少，一般通过双重存储策略避免。
- Refine中断：离线精炼可能因为资源原因被中断（例如系统突然重启或降级）。RefineJob 有**幂等**设计：每处理一批记录都会写进度，下次重启可续跑。若中断，系统标记RefineJob状态为“Interrupted”，允许管理员手动重新resume。AuditLog记录中断点。对于一些不可续的Refine（少见），需要重新触发从头跑。
- 精炼影响在线性能: Offline Refine 默认在低优先级线程运行。但如过程中监控到线上性能受明显影响（可能批处理占用过多I/O），系统会自动 **pause/refine**（暂停精炼，降低Batch大小或等待低峰再继续）。这样不会有直接错误表现给用户，但延长完成时间。RefineJob 最终成功但带警告“因性能原因分多段完成”。Ops可据此优化批处理参数。
- 数据不一致：如果精炼过程中发生异常，导致部分数据更新成功、部分未更新（理想情况下批处理要么批次粒度原子，但若非原子），系统会在报告中强调“部分数据未更新，需要后续人工校验”。并标记RefineJob状态为“CompletedWithErrors”。治理人员可决定是否重跑。

---

6. Functional Requirements（功能性需求）

以下为系统功能需求列表（FR）。每条FR定义了系统**必须做**或**应该做**的具体功能行为，并给出了输入输出、优先级、依赖关系、与OKR的关联，以及可测试的验收标准（AC）。**Priority** 列采用MoSCoW优先级: Must=必须

实现，Should=应实现（有次优方案可接受）。**Trace to OKR** 列标明该需求支撑的目标和关键结果。FR表结构确保需求→目标的可追溯，并为测试提供明确标准。

FR ID	Title (功能标题)	Inputs (输入)	Outputs (输出)	Priority	Dependencies	Trac OKR
FR-001	Non-blocking Ingestion Pipeline （非阻塞的采集处理管道）	新内容采集事件（FastStream消息，含内容/元数据）	Document 对象（已解析内容）进入索引流程；处理状态更新	Must	基础消息系统可用；FR-017（降级策略）	O1 KR1 KR3

FR ID	Title (功能标题)	Inputs (输入)	Outputs (输出)	Priority	Dependencies	Trac OKR
FR-002	Unified Query DSL for 3-layer Search （统一三层检索DSL）	用户查询请求（查询字符串或结构化DSL请求）	统一解释的查询计划（包含全文、向量、图谱子查询）	Must	语法解析模块；CAP-KR-001（DSL定义）	O1 KR1 KR1

FR ID	Title (功能标题)	Inputs (输入)	Outputs (输出)	Priority	Dependencies	Trac OKR
FR-003	Content Parsing & Metadata Extraction （内容解析与元数据提取）	抓取的原始内容（HTML文本或文件流）	解析后的文档正文、标题、作者、时间等结构化字段	Must	针对不同类型的Parser库；CAPING-001	O1 KR1 KR1

FR ID	Title (功能标题)	Inputs (输入)	Outputs (输出)	Priority	Dependencies	Trac OKR
FR-004	Multi-Tenant Data Isolation （多租户数据隔离）	用户请求（含租户上下文）	仅包含该租户有权访问的数据的响应	Must	租户身份验证服务；RBAC策略	O2 规）

FR ID	Title (功能标题)	Inputs (输入)	Outputs (输出)	Priority	Dependencies	Trac OKR
FR-005	5-Min E2E Ingestion-to-Search SLO （新内容5分钟可检索）	ingestion.newDoc 事件流	可检索的新文档索引更新（Document.indexed=true）	Must	爬虫准实时抓取；FR-017（降级豁免）	O1 KR1 KR3

FR ID	Title (功能标题)	Inputs (输入)	Outputs (输出)	Priority	Dependencies	Trac OKR
FR-006	Relevant Results & Evidence Ranking （检索结果相关性与证据排序）	用户查询（文本或DSL）	排序后的检索结果列表（含相关度评分）	Must	索引构建完备（FR-005）；EvidenceFusion算法	O2 KR1 KR3

FR ID	Title (功能标题)	Inputs (输入)	Outputs (输出)	Priority	Dependencies	Trac OKR
FR-007	Answer & Summary Generation （基于证据的答案/摘要生成）	检索证据集合（文档片段列表）	精炼的答案或摘要文本	Must	GPT-Researcher Agent可用；CAP-RE-002	O2 KR1 KR2

FR ID	Title (功能标题)	Inputs (输入)	Outputs (输出)	Priority	Dependencies	Trac OKR
FR-008	Cross-Lingual Search & Bilingual Evidence （跨语言检索与双语证据）	用户跨语言查询（如韩文查询中文内容）	检索结果（含原文和译文证据双语呈现）	Must	翻译服务或模型；CLIR缓存	O3 K

FR ID	Title (功能标题)	Inputs (输入)	Outputs (输出)	Priority	Dependencies	Trac OKR
FR-009	Knowledge Graph & Timeline Updates （知识图谱与时间线更新）	新文档或变更事件（带时间戳、实体关系）	图谱新增或更新节点/边；Persona 快照序列更新	Must	图数据库可用；CAP-KR-003/005/006	O3 KR1 KR1

FR ID	Title (功能标题)	Inputs (输入)	Outputs (输出)	Priority	Dependencies	Trac OKR
FR-010	Domain Ontology Consistency （领域本体一致性应用）	分析输出（涉及实体或事件类型字段）	标准化的实体类型、事件类型标识（Ontology类型ID）	Must	东北亚本体定义提供；CAP-KR-007	O3 KR1 KR3

FR ID	Title (功能标题)	Inputs (输入)	Outputs (输出)	Priority	Dependencies	Trac OKR
FR-011	Multi-Language Output & Localization （多语种界面及报告输出）	用户界面文本、报告模板（默认中文）	不同语言版本的界面显示或导出报告	Should	语言资源文件；翻译检查流程	O3 K

FR ID	Title (功能标题)	Inputs (输入)	Outputs (输出)	Priority	Dependencies	Trac OKR
FR-012	Real-Time Persona Profile Update （人物画像实时更新）	Persona 相关的新数据（如提及该人的文档或社交帖）	更新的 Persona 画像属性、指标，以及触发的异动检测	Must	FR-009 图谱更新；CAP-KR-006	O4 KR1 KR2

FR ID	Title (功能标题)	Inputs (输入)	Outputs (输出)	Priority	Dependencies	Trac OKR
FR-013	Policy Bundle Versioning & Injection （策略包版本管理与注入）	策略包配置变更（新规则/参数集）	策略影响即时生效（检索/分析行为变化），可查询版本状态	Must	策略管理服务；CAP-TG-003	O2 KR3 KR2

FR ID	Title (功能标题)	Inputs (输入)	Outputs (输出)	Priority	Dependencies	Trac OKR
FR-014	Evidence Traceability Requirement （证据链强制追溯要求）	系统输出的分析结论/建议（Answer/Insight/Card 等）	附加的 evidence_list 字段（至少包含doc_id和摘录片段）	Must	紧耦合于各输出对象结构；FR-006/007	O2 KR1 KR2

FR ID	Title (功能标题)	Inputs (输入)	Outputs (输出)	Priority	Dependencies	Trac OKR
FR-015	Credibility Scoring & Evolution （内容可信度评分及演化）	Document 内容及上下文（来源、时间等）	credibility_score 分值及分解构成（写入Document/Persona等）	Must	信度模型服务；CAP-TG-002	O4 K

FR ID	Title (功能标题)	Inputs (输入)	Outputs (输出)	Priority	Dependencies	Trac OKR
FR-016	Adversarial Attack Detection & Alerting （对抗攻击检测与告警）	文档内容特征、新增内容分布（流量模式）	AdversarialAlert 告警事件（含等级、原因、建议措施）	Must	攻击检测规则/模型；CAP-TG-001	O4 K

FR ID	Title (功能标题)	Inputs (输入)	Outputs (输出)	Priority	Dependencies	Trac OKR
FR-017	Multi-Level Degradation Strategy （多级降级策略）	系统运行状态监测指标（QPS、延迟、队列长度等）	不同降级级别下调整的功能开关状态	Must	Metrics/Alert模块；配置的阈值	O1 KR3 KR4

FR ID	Title (功能标题)	Inputs (输入)	Outputs (输出)	Priority	Dependencies	Trac OKR
FR-018	Anomaly Alerts for Narrative Changes （叙事变化异常告警）	Persona/主题相关的时间序列数据（内容情感、频率）	告警事件（叙事突变类型），以及衍生的RecommendationCard	Should	PersonaSnapshot序列；FR-016告警	O4 K

7. Non-Functional Requirements（非功能性需求）

以下列出系统主要的非功能需求（NFR），包括性能、可靠性、安全、可维护性等方面要求。每条NFR具有全局唯一的标识（Rank），并用 Must/Should 标明优先级。表中 **Target** 为定量目标值，**SLO** 定义统计窗口和达标率，**Measurement** 描述如何测量，**Alert Threshold** 为相应告警触发门槛。这些NFR确保系统质量属性可测且可审计。

Rank	Requirement (可度量需求)	Target	SLO (达标率/周期)	Measurement (测量方法)	Alert Threshold	Priority
Must-01	**Query Latency** – 用户查询端到端延迟应足够低。 说明: 99%查询延迟 (P99) ≤ 800ms。	P99 ≤ 800ms	≥99% 请求满足; 月度评估	收集每次查询总耗时 (MTR-002)，按日计算P99，月末评估合规性	P99 > 800ms 连续3天触发告警	Must
Must-02	**Ingestion Pipeline Latency** – 新内容从接收至可检索延迟需满足5分钟目标。	P95 ≤ 5 min	≥95% 内容满足; 月度评估	记录 ingestion.received_at 与 index.search_ready_at 差 (MTR-001)，按周计算P95	P95 > 5min 任意周触发告警	Must
Must-03	**Query Success Rate** – 查询请求成功率应非常高（内部错误极少）。	≥ 99.5% 成功	每月99.5%+ (不含用户错误)	统计查询总次数与系统错误次数 (MTR-004)，排除4xx用户错误后的成功率	当日成功率 < 99% 立即告警	Must
Must-04	**Query Throughput Capacity** – 系统支撑的稳定查询吞吐。 说明: 单集群≥100 QPS。	≥ 100 QPS	在生产配置下，可持续支撑; 阶段验收	使用压力测试模拟持续负载，测量稳定无错误的最大QPS (MTR-003)	峰值QPS接近100时告警, 需评估扩容	Must
Must-05	**Ingestion Volume Capacity** – 日采集内容容量支持预期规模。 当前假设: ≥ 10k 新文档/日。	≥ 10k docs/day	在典型文档大小下持续支持	模拟10k篇/日 7天运行，无累积延迟；监控每日入库数量 (MTR-005)	当日入库量 < 80% 预期或处理积压触发告警	Must
Must-06	**Multi-Store Consistency** – 文档、向量、图谱数据最终一致性。 要求: 任一文档的数据副本不出现永久不一致。	校验错误率 < 0.1%	每周一致性扫描, 100%自动修复	每周跑一致性校验脚本（Doc vs Vector vs Graph），计算不一致记录比例	单次扫描发现 >0.5%不一致告警	Must

Rank	Requirement (可度量需求)	Target	SLO (达标率/周期)	Measurement (测量方法)	Alert Threshold	Priority
Must-07	**Authentication & Session Security** – 用户登录和会话管理必须安全。 包括: MFA支持，设备绑定，空闲超时。	MFA 可用, Idle ≤30min, Max 并发=3	100% 安全策略启用	检查配置：开启MFA，记录设备fingerprint，模拟Idle30min被登出，多端>3拒绝登录	检测到未启用MFA或异常登录事件立即告警	Must
Must-08	**Authorization & Data Isolation** – 强制租户/项目级访问控制，无跨界数据泄露。	0 未授权数据访问	100% 请求经ACL校验	所有查询结果附带tenant_id标签校验；定期运行越权测试用例，无一成功	任何一次发现越权访问即告警	Must
Must-09	**Rate Limiting & Anti-bruteforce** – 接口滥用防护。 例如: API调用和登录尝试速率限制。	登录失败 < 5次/5min 锁定, 各API有QPS阈值	实时生效, 策略可调	配置Nginx/API Gateway限流策略并日志监控；模拟>5次连续失败，账号被锁	任一用户/IP 连续失败阈值超过即告警	Must
Must-10	**Transport Encryption** – 数据传输需加密。 要求: 所有客户端–服务、服务–服务通讯启用TLS或等效手段。	100% 流量加密	持续 – 所有环境	检查网络配置：前端HTTPS强制，内部gRPC启用TLS；定期使用安全扫描工具验证无明文接口	任何扫描发现未加密通道立即告警	Must
Must-11	**Audit Logging & Non-repudiation** – 关键操作全记录且日志防篡改。	100% 关键操作记录	日志完整率100%, 保留≥180天	验证AuditLog Schema覆盖用户登录、数据导出、策略变更等操作；日志存储采用Append-only或签名校验	核心审计日志缺失或修改检测到立即告警	Must
Must-12	**No Sensitive Data in Logs** – 日志不应记录敏感信息明文（密码/令牌/PII）。	0 敏感明文	每月抽查, 发现即整改	定期脚本扫描日志关键字（“password=”，16位token模式等），人工复核怀疑项	发现敏感信息（如token串）触发安全告警	Must
Must-13	**Distributed Trace Coverage** – 核心业务流程均有分布式追踪。	≥ 95% 关键请求有完整trace	持续监控, 月评估	检查TraceSpan覆盖：随机抽取100次查询/ingest请求，trace包含预定义核心span序列；统计丢失率	若关键流程trace缺失>5%则告警	Must

Rank	Requirement (可度量需求)	Target	SLO (达标率/周期)	Measurement (测量方法)	Alert Threshold	Priority
Must-14	**Monitoring & Alerts** – 关键指标均有监控告警。 要求: 所有SLO指标配置告警规则。	100% SLO 有告警	持续 – 平均响应5min内	定义监控规则集覆盖NFR表中所有阈值；验证每条规则通过模拟场景可触发（如临时调参数）	任一关键指标缺少告警配置即运维警示	Must
Must-15	**Disaster Recovery (DR)** – 灾难恢复能力。 目标: RPO ≤ 1小时，RTO ≤ 4小时。	RPO ≤ 1h, RTO ≤ 4h	每季度演练, 100%达标	定期切断主数据库模拟灾难，启动从备份恢复流程，测量最新数据丢失时间和恢复服务用时	演练结果不达标或超出阈值需告警	Must
Must-16	**Supply Chain Security** – 软件供应链安全措施就绪。 包括: SBOM、签名镜像、CI漏洞扫描闸。	SBOM 100%组件, CI无高危漏洞	每版本发布检查	CI过程中生成SBOM并验证，无未许可第三方；CI集成SAST/DAST扫描，高危0容忍；镜像签名在部署前验证	CI出现高危漏洞或签名验证失败立即阻断	Must
Should-01	**Cost Efficiency & Cold Data Ratio** – 系统成本可控，冷查询占比较低。	冷查询 ≤ 5%	每月评估, 策略可调	统计查询中标记为访问冷存储的数据比例(MTR-015)；监控存储增长与预算对比	冷查询 >8%或成本超预算阈值告警	Should
Should-02	**Mobile Performance** – 移动端访问体验良好。 目标: 典型移动设备4G网络下首屏加载 ≤ 5s。	首屏 ≤ 5s (4G)	P90 ≤ 5s, 月度抽测	使用模拟移动设备脚本每周访问主页，测量TTFB和首屏渲染时间，统计P90	P90 > 5s 持续2周告警	Should
Should-03	**Contract Compliance & Backward Compatibility** – 模块接口契约遵守和兼容演进。	0 接口违约/无文档变更	持续检查, 阶段评审	CI自动检查接口定义和实现一致性；所有契约变更需提供版本升级策略，老版Deprecation不少于1版本周期	发现未宣告的接口变化即告警	Should

(注: Priority列Must/Should仅分类，不代表排序；Rank序号全局唯一且Must类整体优先于Should类。)

8. Data Governance（数据治理）

系统根据数据类型制定保留与清理策略，保障数据生命周期管理合规、高效。下表列出了主要**数据类型**在不同存储层级（Tier）的保留期限、删除SLA、恢复策略等。除特殊说明外，删除动作均会写入审计日志以备合规审查，且多租户场景下各租户的数据按租户隔离管理。

Data Type (数据类型)	Tier (存储层级)	Retention Period (保留期限)	Delete SLA (删除执行时间)	Restore Policy (恢复策略)	Audit Fields & Logging	Tenant Scope
Raw Crawl Page 抓取到的原始页面内容（HTML、JSON等临时文件）	Hot (缓存)	7 天（解析后即为冗余，仅短期留存用于纠错）	到期+1天内自动删除	不恢复（删除不可逆）；异常情况可从源重新抓取	AuditLog记录批量删除概要（删除数量、批次时间）	Per Tenant (按租户隔离)
Parsed Document 解析后的文档正文和元数据（主数据存储）	Hot	90 天作为“热数据”可高速检索	定期批处理：到期后24小时内软删除	Warm存储保留副本，可按需从Warm层恢复至Hot（如用户访问触发） ；超Retention后不恢复	Document 字段含 `deleted_at`；删除操作AuditLog逐条记录doc_id	Per Tenant
Parsed Document (Warm) 文档降级存储（降低访问频率）	Warm (低成本存储)	2 年（热转温，降低查询性能但节约成本）	T+2年翌日自动删除	Cold Archive仍保存摘要，可手工请求从Archive恢复到Warm；超期不恢复	删除作业Audit记录影响文档数、租户ID	Per Tenant
Document Archive 文档存档（冷存储，仅概要索引）	Cold Archive	5 年（# Requirements Spec (RS) v3.1 – QuantWin / 智能体研究分析系统				

1. Overview（概述）

1.1 Problem Statement（问题陈述）

在当今情报分析环境中，分析师需要从海量开放源（OSINT）数据中快速提炼出可行动的洞察。这一过程面临诸多挑战：

- **数据分散且多样**：信息来源多样（新闻、社交媒体、博客等），语言跨越中英韩日等，格式包括文本、图像、视频等，难以统一处理。

- **时效性要求高**：重大事件信息需要在几分钟内获取并分析，以便决策者及时响应；系统必须保证“采集至可用”延迟极低（级别达到分钟级）。
- **可信性和溯源**：在复杂的信息环境下存在虚假或恶意操纵内容（对抗性投毒）。分析结论必须提供证据链并给出可信度评估，方便审核与追溯来源。
- **多租户与安全**：系统将服务多个独立团队/租户，每个租户数据隔离，需满足严苛的安全与合规要求（访问控制、审计、数据保留/删除等）。
- **资源受限**：部署在私有云环境，硬件资源有限且负载波动。系统需要具备弹性伸缩和分级降级能力，确保在高负载或部分组件故障时核心功能仍可用。

QuantWin 智能体研究分析系统旨在解决上述问题，提供一个从数据采集到分析产出的一站式平台。通过引入智能编排代理（GPT-Researcher）和三层检索体系（全文搜索+向量语义+知识图谱），本系统将实现“5分钟内情报生产闭环”，并输出结构化、可解释且可审计的分析结论，供决策者直接采用。

1.2 Objectives & Key Results（目标与关键结果, OKR）

- **O1：实现“5分钟内可检索”的情报生产闭环**（Ingest → Index → Retrieve）
- **KR1**：新内容从“采集完成”到“可被检索（Searchable）”的端到端延迟 **P95 ≤ 5 分钟**（内部SLO）。
- **KR2**：用户查询端到端延迟 **P99 ≤ 800ms**（包括检索/融合/基础生成，但不包括长报告导出）。
- **KR3**：系统支持在线查询吞吐量 **≥ 100 QPS**，请求成功率 **≥ 99.5%**。

- **KR4**：在资源紧张或部分模块异常时，系统可按 **L0-L3** 等级自动降级，保障核心检索和证据链输出仍然可用（已有完整降级矩阵定义）。

- **O2：让研究产出“证据化、结构化、可审计”**，支持业务决策

- **KR1**：所有面向用户的关键结论（**Answer/Insight/Recommendation**）必须附带 **evidence_list（证据列表）**，每条证据包含来源文档ID及片段引用，由标准的 RecommendationCard 结构承载。
- **KR2**：所有“建议类输出”统一以 **RecommendationCard** 形式呈现，至少包含：risk_level（高/中/低）、summary（摘要结论）、evidence_list（证据条目），以及可选的 insight（深入见解）等字段。
- **KR3**：证据融合调用统一的 **EvidenceFusion API**，默认融合 Top-N 证据（N 的默认值通过策略配置），并记录采用的策略名称（used_policy）和证据评分结果，便于审计和复盘。

- **KR4**（讨论项）：导出的审计报告（PDF）中，是否要求**每条关键结论都可回溯到全文检索证据**（Full-text Verify）？（当前假设：对风险等级为 High 的卡片执行全文验证，并在报告中附上证据附件索引，详见数据治理策略）。

- **O3：保障东北亚领域的一致性语义和跨语言可用性**

- **KR1**：构建**东北亚领域本体（Ontology）**，统一实体与事件类型规范。所有模块输出使用统一的实体/事件类别名称，避免歧义。
- **KR2**：支持跨语言检索（**CLIR**）：提供查询自动翻译缓存及双语证据展示。额外翻译处理的延迟 **目标 ≤ 500ms**；翻译缓存命中率目标值将设定以减少重复翻译延迟（例如目标 ≥ 80%）。

- **KR3**：**支持至少 2 种语言**（中文+英文）在第一阶段全面可用，界面及输出可双语展示；在第二阶段扩展支持韩语、日语，实现 **4 种语言** 的多语言功能。

- **O4：在复杂信息环境下维持“可信度演化 + 对抗攻击防御”的稳健性**

- **KR1**：实现多因素的内容可信度评分机制，并支持 **多轮演化**（iterative refinement）以提供可解释的可信度构成（例如时间衰减、社交网络传播、域名可信度等分项），输出“为何可信/不可信”的依据。

- **KR2**：实现对抗性投毒内容检测及告警机制。**误报率**（False Positive Rate）初始控制在 **< 5%**（低风险告警级别），允许在早期阶段宁愿漏报少量可疑内容也避免大量误报扰民。系统以 Low/Medium/High 分级产生告警，并在后续运营中根据标注数据逐步校准阈值。

1.3 Success Metrics（成功指标）

下表汇总了主要的成功指标及其目标值、计算口径和评估周期。这些指标均与上述 KR 一一对应，并将用于验收系统是否达到目标要求：

Metric 名称	定义与范围	评估周期	目标值
内容可检索延迟（P95） New Content Indexing Latency	新采集内容从进入系统（`ingestion.received_at`）到索引完成可检索（`index.search_ready_at`）的端到端延迟，统计95分位数。范围涵盖正常运行时所有内容管道，不含手动暂停的情况。	日/周（滚动窗口）	**⩽ 5 分钟**（95% 内容）
查询端到端延迟（P99） Query Latency	用户查询请求从收到到完整响应的延迟，统计99分位数。包括检索、证据融合、基础分析（不含长报告异步部分）。	日（每昼夜）	**⩽ 800 毫秒**
查询吞吐率 Query Throughput (QPS)	系统每秒可处理的查询请求数。在100并发用户压测下测得稳态平均值。	压测/峰值期间	**⩾ 100 QPS**
请求成功率 Query Success Rate	有效用户请求得到成功响应的比例（非错误响应数量占比）。排除无效请求（权限不足、参数错误等）。	连续监控	**⩾ 99.5%**
分级降级覆盖率 Degradation Coverage	压力场景下自动降级策略覆盖核心功能的程度。定义若进入 L1/L2/L3 降级后，核心查询和证据输出仍可用的请求占比。	故障演练/实时监控	**100%**（核心功能不中断）
证据链附带率 Evidence Inclusion Rate	面向用户的分析结论中附带证据列表的比例。例如输出的Answer/Insight/Recommendation中包含evidence_list 的占比。	持续监控/抽样	**100%**（必须全覆盖）
Ontology 使用一致性 Ontology Usage	实体/事件在输出中使用标准Ontology类型的覆盖率。统计输出内容中的实体引用有规范类型标注的比例。	抽样检查	**100%**（全采用统一类型）
翻译额外耗时 Translation Overhead	跨语言查询因翻译产生的平均额外延迟（Cache Miss情形）。	周（月）	**⩽ 500 毫秒**
翻译缓存命中率 Translation Cache Hit Ratio	翻译缓存命中次数占总翻译请求次数的比例。目标在常用查询场景下尽量提高重复利用率。	月	**⩾ 80%**
支持语言数量 Supported Languages	系统正式支持的语种数量（UI界面和分析功能）。第一阶段至少含中英，第二阶段扩展韩日。	里程碑检查	**2 种**（初版） **4 种**（第二阶段）

Metric 名称	定义与范围	评估周期	目标值
可信度评分可解释覆盖率 Trust Score Explanation	产生高风险结论时提供可解释可信度分解的比例。例如 High 风险级别的 RecommendationCard 是否均附带 risk_factors。	抽样审核	**100%**（高风险必须解释）
对抗攻击告警精度 Adversarial Alert Precision	对抗投毒检测告警的准确率。定义为实际确认的有问题内容占系统告警的比例（低级别告警除外）。初期偏重精确率以减少误报。	月/季度分析	**⩾ 95%**（高准确率，误报 <5%）
冷查询占比 Cold Query Percentage	查询请求中，命中冷数据（归档长期数据）的比例。通过查询日志分析判断（如超过设定时间范围需访问冷存储的请求数/总请求数）。	月	**⩽ 5%**
成本控制策略 Cost Strategy Adherence	成本控制策略的执行情况。例如在资源紧张时降级策略是否按预期触发、GPU/CPU使用率是否达标等。以相关Metrics告警触发计数衡量。	持续监控	**满足**预定义策略（无未触发/过度触发）

注：以上指标均以生产环境为基准。各指标采集方法与告警阈值定义详见第12章【指标与可观测性】。默认配置适用于典型负载场景，实际部署可根据租户规模和硬件环境进行参数化调整，并需通过变更审核与审计。

2. Stakeholders & Personas（干系人及角色）

- **Persona-AN（分析师，Analyst）**：主要使用者，发起研究任务，快速获取**可追溯证据链**支持的结论。关注能够回溯至少8年历史，支持跨语言检索，一键生成报告。典型权限：创建查询/研究任务，生成卡片和报告，订阅主题。
- **Persona-DM（决策者，Decision Maker）**：主要阅读者，只关注“结论 + 风险评级 + 建议动作”，并可查看证据详情，要求输出稳定可信、可审计。典型权限：只读访问，订阅和下载报告，不可修改策略。
- **Persona-AD（管理员，Admin）**：系统管理者，配置数据源和采集计划、策略包（PolicyBundle）、资源预算与限速；管理租户、用户和权限；查看中控台与系统告警。典型权限：全局配置和治理权限。
- **Persona-GOV（治理官，Governance/Compliance）**：负责策略治理与合规，关注策略版本管理、审计追踪和对抗投毒响应流程；审核高风险输出。典型权限：审批策略变更，查看审计日志，隔离/解除内容。
- **Persona-SRE（运维工程师，Platform Ops）**：保障系统在私有云中的SLO达标（5分钟、P99 800ms等），维护可观测性和发布门禁。典型权限：系统监控，配置基础设施参数，处理紧急降级。
- **Persona-DEV（集成开发者，Integrator）**：根据插件合约扩展数据源，或根据分析方法库接口增加算法模块；对接前端应用或定制报告模板。典型权限：受限开发权限，不能访问非授权数据。

3. Scope & Non-Goals（范围及非目标）

3.1 In-Scope（系统负责功能）

- **OSINT 数据采集编排**：集成 Prefect 进行采集任务调度与重试，利用 Crawl4AI 负责网页抓取，使用 FastStream 实现异步消息队列传递。支持 CrawlPlan 定义多源采集计划、速率限制和预算控制；支持 SourcePlugin 插件机制扩展数据源类型（沙箱隔离、白名单审批、配额管理）。
- **数据源治理**：实现采集去重策略（URL规范化+内容指纹去重）和幂等消费，确保相同内容不重复处理。提供 CrawlPlan 管理接口，支持计划的创建/修改（入口URL、深度、include/exclude规则、定时Cron、优先级、解析器类型）。支持采集任务的暂停/回放以及数据源配额监控。
- **知识检索**：实现**三层检索体系**，包含全文检索（document/keyword）、向量语义检索、知识图谱检索，统一通过 Query DSL 和 Query Planner 选择执行。保证文档-向量-图谱多存储数据的一致性写入

（最终一致并有校验机制）。支持知识图谱增量更新和社区摘要生成，实现 HiRAG（分层知识检索生成）增强的推理能力。提供时间切片检索和时间衰减函数用于时效性排序。实现 PersonaSnapshot 模型，定期更新人物/账号画像并检测异动。

- **推理与结论产出**：提供**证据融合（EvidenceFusion）** API，将多来源证据（向量相似、图谱关联、全文检索验证）融合，生成最终依据列表。实现通用分析方法库（如实体识别、关系提取、自动摘要、矛盾检测、事件聚类等）的标准接口。将分析结果结构化呈现为 **RecommendationCard**，包含风险标注和简要结论。支持报告导出（PDF），应用预定义模板，附带水印和审计ID。
- **可信度与安全**：实现内容可信度评分演化机制（基于时间、网络传播、域信誉等维度）。提供对抗性攻击检测输出（Adversarial Alert），对可疑投毒内容进行分级告警和措施建议。实现检索策略治理（RMS/PolicyBundle），在 Query Planner、Verifier、工具路由等环节注入治理规则。加强插件执行隔离和资源预算，防止第三方插件影响主系统。
- **平台与运维**：支持私有云 Kubernetes 多节点部署，利用弹性伸缩策略确保性能（可针对CPU/GPU节点分类伸缩）。实现多阶段数据迁移方案（本地->云端），保证数据一致性。提供统一可观测性方案（OpenTelemetry 分布式追踪，预构建 Dashboard 和告警规则）。实现容量模型驱动的自动降级触发（依据队列长度、响应延迟等指标）。加强供应链安全（提供软件物料清单SBOM、镜像签名、依赖版本锁定和CI发布闸门）。
- **产品交付能力**：采用终端无关的Web界面（H5/PWA 优先）以支持PC和移动浏览；实现多因素认证（MFA）和设备绑定，保障终端访问安全。内置多语言界面支持，提供双语内容展示（原文+翻译）。提供**中控台（Control Tower）**用于系统治理：可视化展示数据源状态、调度进度、策略版本、可信度监控、成本统计、系统告警和审计日志。

3.2 Out-of-Scope（非目标事项）

- **GPT-Researcher 长期爬虫/存储**：本系统不承担长期定时爬虫任务的全量数据存储，只负责针对具体研究任务的“即时研究编排+工具调用”。持续海量数据存储与管理由外部系统承担。
- **Prefect 细粒度数据处理**：Prefect 仅用于调度和重试，不负责具体消息传递或数据解析；业务数据解析和模型推理由本系统内部模块完成。
- **FastStream 业务逻辑**：FastStream 仅作为消息队列，不处理任何业务逻辑、数据解析或模型推理；其作用限于提供Topic/Queue机制和异步解耦。
- **Crawl4AI 之外的数据推理**：Crawl4AI 只负责基础抓取和初步解析，不进行复杂知识推理、可信度判断或报告生成，这些由本系统完成。
- **移动端原生 App 开发**：当前以自适应网页(H5/PWA)为主要终端形式，不专门开发 iOS/Android 原生应用（原生App作为可选项，非P0需求）。
- **付费/封闭平台数据采集**：本系统不保证绕过版权或身份验证来采集付费或封闭平台的数据。最小假设：系统仅处理合法可访问的公开数据；对于封闭平台数据，需要租户业务方提供授权接口或数据，系统本身不直接采集未授权数据。

4. Glossary（术语表）

5分钟可检索（5-min Searchable） – 新内容自采集接收（`ingestion.received_at`）到建立索引可被检索（`index.search_ready_at`）的端到端时长要求。本规范中5分钟指P95≤5min的内部目标（SLO），非对外承诺的SLA。

Analysis-ready – 新内容完成全文索引后，进一步经过嵌入向量生成、知识图谱关联、策略评估等分析处理，达到可用于高级分析（如可信度计算、推理生成）的状态。用 `analysis.ready_at` 时间戳标识内容进入analysis-ready状态。

HiRAG – Hierarchical Retrieval-Augmented Generation，分层次知识检索增强生成。通过多层级知识表示（如实体→事件→主题）改进信息检索与生成的相关性和可解释性。

OSINT – Open Source Intelligence，开放来源情报。指从公开可获得的数据（网络新闻、社交媒体等）中收集、分析情报信息的过程和所用数据。

Ontology（本体） – 在本系统指东北亚领域的实体类型/事件类型体系，用于规范人物、组织、事件等分类标准，保证不同模块对相同概念使用一致的类型命名。

Persona（人物角色） – 这里指知识图谱中的人物节点或社交账号画像，用于跟踪其属性变化、社会关系和行为模式（PersonaSnapshot）。也用于指代系统用户角色（Stakeholder），视上下文而定。

PersonaSnapshot – 人物/账号某一时间点的属性和状态快照，包括职务、立场、粉丝数等关键属性以及可信度、舆情等指标。快照序列存储在时序库以支持异动检测。

PolicyBundle – 一组检索/分析策略规则的集合包，可发布到系统以影响查询规划、内容过滤、证据融合等行为。包含版本号和生效时间，可进行回滚。由治理人员管理发布。

Research Orchestrator – 指 GPT-Researcher 智能代理，在复杂查询任务中生成ResearchPlan并调用工具链执行的模块。负责根据用户问题自动选择检索手段、调用分析方法并汇总结果验证。

RMS – Retrieval Management Service，检索管理服务，用于**检索策略治理**（如在查询规划中注入限制规则）。可通过PolicyBundle向RMS下发新的检索/过滤策略，在Planner、Verifier等环节生效。

SBOM – Software Bill of Materials，软件物料清单。列出系统所包含的所有第三方组件及其版本，用于供应链安全审查。

SLA / SLO / SLI – 服务等级协议/目标/指标。SLA指对外正式承诺的最低服务水平（违反可能有惩罚）；SLO指内部设定的运营目标值（通常严格于SLA，无惩罚性）；SLI指具体测量指标值（用于计算SLO/SLA达成情况）。注：本规范中如无特殊说明，提到“5分钟、800ms”等均为SLO指标而非外部SLA。

三层检索（Three-layer Retrieval） – 指集成**全文检索**（关键字/布尔搜索）、**向量检索**（语义相似度搜索）和**图谱检索**（基于知识图谱的关系推理查询）的综合检索体系。Query Planner 将根据查询特征决定调用哪一层或组合结果，EvidenceFusion 融合各层证据统一排序。

冷/热数据（Cold/Hot Data） – 热数据指近期、高频访问的数据（如最近几月的文档）存储在高速存储和索引中以保证查询性能；冷数据指较久远、访问频度低的数据（如多年历史归档）存储在较慢介质或压缩索引中。系统会对冷数据查询采取不同策略，允许较长响应时间，并将冷查询量控制在约5%以内。

降级级别 L0-L3 – 系统资源不足或异常时的自动降级策略等级。定义：L0=正常（无降级）；L1=关闭非关键功能（如停止更新某些统计）；L2=仅保留核心检索和基本分析，暂停次要任务；L3=进入仅服务降级（暂停新的数据摄取和深度分析，仅提供已有数据检索）。详见FR-017及降级矩阵。

Fulltext Verify（全文验证） – 指证据融合过程中，对生成的结论再次使用全文搜索验证其支持是否确凿的步骤。例如RecCard生成高风险结论时，会自动针对结论要点进行全文检索校验，并在报告中附上完整原文证明。

CLIR – Cross-Lingual Information Retrieval，跨语言检索。允许用户使用某一语言查询不同语言的数据来源，系统自动翻译查询和/或结果，实现多语言搜索。

OpenTelemetry（OTel） – 开放遥测协议，用于分布式系统的统一追踪和指标采集。本系统采用 OTel 标准埋点，贯穿用户请求到各微服务、数据库调用的trace span，方便集中分析性能瓶颈。

ArcticDB – 专用于时序数据和版本化数据存储的数据库方案，用于存储PersonaSnapshot序列、指标序列等需要按时间查询的数据。支持模式演进和Schema版本管理。

Quality Gate（质量闸） – 持续集成（CI）流程中的质量检查关口。具体指只有通过所有关键回归测试、静态检查和安全扫描的版本才能部署。包括依赖漏洞扫描、SBOM检查、性能回归验证等。

5. Use Cases（核心用例）

下面定义核心用户用例 (UC-001 ~ UC-008)，涵盖主要的用户交互流程。每个用例包含触发条件、主要步骤、输出结果，以及**异常处理/失败应对**（包括用户可见错误码、降级行为等）。

UC-001: 发起研究任务（Deep Research Orchestration）

Trigger：Persona-AN（分析师）提出新的研究课题或复杂查询（包含一个或多个实体、时间范围、地域等）。

Primary Steps:

1. **分析师提交研究请求**：用户通过UI输入研究主题或关键问题以及相关参数（如涉及的实体名称、时间窗口等），点击“开始研究”。
2. **系统生成研究计划**：GPT-Researcher 智能代理根据用户问题自动生成一个ResearchPlan，拆解出所需的信息类别和检索子任务。例如确定需要检索的事件、人物关联、历史趋势等，并选择相应工具（全文检索、图谱查询、问答等）。
3. **系统执行检索子任务**：系统并发调用三层检索模块：对关键字和实体进行全文检索、向量相似检索相关文档、图谱查询关联节点。Query Planner 根据Plan决策顺序，对每个子查询调用搜索引擎/向量库/图数据库，获取初步结果集合。
4. **系统调用分析方法**：针对检索到的结果，系统调用内置方法库进行分析处理，例如：提取主要事实（NER/关系抽取）、摘要总结多篇内容、检测证据间矛盾、评估可信度等。
5. **系统融合证据并生成结论**：EvidenceFusion模块对来自不同渠道的证据进行相关性评分和融合，剔除冗余和冲突。然后GPT-Researcher根据融合后的证据集撰写研究结论（Answer/Insight），附带对结论的解释说明。
6. **系统封装输出结果**：系统构建输出对象，包括主要结论（Answer/Insight文本）、支撑证据列表（Top-N EvidenceItem列表），以及在需要时生成 RecommendationCard（如果结论包含风险评级或行动建议）。
7. **系统返回结果给分析师**：分析师在前端界面收到结构化的研究结果：结论摘要、证据列表（可展开查看每条证据详情），以及（若有）推荐卡片。用户可以进一步查看证据原文、调整查询或将结论保存。

Output: - **ResearchAnswer**（研究结论） – 对用户问题的直接回答或分析摘要文本。 - **EvidenceList**（证据列表） – 支撑结论的证据条目数组，每条含证据来源文档ID、摘要片段等（结构见RecommendationCard.EvidenceItem）。 - **RecommendationCard**（推荐卡片，可选） – 若本次任务产出了具体建议或高风险警示，则提供包含 risk_level、summary、evidence_list 等字段的卡片（结构详见C-015）。 - （系统还提供 `trace_id` 用于关联本次请求的内部执行轨迹，方便审计和调试。）

Failure Handling: - 无结果情况：若检索未发现任何相关内容，系统返回空结果集，并给出提示信息（例如代码 **1200**，消息“暂无相关数据”）。分析师可尝试调整查询条件。 - 查询语法错误：如果用户输入的DSL查询存在语法错误或不支持的格式，系统立即返回错误（代码 **1101**，“查询语法错误”），提示用户修改【B-03】。该错误为用户可纠正，重试一般成功。 - 处理超时/部分失败：如果某些子任务（如复杂分析步骤）在预期时间内未完成，系统将在超时阈值（例如30秒）后返回部分结果而非整个失败。界面会标注分析不完整并提示稍后查看补充结果。内部记录错误码（如 **5101 AnalysisTimeout**）。对于超时的分析部分，系统后台继续处理，完成后可通知用户查看更新结果。 - 系统降级场景：当系统处于资源紧张的降级模式时，本用例将自动简化执行： - 在 **L1/L2 降级** 时：系统可能跳过耗时的深度分析步骤，仅返回基本检索结果和简单摘要。界面

提示“系统繁忙，已提供简化结果”。此情况下返回的 HTTP状态仍为200且有结果，但附带 degrade_level 信息（L1/L2）供前端展示提示。 - 在 **L3 降级** 时：系统可能拒绝新的深度研究请求以保障核心服务。用户将立即收到错误响应（代码 **5403 ServiceOverloaded**），提示“系统繁忙，暂时无法处理该研究任务”。此错误建议用户稍候重试。系统会将请求放入队列等待稍后处理，并在恢复后自动执行，或由用户手动重试。 - 权限不足：如果分析师对请求的某数据域没有权限（例如尝试访问未授权的项目数据），系统返回错误（代码 **1003 AccessDenied**），前端提示无权访问。 - 关键依赖不可用：执行过程中如果某个关键子系统不可用（例如向量检索服务宕机），系统自动记录降级。对于用户，此时可能只得到部分结果（例如纯全文检索部分），并伴随警告。若整个请求无法完成则返回通用错误（代码 **1300 DependentServiceError**）提示稍后再试。系统监控会在背景告警运维。

UC-002: 事件/人物的长期回溯分析（Historical Backtrace Timeline）

Trigger：Persona-AN（分析师）指定一个感兴趣的**人物或事件类型**以及**时间范围**，请求系统对其进行长期趋势回溯分析。例如：“跟踪某人物在过去5年的职位变化和重大事件”。

Primary Steps:

1. **分析师提交回溯请求**：用户在界面选择人物（或事件类型）以及起止时间范围（可按年/月），然后点击生成“时间线（Timeline）”。
2. **系统检索历史数据**：系统根据所选对象和时间窗口，查询内部存储的相关**PersonaSnapshot**序列或事件序列。检索包括：该人物在指定期间的所有状态变更记录，各年度/月份的关键指标（如影响力、舆情）变化，以及该对象关联的关键事件节点（从知识图谱中按时间过滤）。
3. **系统识别关键变点**：对时间序列数据应用**异动检测**算法，找出显著变化点。例如人物职位变动、关注度突增或骤降的时间点。对于事件序列，则识别峰值或异常时期（如某话题讨论突然增加）。
4. **系统生成时间线**：根据检索和分析结果，系统编排一个按时间顺序的事件列表。每个时间节点包括日期、对应的变化描述（例如“2019年6月：晋升为部长”“2021年1月：卷入重大事件X”）、以及支撑该变化的证据条目（新闻报道链接等）。
5. **系统（可选）输出洞察**：如果检测到因果联系或明显模式（例如某事件导致后续持续影响），系统在时间线中加入简短**洞察**提示。例如标注“此段时期内社交媒体关注度持续下跌，可能与政策Y实施有关”。
6. **系统返回时间线结果**：分析师在前端查看可视化的时间线。节点按时间排序，展开可见详细描述和证据来源。用户可筛选节点类型（例如只看职位变更）或调整时间范围。

Output: - **Timeline 列表** – 由一系列按时间排序的事件条目构成。每个条目包含 timestamp（时间点）、description（文字描述变化或事件）、以及 evidence_list（支撑此条目的证据文档列表，例如新闻标题及ID）。 - **关键变点标识** – 对于算法判定的显著异动节点，条目将标记特殊标识（例如⚠符号）以提示用户这是重要变化。 - **（可选）Insight 提示** – 若系统检测到长周期趋势或异常模式，会在时间线末尾或相关处添加 Insight 注释，例如一段总结性的说明。

Failure Handling: - 无相关数据：如果指定的人物/事件在给定时间段内没有任何数据，系统返回空时间线，并提示“所选对象在该时间范围无记录”（代码 **1200 NotFound**）。这不是错误，仅作为正常结果告知用户可能需更改查询条件。 - 时间范围过大：若用户请求的时间跨度过长（例如超过系统数据留存期限），系统可能将范围裁剪到可用数据范围，并在结果中注明。例如请求10年但系统只保留8年，则返回8年的时间线并警告部分数据缺失。如果时间过长导致结果节点过多，系统可能按粒度聚合（例如按年汇总）。无致命错误，但UI提示“时间范围过大，已部分汇总结果”。 - 查询超时：如果历史数据量极大导致处理超时，系统返回部分时间线（优先最近年份或显著事件），并附错误码 **5101 AnalysisTimeout** 指示分析未完全完成。用户可缩短时间范围重试。系统后台可能继续计算剩余部分并在稍后提供。 - 权限限制：如涉及跨租户数据（例如用户无权访问其他项目的历史数据），系统会过滤不可访问内容，仅显示授权范围内的时间线。若整个请求不被允许，则返回 **1003 AccessDenied** 错误。 - 降级模式：在L2级降级下，此用例可能跳过高耗时的因果分析，仅提供基本时间线；在L3下可能拒绝新的长周期回溯请求（返回 **5403 ServiceOverloaded**）。这些情况下的处理同UC-001中的降级策略：要么部分结果+提示，要么错误并建议稍后重试。

UC-003: 配置数据采集计划（CrawlPlan 配置）

Trigger：Persona-AD（管理员）需要新增或调整一个数据源的采集计划。例如添加对某新闻网站的爬取，或修改已有计划的频率。

Primary Steps:

1. **管理员提交计划配置**：通过管理控制台，Admin 填写 CrawlPlan 表单，包括数据源入口（URL列表或API端点）、抓取深度、包含/排除规则、调度频率（cron表达式）、优先级、解析器类型（如HTML解析或PDF解析）等。如果是更新已有计划，则选择计划ID并修改相应字段。
2. **系统验证输入**：系统对提交的计划配置进行校验，如：URL格式是否合法可访问，调度Cron表达式语法是否正确，解析器名称是否支持，是否存在重复的计划等。若发现错误或冲突，立即反馈给Admin要求修正（如URL不合法则提示错误，不保存计划）。
3. **系统保存计划**：验证通过后，系统将新的 CrawlPlan 保存到计划库（持久存储），赋予一个唯一的 **plan_id**。对于修改已有计划的情况，系统更新存储记录并记录版本变更（旧配置存历史以备审计）。
4. **调度器加载计划**：Prefect 调度模块检测到新的或更新的计划后（通常通过数据库触发或定时扫描），将该 CrawlPlan 加入调度队列。根据计划设定的 cron，调度器在下一个触发时间启动采集任务。
5. **执行采集任务**：在计划触发时，系统产生日志记录任务开始。FastStream 消息总线收到抓取任务（topic 如 `ingest.crawl.start`），Crawl4AI 按配置抓取源站点内容：遍历入口URL及符合规则的链接深度获取页面。
6. **处理抓取结果**：每当 Crawl4AI 抓取到新页面，立即通过FastStream发送 `crawledPage` 事件，包括页面内容和meta。系统 Ingestion 服务消费该事件并对页面进行解析（HTML转正文，提取标题、发布时间等）。解析得到的新文档触发 `newDoc` 事件进入后续管道 (详见UC-004)。
7. **反馈与监控**：Admin 可在控制台查看新计划的状态：如“Active/运行中”“上次运行时间/下次运行时间”“已抓取文档数”等。系统对每个计划维护运行日志（如最近一次运行是否成功、抓取到多少条、发生的错误）。如果出现持续错误（如目标站点无法连接），系统会在控制台标记告警提示 Admin 干预。

Output: - **CrawlPlan 配置确认** – 系统在UI上确认新计划已创建成功（展示 plan_id）或现有计划更新成功，并显示主要配置摘要。对于更新，还会标明版本变更已记录（以供审计）。 - **计划执行结果日志** – （后台可查）每次计划运行会产生运行日志条目，包括开始时间、结束时间、抓取到的新文档数量、发生的错误数等。这些日志供Admin通过控制台查看，以评估计划健康度。 - **新文档事件** – 新计划执行后，如有抓取到新的内容，则通过后续管道产出 Document 对象并进入搜索/分析（属UC-004范畴）。Admin 不直接看到Document数据输出，但可通过整体系统指标看到文档总量增加或在数据治理界面查询该源的数据统计。

Failure Handling: - 配置校验失败：如果提交的计划配置有错误，系统前端在保存之前即阻止并以高亮提示字段错误原因。如Cron表达式无效、URL格式错误、解析器名称未注册等。此类错误不产生错误码（未提交成功前），在UI表单直接提示。Admin 修正后可重新提交。 - 重复或冲突计划：如果新计划与已有计划在功能上重复（例如相同数据源URL和范围），系统检测到后将警告Admin可能重复。Admin可选择取消（避免双重抓取浪费）或强制添加。若强制添加，系统标记该计划冲突风险以供后续治理。 - 权限不足：如果非Admin用户尝试创建/修改 CrawlPlan，系统拒绝并记录安全审计。前端收到错误码 **1003 AccessDenied**。只有具备相应权限的Admin/GOV角色可执行此用例。 - 计划执行失败：计划保存成功后，后续执行阶段可能出现问题。例如目标网站无法访问或抓取超时。在这种情况下： - 系统调度器会在日志中标记本次运行失败，并自动按照既定重试策略（如指数退避重试3次）尝试。无须人工介入。 - 如果连续多次运行失败（例如连续3次调度都抓取失败），系统触发告警（在中控台和运维渠道），提示Admin检查数据源连通性或修改计划。错误原因（如网络超时、HTTP 50x）显示在计划详情中。 - 该计划的失败不会影响其他计划或核心查询服务。系统**不**会因为单个计划失败而整体降级，只会针对该源暂停或降低频率。除非失败原因影响全局（如数据库不可用），那属于全局故障处理（参考降级策略）。 - 计划停用/删除：Admin 可能取消某计划。例如数据源不再需要。Admin可在控制台将计划状态设为“Disabled”或删除计划。系统立即停止后续调度，并在数据治理策略下处理其已抓取数据（例如标记不再更新）。此不算失败，但系统需审计记录该操作（谁在何时停用了计划）。如果删除计划，需要遵循数据治理删除SLA（参见第8章）。 - 降级模式影响：在L3极端降级时，系统可能暂缓启动新的采

集任务以减轻负载。若该用例触发时系统正处L3，则保存计划仍然成功，但调度器可能延迟执行，控制台会标注“计划已保存，但系统繁忙，将延迟执行”。当降级解除后，计划自动恢复正常调度。

UC-004: 实时增量采集 → 5分钟可检索（5-min Pipeline）

Trigger：外部数据源出现**新内容**，系统接收到相应事件。典型场景：Crawl4AI 成功抓取到新网页，向FastStream发布 `crawledPage` 消息；或第三方数据通过API推送到系统的 Ingestion 接口。

Primary Steps:

1. **接收新内容事件**：系统的异步入口收到新内容通知。对于网页爬虫，FastStream Topic `ingest.crawledPage` 上出现消息，包括抓取到的页面正文、元数据（URL、发布时间等）。Ingestion微服务消费该消息。对于API推送的数据，也通过统一接口进入Ingestion。
2. **预处理与解析**：Ingestion服务对新内容进行预处理：根据数据类型选择解析器（HTML解析、JSON解析等）。提取文档标题、作者、发布时间、正文正文等字段。生成内部 **Document** 对象（初始状态：未索引，analysis_ready = false）。
3. **重复检测**：系统计算内容的 `content_hash` 或其它去重标识。在保存Document前，检查是否已有相同内容（同一租户范围内）已存在。若检测为完全重复，则：
4. 丢弃该Document，不进行后续索引；
5. 记录一次重复事件（用于统计和告警，如果某来源大量重复可能有问题）；
6. 不触发新文档pipeline（因为无新内容)。 如果不重复，则继续。
7. **存储并标记接收**：系统将新的 Document 对象持久化存储（Document库）。写入时赋值 `ingestion.received_at` 当前时间戳，状态标记为“已接收，待索引”。Document 获得唯一 `doc_id`。
8. **触发索引流程**：Document 存储成功后，系统发出 “文档待索引” 信号（例如FastStream发布 `ingest.newDoc` 事件，或者直接调用索引模块API）。搜索索引模块（全文索引、向量索引服务等）收到该通知，开始处理该Document：
9. 将文档文本编入全文搜索索引；
10. 计算文档的嵌入向量，将向量写入向量数据库；
11. 将文档涉及的实体/关系插入知识图谱，或标记相关节点待更新。
12. **索引完成（Searchable）**：当全文索引操作完成后，系统更新Document的 `index.search_ready_at` 时间戳，并将 `indexed` 状态置为true。此时，该文档对用户查询**可检索**了（即满足5分钟SLO的一部分）。系统会在后台继续分析处理，但如果有用户查询正好命中该文档关键词，将可以立即返回结果。
13. **策略与分析处理**：在索引完成后，系统异步执行进一步的分析处理：
14. 运行策略引擎（RMS/PolicyBundle）对该文档内容进行评估，如是否敏感/需过滤或特殊处理；
15. 计算文档的初始可信度评分；
16. 如果文档包含特定情报（如涉及重要人物或事件），触发知识图谱更新（建立文档与相关实体/事件节点的关联边）；
17. 生成Document对应的向量Embedding（如尚未在索引阶段生成，则此时计算，通常在索引阶段已经做了）；
18. （可选）对文档内容运行摘要、分类标签提取等分析，以便后续检索使用。
19. **分析完成（Analysis-ready）**：当上述分析步骤全部完成后，系统更新Document的 `analysis.ready_at` 时间戳，并标记 `analysis_ready = true`。此状态表明该文档的所有派生数据（向量、图谱节点、摘要等）均已准备完毕，可用于高级分析（如问答生成、关联推荐等）。
20. **通知订阅/监控**：如果有订阅此类内容的模块（如Persona监控模块订阅了相关人物新内容），系统发送通知事件（如 `analysis.newDocReady`），触发相应处理（例如更新Persona快照，参见UC-005）。此外，系统监控Pipeline各阶段耗时，如超过预警阈值将告警。

Output: - （对终端用户）**可检索文档** – 从本用例出发并无直接用户界面输出。然而，一旦Document进入Searchable状态，用户随后的搜索用例即可检索到该内容。对用户而言，新内容通常在采集后几分钟内就能搜索到，这正是5-min Pipeline目标。 - （内部）**Document对象更新** – Document契约数据（见 C-001）得到更

新填充了索引和分析时间戳等字段，供系统后续查询和展示使用。例如在数据治理界面，可以看到文档的状态已从“Pending”变为“Indexed/Analysis-ready”。 - （内部）**分析结果派生** – 此新文档关联的嵌入向量已存储、知识图谱实体边已添加、可信度评分已计算并可在审计日志或监控指标中查见。这些派生结果没有单独的输出界面，但会融入整体系统功能（如查询时影响排序，或在Persona档案中反映该文档贡献的变化）。

Failure Handling: - 解析失败：如果抓取的原始内容无法正确解析出Document（例如HTML结构异常或格式不支持），系统会跳过索引并记录错误。Document记录可能仍存储但标记 `processing_error_code` （例如 **2101 ParseError**），并 `indexed=false` 。该错误不会影响其他文档处理。系统将此情况计入监控指标（解析成功率）并可能告警运维。如果解析失败的内容对分析师很重要，可通过离线手段补录。 - 去重冲突：如果发现content_hash重复，系统判定为重复文档而未生成新Document。这不视为错误，但对于统计和资源消耗有影响。系统在日志中记录重复事件并更新相关指标（如某来源重复率）。Admin可定期查看哪些来源产生大量重复，以调整采集策略。 - 索引失败：如果全文索引或向量存储在处理该Document时发生错误（例如索引服务宕机或出现异常），系统将重试（根据实现可能重试X次）。如最终失败： - Document 将被标记 `indexed=false` 且 `processing_error_code` 填写相应错误（如 **2201 IndexFail**）。该文档不会出现在检索结果中。 - 系统发出告警（因为这影响SLO）。运维需尽快恢复索引服务，然后可使用重处理工具将此文档重新索引（系统应提供幂等重放机制）。 - 在降级策略下，若索引服务不可用且进入L3降级，系统可能暂停接受新文档（见降级处理）。一旦服务恢复，需确保积压文档全部补索引，并监控清理延迟是否在SLO内。 - 分析失败：如果后续可信度计算或知识图谱更新失败（例如模型服务超时），Document可能永远无法标记analysis_ready=true。不过此时Document至少已Indexed，对检索无影响，只是在高级分析中可能缺少该内容。系统会记录 `processing_error_code` 并将analysis相关任务放弃或等待下次批处理纠正。此错误通常不反馈给终端用户，但长远看会在可观测性指标（analysis_ready成功率）上体现并引起工程修复。 - 系统降级：此用例在降级模式有特殊处理： - **L2 降级**：系统可能暂时将analysis处理队列暂停或放缓，但仍会完成基础索引以保证Searchable状态达成（可能略超5min SLO但尽量保障）。新内容 `ingestion.received_at` 仍会记录，但 `analysis.ready_at` 可能延迟较久。系统在恢复正常后会逐步清理堆积分析任务，并确保最终analysis_ready完成。对于用户查询，在analysis未完成期间检索结果仍可看到该文档但可能缺少附加信息（如摘要）。 - **L3 降级**：系统将暂停处理新的 `crawledPage/newDoc` 事件以专注服务查询。新内容事件不会丢弃而是**进入队列等待**。系统返回给爬虫端的确认可能延迟（或通过backpressure告知爬虫放缓）。当系统脱离L3状态后，将逐步处理积压的新内容，并监控额外延迟。Admin在中控台可看到提示：“系统处于最高降级，新内容暂未处理”。恢复后，确保所有积压文档在可接受时间内处理完毕，并达成清理SLO（例如恢复后10分钟内清空队列）。 - 数据保留策略：如遇文档属于租户请求删除的数据源或超过保留期，系统应中止后续处理并直接按删除流程处理（参见数据治理）。这属于特殊情况，不在一般Pipeline流程内。

UC-005: 社交账号画像更新与监控（Account Profile & Monitoring）

Trigger：Persona-AD（管理员）或 Persona-AN（分析师）对某**社交媒体账号或话题**创建了监控订阅。系统持续采集该账号发布的内容并更新其画像。当画像指标发生显著变化或异常行为时触发告警和深入分析。

Primary Steps:

1. **订阅设置**：Admin/Analyst 在系统中选定一个社交账号（例如一个Twitter用户名）或主题标签，创建订阅任务。配置包括监控项类型（账号帖文/主题流量）、监控频率、以及感兴趣的指标（如粉丝数变化、情感倾向）。
2. **持续采集**：系统根据订阅，调用对应的社交平台采集策略，不间断地获取该账号的新**SocialPost**内容和账号状态信息（如粉丝数、简介更新）。采集频率可按订阅配置或平台API限额（例如每5分钟检查一次新帖）。
3. **更新 AccountProfile**：每当获取到该账号的新内容或状态变化，系统更新该账号的 **AccountProfile** 数据。AccountProfile 包括：账号基本信息（名称、简介等）、统计指标（粉丝/关注数、发帖频率）、内容特征（主要活跃主题、语调情感平均值、可信度评分等）。
4. 新帖文内容会触发专门的分析：如对帖子文本进行NLP（情感分析、主题分类），结果汇总更新到账号画像的趋势指标中（例如最近一天的内容情感平均值）。

5. 如果AccountProfile中跟踪“立场/阵营”之类属性，则根据新内容对其可能做微调（比如通过关键词分类判断其政治立场是否变化）。
6. **异动检测**：系统对AccountProfile的关键字段应用**Change Detection**算法。例如：粉丝数在短时间内异常增长、内容情感分布与之前大相径庭、发布频率骤变等。若检测到显著“异动”，则生成一个 `personaChangeDetected` 事件，内部发布（analysis.personaChange）。
7. **触发告警和分析**：当异动事件产生：
8. 系统创建一条 **AdversarialAlert / PersonaAlert** 告警（取决于判断该异动是否可能由对抗性操纵引起）。例如，若该账号突然开始传播异常信息，则触发对抗性告警；若只是自然事件导致粉丝增长，也可作为一般PersonaAlert告警。
9. 系统同时触发深入分析流程（类似UC-001的研究任务但针对该账号）：如自动生成一张 **RecommendationCard**，内容包括：描述该账号异常情况、风险评级（若判定有风险）、相关证据列表（异常帖子引用）以及建议（例如“人工复核该账号”）。
10. 如果策略中定义了自动措施（例如对高风险账号自动降权），PolicyBundle规则在此时会被执行。
11. **用户接收通知**：Persona-AD 和 Persona-GOV（治理官）会在中控台或通知中心看到关于该账号的告警信息和推荐卡片。例如：“⚠账号 @X 在过去1天粉丝增涨+500% 且内容倾向发生显著改变（High 风险）”。Analyst 也可在订阅界面查看该账号的最新画像和系统分析结论。
12. **持续监控**：系统继续后续循环监控。如异常持续，系统可避免重复告警（参见Failure Handling中的去重）。若异常消失（指标恢复正常），可在AccountProfile上标记异常结束时间，并可能生成一条恢复通知（风险级别降低）。

Output: - **AccountProfile 更新** – 每次新内容到来会更新该账号的画像数据（C-001 Document 和衍生结构中也有记录，但AccountProfile汇总级别的数据结构应定义，例如C-010或附属结构）。用户可在前端账号详情页面查看最新画像信息：包含最新的粉丝/内容指标、近期趋势图表等。 - **Alert 告警** – 当检测到异常时，系统在告警中心生成**告警条目**（AdversarialAlert或PersonaAlert），包括触发时间、账号标识、异常摘要、严重程度（Low/Med/High）、关联的 evidence_list（如异常行为的示例帖子引用）以及唯一 alert_id（用于追踪）。同时邮件或站内通知相关Persona-GOV/AD角色。 - **RecommendationCard** – 若异常风险较高，系统自动生成一张RecommendationCard来建议后续行动（例如“将该账号列入重点监控”）。卡片内容包括 risk_level（例如High）、summary（描述此账号异常行为）、evidence_list（异常帖文链接集）、以及可能的action建议字段（如 “暂时降权该账号” 或 “人工审查内容”）。 - **Audit Log** – 相关的订阅创建、修改，以及触发的告警事件等均在审计日志中记录，包括操作者、时间、对象ID等（C-013 AuditLog）。

Failure Handling: - 数据源访问失败：如果社交平台接口不可用或超出API配额，系统会记录采集失败。在不中断监控的情况下，系统将按照退避策略重试。同时给Admin一个提醒（例如“Twitter API 调用受限，监控延迟”）。不触发用户级错误，只在后台显示状态异常。恢复后系统自动继续，无需人工介入。 - 账号不存在或权限问题：如果订阅了错误的账号ID或因隐私设置无法获取其数据，创建订阅时系统返回错误（代码 **1200 NotFound** 或 **1003 AccessDenied**）。如果账号后续变为不可访问（例如账号被删除或改为私密），系统在监控日志中标记并通知Admin。订阅可以保持但无数据更新，Admin可选择移除。 - 误报和重复告警：为避免过度告警，系统对告警进行了去重和抑制： - 若检测到的异动在一定时间窗口内已告警过（例如24小时内重复的变化趋势），系统不会重复生成相同内容的告警。已存在的告警会更新最近发生时间戳，而不会每次都新建。Alert 对象中的 `alert_id` 结合账号标识和异常类型生成，重复事件触发时发现相同 alert_id 已存在则进行**合并**而非新告警。 - 如果策略评估认为某些异常可接受（如粉丝小幅波动），可能调整为低级别告警甚至不告警。只有超出阈值的才升级。 - Persona-GOV 可以在前端对某些告警标记为误报或已处理；系统应停止对此相同原因频繁告警，并将该反馈用于今后模型调整。 - 自动响应失败：如果PolicyBundle配置了自动处置（例如立即降低该账号内容可信度权重），系统执行这些动作时可能失败（例如尝试更新策略时冲突）。这类错误记录在审计日志，且在告警详情里注明“建议动作未自动执行，需要人工处理”，但不会另行触发新的告警。GOV人员需人工检查并重试策略调整。 - 降级影响：在系统L2/L3降级时，监控频率可能降低甚至暂停： - **L2**：系统可能暂缓高级分析部分。例如仍采集和更新基础指标，但复杂的情感计算或风险分析延后。这样可能导致告警延迟产生。系统应在降级恢复后立即补做分析，并评估是否错过告警需要补发。 - **L3**：系统可能暂时停止所有订阅监控任务，将资源让位于核心查询。此时用户界面会标记监控状态“暂停中”。当恢复正常后，系统应重新扫描监控期间错过的数据，若补回后仍检测出异常则补发告警，并标注“迟发”。对于L3期间错过的潜在告警须在风险报告中列出并人工审核一次。 - 数据保留：AccountProfile 会随时间积累大量历史指标。系统定期归档

旧的详细数据，仅保留聚合趋势（详见数据治理）。这不会影响实时监控，但如果Admin请求很久以前的细节可能有限制。

UC-006: 推荐卡片驱动的行动建议（Recommendation Card to Action）

Trigger：系统检测到特定触发条件需要产生**行动建议**。典型触发包括：Persona 异动（来自UC-005）、重大事件聚类形成新热点、某主题可信度显著下降、对抗性攻击告警等。

Primary Steps:

1. **触发事件发生**：某个模块产生了需要决策关注的事件。例如：
2. PersonaChangeDetected（人物画像异动，高风险）事件（见UC-005）；
3. 新的事件聚类被识别为舆论热点（如系统发现某主题短时间内出现爆炸性增长）；
4. 全局可信度评分显著下降（如大量低可信内容涌入）；
5. 检测到对抗攻击模式（如多个来源同时出现相似假新闻）。
6. **系统生成RecommendationCard**：对于每一种触发，系统都有预定义的Recommendation模板和逻辑：
7. 系统收集触发事件的关键信息和证据。例如对于Persona异动，收集相关账号近期异常帖文；对于热点事件，收集该事件的主要报道和扩散范围。
8. 根据模板，系统生成**RecommendationCard**对象，字段包括：
    - `title`：简单描述建议内容。例如“监控某人物的异常行为”或“关注热点事件X”。
    - `summary`：详细说明背景和建议行动。例如“账号@X的行为出现异常，建议启动舆情调查”或“事件X可能引发重大影响，建议相关部门准备应对方案”。
    - `risk_level`：系统评估的风险级别或优先级（高/中/低）。例如Persona异动一般High，对于一般舆情热点可能Medium。
    - `evidence_list`：提供支撑该建议的证据条目列表。例如触发Persona异动的几条典型异常发言；热点事件的几篇关键报道及数据统计。
    - `insight`：可选的分析见解，如果有额外背景说明。如“该账号历史上曾多次出现类似异常，每次均与某事件相关”。
    - `recommended_action`：**建议的行动**。例如对于高风险账号建议“暂时限制其内容传播并人工复核”；对热点事件建议“召开专项分析会，制定应对策略”等。
    - `timestamp`：卡片生成时间。
9. **系统审核/发布卡片**：如果策略要求人工审核（例如High级别建议需Gov审批才能发布给决策者），系统将该卡片状态标为“Pending Approval”，通知Persona-GOV进行审核。GOV在审阅证据后，可选择批准发布或驳回/修改卡片。如果无需审批，则跳过此步直接发布。
10. **卡片推送**：系统将最终的RecommendationCard 推送给相关受众：
11. Persona-DM（决策者）在其仪表盘或通知中心收到该推荐卡片，以高亮方式提示有新的行动建议。决策者可展开查看详情和证据。
12. Persona-AN（分析师）也会在分析工作台看到新卡片，以便他们准备后续分析报告或执行建议动作。
13. Persona-AD/GOV 可在治理控制台查看所有RecommendationCard列表及其状态（新的、进行中、已执行、已驳回等）。
14. **执行跟踪**：系统在卡片推出后，支持对其建议的执行跟踪。例如，如果卡片建议“导出报告”，Analyst 可以一键根据卡片内容生成报告（集成UC-007）；如果建议“采取下架措施”，Admin 可在控制台直接针对提及的数据源执行下架操作。系统会将这些执行操作与原RecommendationCard关联记录，更新卡片状态为“ActionTaken”或类似，并在卡片界面显示执行结果（例如“报告已导出 by Analyst A at 时间”）。
15. **反馈闭环**：决策者或执行人可对卡片的成效进行反馈评分（如标记建议是否有用）。系统收集这些反馈供后续优化策略。例如如果某类建议多次被标记无效，可在策略中降低其触发频率。

Output: - **RecommendationCard** – 一条结构化的行动建议卡片（参见C-015），呈现给决策者/分析师。用户界面中卡片包含标题、概要、风险级别等关键字段，并支持展开查看证据列表。卡片还能展示执行按钮或链接

（如“导出报告”、“查看详情”）。 - **通知消息** – 系统为高优先级的卡片发送即时通知（邮件或短信，若已配置），确保相关人员及时看到建议。例如High风险卡片发送短信提醒决策者查看。 - **卡片列表更新** – 在控制台或报告中心的RecommendationCard列表中，新增该卡片条目。相关人员可以过滤查看未处理的建议卡片。 - **审计记录** – 卡片的整个生命周期重要步骤都进入审计日志：生成者（系统）及时间，审批人及操作，受众查看时间，执行人及执行结果等（C-013 AuditLog）。

Failure Handling: - 建议生成误差：可能出现卡片内容不准确或证据不足的情况（例如算法误判风险）。治理人员可以**驳回**卡片：标记为“Rejected”，并在理由中说明误判原因。系统将此反馈记录，并避免同一触发在短期内再次生成类似卡片。被驳回的卡片不会推送给决策者，只在治理控制台留档。 - 审批超时：如果卡片需要审批但较长时间（如>2小时）未被审核，系统会提醒备选审批人（如另一个Governance人员）。如果依然无人处理且卡片风险级别High，系统可以考虑直接推送并标记“未审批自动发布”（此策略需在PolicyBundle中定义）。一般情况下审批超时不会自动发布Low/Med风险卡片，而是等待或降级处理。 - 通知未达：如果决策者未及时看到通知（例如邮件延迟），系统在卡片创建一定时间后（如1小时）会再次发送提醒，或通过备用渠道通知（如短信）。这一机制保障重要建议不被遗漏。多次通知仍未读，系统可能升级告警给Admin以人工确认决策者状态。 - 执行未执行：卡片建议的行动如果在一定时间内未被执行（例如卡片建议24小时内导出报告但没人执行），系统会将该卡片状态标记为“未执行”，并通知Governance人员跟进。这确保关键建议有闭环，不石沉大海。 - 降级模式下行为：在系统进入L3降级时，可能会**暂停生成新的RecommendationCard**，以减少非核心开销。已触发的事件暂存待系统恢复后再处理生成卡片。或者在L2模式下，系统生成卡片但**延迟推送**，等待系统稳定后再交付，以避免在混乱期间决策者收到过多信息。降级期间产生而延迟的卡片在推送时应注明生成时间和延迟原因以供参考。 - 重复建议合并：如果不同触发事件产生内容相似的建议（例如两个相近的热点事件建议相同行动），系统应**合并**卡片：在一张卡片中涵盖多个触发来源，或仅生成一张优先级更高的综合卡片。这由策略定义避免建议轰炸。对合并逻辑不完善导致的重复卡片，Governance可手工合并/关闭。未来优化策略，减少重复。

UC-007: 生成可交付报告（PDF Export）

Trigger：Persona-AN（分析师）在完成一系列研究分析后，需要将结果整理成正式报告，以PDF格式导出分享给决策者或其他利益相关者。

Primary Steps:

1. **选择报告内容**：分析师在前端报告界面挑选需要包含的内容模块。通常包括：若干 **RecommendationCard**（可从之前生成的卡片中选择）、关键数据可视化图表（如趋势图、统计表）、正文说明段落等。分析师也可以选择全部当前研究任务产生的卡片和结论。
2. **选择模板和参数**：分析师从预先定义的 **ReportTemplate** 列表中选择一种版式模板。模板决定了报告封面、目录样式、章节布局，以及页眉页脚（水印）等。分析师还设定报告标题、作者、导出的语言（若需要不同于默认语言，则系统会将内容翻译，双语展示或按照Persona-DM的语言偏好输出）。
3. **提交导出请求**：分析师点击“导出PDF”按钮。系统显示确认信息（所选内容项、模板、语言等），确认后开始生成。导出任务在后台异步执行，以免阻塞前端。
4. **队列处理导出**：系统将该导出请求封装成 **ReportJob**（参见C-010），放入导出队列。队列确保即使短时间多个导出请求也能按序处理。ReportJob 包含report_id、请求者、选用模板id、选取的内容IDs列表等信息。
5. **生成PDF**：Report Generator服务消费ReportJob，开始生成PDF：
6. 根据模板布局，将所选 RecommendationCard 等内容填充到相应版块。文本类内容直接插入，图表类内容根据数据渲染生成图形（如调用图表库）。
7. 对于需要翻译的内容，先调用翻译服务将文本转换到目标语言；双语模式则在报告中并列展示。
8. 添加 **水印和审计标识**：按照要求在每页添加水印文字（如“机密”+租户名），并在显著位置注明审计ID和生成时间。审计ID与审计日志对应，形如 Report#20251201-001。
9. 生成目录、页码等。然后编译输出为 PDF 文件字节流。

10. **存储并完成**：生成的PDF文件保存至文件存储（或直接缓存于内存流）。系统更新 ReportJob 状态为“Completed”，记录输出文件的存储路径、文件哈希等元数据。审计日志记录report_id、生成用时等。
11. **通知并下载**：系统通过前端通知分析师“报告已生成”。分析师点击通知可下载PDF文件到本地。系统也支持一个短时间的下载链接。有需要的话，Persona-DM 决策者也能访问到此报告（若分析师设置了共享）。

Output: - **PDF 报告文件** – 含有封面、目录、内容正文、附录（证据列表或相关参考）等的完整PDF文件。例如文件名 `ResearchReport_事件X_2025-12-18.pdf`。PDF每页带有租户水印和唯一审计编号，用于防泄漏溯源。 - **报告元数据** – 系统在报告列表中新增该报告条目，包括报告名称、创建人、创建时间、涉及主题/人物标签等。供日后检索报告用。 - **审计记录** – 审计日志里记录 ReportExport 动作，字段包括report_id、导出人、模板ID、内容项IDs、生成时间、文件哈希、policy_version（策略版本）等（C-013 AuditLog），确保报告内容可追溯和不可抵赖。

Failure Handling: - 模板错误或不兼容：如果所选ReportTemplate文件有错误（如占位符未正确定义）导致渲染失败，系统捕获异常： - ReportJob 状态标记为“Failed”，附带错误原因。分析师前端将收到失败通知（代码 **2400 ReportGenError**），提示报告生成失败。分析师可尝试选择不同模板或联系Admin修复模板。 - 系统也向Admin/GOV发送告警，因为模板错误通常需要修正。错误模板在修复前可被临时禁用以防止连续失败。 - 所含内容过期/缺失：导出时若所选的某些 RecommendationCard 等内容已被删除或权限变更导致不可用： - 系统在生成时会跳过无法获取的内容，并在结果报告中注明“（该部分内容未提供）”。同时返回一个警告状态（不算完全失败），前端提示“部分内容未导出”（可带代码 **1201 PartialContent**）。 - 分析师可根据需要重新调整内容再导出。如果关键内容缺失造成报告无意义，则应中止导出，系统返回错误（代码 **1201** 也是possible，但伴随消息说明哪个内容缺失）。 - 导出任务超时：如果报告生成非常耗时（比如包含大量高清图表）超过设定阈值（如60秒），系统可能取消该任务： - 前端收到超时通知（**5102 ReportTimeout**），表示报告未成功。建议分析师减少内容或更换模板重试。 - 同时在后台继续尝试生成简化版本（例如低分辨率图片），或拆分任务。如果最终成功，可通知分析师。但通常超时任务需要人工调整。 - 文件存储失败：如果PDF生成后保存到文件存储失败（如磁盘空间不足、网络故障），系统会记录错误，将ReportJob标记失败并告警运维处理磁盘问题。前端得到错误（**1300 DependentServiceError** 或定制消息“存储失败”）。待存储问题解决后，可重新执行该ReportJob（具备幂等ID避免重复内容）。 - 用户下载失败：如果分析师收到报告但下载链接失效（可能因链接过期或权限问题），分析师可以在报告列表重新请求下载（链接可重新生成）。系统确保报告文件至少保留一段时间（配置的保留期，如7天）以供重新下载。超过保留期文件可被清理，但报告元数据保留。用户若需要需重新生成报告。 - 过载与降级：在高负载L2/L3情形下，系统可能**延迟执行非关键的报告导出**： - L2时，新导出请求进入队列但处理速率降低，分析师UI提示“系统繁忙，报告生成可能延迟”。一旦有空闲资源就处理。确保在线查询优先。 - L3时，系统可能暂不接受报告导出请求。前端立即返回错误（**5403 ServiceOverloaded**），要求用户稍后再试。并将请求记录（或让用户稍后手动重试）。此举保证严重过载时不因报告任务影响核心检索。 - 降级期间未完成的ReportJob保留在队列，降级解除后系统按照提交顺序继续生成，并通知用户。如果恢复后队列过长可能违反导出SLO，但这在非常态情况，可以在Acceptance Plan里豁免。 - 安全与权限：报告生成遵循权限边界：分析师只能导出其有权限访问的数据所形成的报告。例如包含的卡片和图表均来自该租户或项目的数据。系统在组合内容时再次校验权限，若发现不应包含的数据，则如上所述跳过或报错。审计日志记录报告内容及权限验证通过情况，供事后审计。

UC-008: 策略治理与离线精炼（PolicyBundle Rollout & Offline Refine）

Trigger：Persona-GOV（治理官）或 Persona-AD（管理员）发布了一版新的策略包（PolicyBundle）用于调整系统行为；或者触发一次离线精炼任务（Refine），例如重新计算所有文档可信度、重建某些索引，以适应新策略或模型升级。

Primary Steps:

1. **策略变更提议**：Governance人员准备好新的 PolicyBundle 配置，例如更新查询过滤规则、证据融合参数或新增对抗攻击处置策略等。通过治理界面上传/编辑策略包（JSON/YAML格式），附加变更说明。然后点击“发布”，进入审批流程。
2. **审批发布**：根据治理流程，高风险策略变更需要至少一名高级审批人确认。Persona-GOV 审阅策略diff后，同意发布。系统将PolicyBundle标记为**Pending Rollout**状态，并准备在全局应用。
3. **版本化发布**：系统为该PolicyBundle分配新的 **policy_version**（如v3.1）。在调度器中创建一个“策略发布任务”，约定5分钟内在全系统生效【B-05】。如果采用灰度发布模式，策略任务可能包含多阶段：例如先在少数节点上应用观察，然后逐步全量。
4. **策略下发**：系统把策略包推送到相关模块：
5. Query Planner 收到新的检索规则配置，在处理用户查询时将按新规则规划（例如不再检索某些来源，或增加某关键词加权）。
6. EvidenceFusion 模块加载新融合参数，在证据排序时应用更新算法。
7. 对抗检测模块加载新阈值，调整告警触发灵敏度。
8. 其他受影响模块如Persona分析、报告引擎等也同步新策略。推送采用发布订阅或配置中心通知，节点收到后立即（或在安全点）切换至新策略。
9. **生效确认**：系统在策略下发5分钟后（或设定延迟）收集生效状况：
10. 各服务报告其当前使用的policy_version。如果有未及时更新的实例，系统重试推送或标记异常。
11. 进行一组关键路径测试（由自动化测试或运行日志验证）以确保新策略真的在生效。例如触发一条受策略影响的查询，检查Planner输出符合预期规则【B-05】。
12. 若全部通过，策略包状态更新为**Active**，生效时间记录为当前时间。
13. **策略监控**：上线后的策略会被持续监控一段时间（如24小时）：
14. 系统重点监视与该策略相关的指标（Trace 覆盖率，告警数量等）是否有异常波动。
15. 如果发现负面影响（比如告警激增或查询耗时上升），治理官收到提醒，可决定是否**回滚**策略。
16. **策略回滚**（如需）：Governance人员在界面点击“回滚到上版”，系统将旧的上一版本PolicyBundle重新发布（过程类似上述，只是不需要审批即可快速应用）。回滚策略应用需尽快（目标5分钟内）完成，并记录此次回滚操作。系统视情况对受影响数据进行修正（例如如果新策略错误导致错误标记很多内容，可能需要离线修复）。
17. **离线精炼任务**（Refine）：当新策略/新模型涉及需要重处理历史数据时，Governance可以下达Refine作业。例如：
18. “重新计算全部文档可信度”：系统将把所有既有Document重新跑一遍可信度算法。这通常是低优先级后台任务，分批处理可能持续数小时。
19. “重建向量索引”或“刷新知识图谱社区”：系统在后台执行，对用户透明。 系统为Refine任务分配ID，调度运行，并在完成后出具报告（处理条目数，修正了哪些数据）。Refine期间不会中断在线服务，但占用资源可能受降级管理。
20. **结束**：PolicyBundle变更和Refine任务完成后，系统在治理日志中记录整个过程详情。新的策略版本号及适用时间写入审计记录，以便将来的所有分析输出都能够追溯到所用策略版本（trace_id 中或报告附注policy_version）。

Output: - **PolicyBundle 列表更新** – 在策略管理界面，新的策略版本条目添加，状态显示Active，生效时间。旧版本策略保留在历史列表可查看（版本号及生效区间）。 - **策略发布审计报告** – 系统生成一份策略发布报告，包含变更内容摘要、版本号、发布人、审批人、发布结果（是否成功在全部节点应用）等。这用于治理存档，Gov人员可下载或查看。 - **Refine结果日志** – 对于每个Refine任务，系统在数据治理界面提供结果摘要。例如“可信度重算完成：影响文档12345篇，其中高可信->中可信 50篇，修正错误标记 5项。” 详细清单可下载。审计日志中记录Refine任务ID、发起人、开始/结束时间等。 - **全局配置影像** – 新策略可能改变系统行为，比如降低告警噪音。用户在其他用例会感受到变化，但没有直接“输出”界面。为了感知效果，Gov可查看监控仪表板上相关指标曲线，例如告警数量在策略前后变化，查询性能变化等。 - **DegradationStatus** – 如果策略涉及降级策略矩阵调整，新的降级阈值和级别行为马上反映在 DegradationStatus API（C-018）输出上，运维查询时会看到已更新的配置。

Failure Handling: - 发布失败/部分失败：如果在5分钟发布窗口后，有部分服务未加载新策略（例如某离线Worker节点未更新）： - 系统标记PolicyBundle状态为**Deployed with Warnings**，列出失败节点。运维/SRE会收到告警，提示手动干预（例如重启相关服务）。 - 在此期间，系统可能处于混合策略状态（部分服务用新策略，部分旧策略）。ARB可根据影响范围决定要不要紧急回滚。如果影响较小，可在运维修复后标记完成。 - 若大范围失败且影响严重，系统自动触发回滚至旧版策略，并错误码 **2500 PolicyDeployFailed** 记录于审计日志。Gov界面提示“新策略发布失败，已自动回滚至vX.X”。 - 策略冲突：如果新PolicyBundle与现行策略或规则冲突（例如两条互斥规则），系统在发布前应检测冲突： - 冲突检测由策略管理UI在提交流程中完成。若发现，系统不允许发布并给出明确冲突描述（如规则A与规则B冲突），要求Gov调整。 - 如果冲突在运行时才显现（例如产生大量异常告警被认为策略逻辑冲突），Gov可能需要紧急回滚，然后调整策略再发布。系统不自动处理逻辑冲突，只提供监控告警。 - 回滚失败：如果执行回滚时遇到问题（例如旧版本文件损坏，或系统已经处于不一致状态无法无缝切换）： - 系统会重试。如果仍失败，将告警提示需要人工介入修复策略（手动在所有服务上应用旧配置）。这种情况极其少见，风险极高，应在测试阶段避免。 - 系统在审计日志中完整记录尝试的每一步，让开发人员日后排查。 - Refine任务失败：离线精炼任务可能因为资源不足或数据异常提前终止： - 系统标记任务状态为Failed，并告警。部分完成的数据已写入的，要么系统设计为**先写临时再统一替换**，确保失败不会部分应用，要么需要在失败后回滚数据。 - 例如可信度重算任务失败一半，则系统应保留旧可信度，对已处理部分回滚旧值；或者标记哪些文档已用新算法而其他没有，从而暂时存在不一致，并强制下次任务继续完成。 - 此类复杂场景通常通过**幂等设计**解决：Refine任务可多次运行直至完成，因此Gov可在修复问题后重新启动Refine。 - 多租户策略隔离：注意策略往往全局适用，但如果系统支持租户自定义策略（当前未明确支持，按假设全局统一），则要考虑不同租户策略不同的情况。本版本假设策略全局统一；如将来支持租户自定义，将在Scope调整。本用例未涵盖多租户不同策略情形。 - 降级期间策略发布：如果系统正处于L3降级紧急情况，不建议在此时发布新策略（风险大）。系统UI会禁止或警告Gov避免此操作。如执意发布，系统会先尽量稳定核心后再应用（比如延迟到降级恢复时自动发布）。审计记录应包含降级期间策略发布的特殊处理说明。

6. Functional Requirements（功能需求）

下表汇总了系统的功能性需求（FR-001 ~ FR-023）。每条需求包含唯一ID、简要标题、输入和输出描述、优先级（MoSCoW）、依赖关系（其他需求或模块）、与OKR的对应关系，以及可验证的验收标准（AC）。这些需求均遵循“只描述**What/Why**，不限定具体实现方式”的原则。

FR ID	Title (功能名称)	Inputs (输入)	Outputs (输出)	Priority	Dependencies	Trace to OKR	A
FR-001	Non-blocking Ingest & Query Pipeline （摄取查询解耦）	新内容数据项；用户查询请求	内容进入索引/分析管道；查询结果或响应超时/错误	Must	FR-017（降级机制）	O1 KR1, KR3	1 用 管 采 通 摄 常 服 系 发

FR ID	Title (功能名称)	Inputs (输入)	Outputs (输出)	Priority	Dependencies	Trace to OKR	A
FR-002	Unified Three-layer Query DSL （统一三层检索DSL）	用户查询字符串（含关键字、语法过滤）	规范化的查询计划（包含全文/向量/图谱子查询）；匹配的结果集（文档IDs）	Must	（无，基础功能）	O1 KR2, O3 KR1	1 布 s 殊 精 非 时 1 全 确 副 同 语 D 查 回
FR-003	Content Parsing & Metadata Extraction （内容解析与元数据提取）	抓取的原始内容（HTML、JSON等）	Document 对象（正文、标题、时间等字段）	Must	（无）	O1 KR1, O1 KR3	1 J 定 D 布 解 解 **语** 赋 钟 析 D 推 语

FR ID	Title (功能名称)	Inputs (输入)	Outputs (输出)	Priority	Dependencies	Trace to OKR	A
FR-004	Multi-tenant Data Isolation （多租户数据隔离）	含租户身份的各类请求（查询、导出等）	仅返回/操作该租户所属数据；拒绝跨租户的数据访问	Must	（无）	(O2 持续合规) ※	1 包 多 中 等 法 尝 负 1 土 制 查 询 to
FR-005	5-min Freshness Pipeline （新内容5分钟新鲜度）	新采集内容事件；系统各处理阶段	新内容可检索（Searchable）；新内容完成分析（Analysis-ready）	Must	FR-003, FR-002, FR-017	O1 KR1, O1 KR4	1 客 态 9 re 6 S 完 写 国 压 D a 确 条 a 外 客 标 s 并 合

FR ID	Title (功能名称)	Inputs (输入)	Outputs (输出)	Priority	Dependencies	Trace to OKR	A
FR-006	Relevant Search Results （检索结果相关性）	用户查询（文本，含语义 intent）	排序后的搜索结果列表（文档IDs + 摘要）	Must	FR-002, FR-005	O2 KR1, O2 KR3	1 诊 实 返 P **关** 但 召 证 事 工 **结** – T 且 **溯** 用 据 S e 准
FR-007	Evidence-based Answering （基于证据的回答生成）	用户复杂问询（需要综合多文档信息）	结构化回答对象：Answer文本 + evidence_list + 选定的推荐卡片	Must	FR-006, FR-004, FR-002	O2 KR1, O2 KR2	1 带 片 统 回 对 文 以 且 则 人 行 来 到 **出** 证 R 除 证 R

FR ID	Title (功能名称)	Inputs (输入)	Outputs (输出)	Priority	Dependencies	Trace to OKR	A
FR-008	Cross-lingual Search & Output （跨语言检索与输出）	非系统主要语言的查询（如英文查询中文内容） 或需要双语展示的输出	查询结果（含原文+译文双语证据）；多语言报告/卡片输出	Must	FR-002, FR-006	O3 KR2, O3 KR3	1 语 主 索 两 上 **双** 示 1 准 **语** 指 翻 – 正 这 输 篇
FR-009	Knowledge Graph & Timeline Integration （知识图谱与时间线融合）	结构化知识（实体关系）；时间序列数据	更新的图谱节点/边；Persona 快照序列；支持时间筛选的查询	Should	FR-005, FR-006	O3 KR1	1 文 证 量 – 耶 复 D 2 e 果 间 时 < G – G P 新 照 用 语 合 答 正

FR ID	Title (功能名称)	Inputs (输入)	Outputs (输出)	Priority	Dependencies	Trace to OKR	A
FR-010	Domain Ontology Enforcement （领域本体一致性应用）	实体/事件抽取结果（自由文本类型）	标准Ontology类型标注的实体/事件字段	Must	FR-003, FR-009	O3 KR1	1 体 型 类 类 伪 O 一 型 O 情 与 判 知 新 类 理 构 均 E
FR-011	Multi-language UI & Localization （界面与内容多语支持）	用户界面文本、多语言内容资源	根据用户语言偏好的界面显示；报告/卡片按所选语言生成	Should	（系统配置）	O3 KR3	1 至 新 按 方 翻 R 内 F 用 > 和 定 或 按 例 序 式 E 表 等 此 各

FR ID	Title (功能名称)	Inputs (输入)	Outputs (输出)	Priority	Dependencies	Trace to OKR	A
FR-012	Real-time Persona Profiling （人物画像实时更新）	新的人物相关内容（新闻、帖文）；订阅的监控实体	更新的PersonaSnapshot；触发PersonaChange事件/告警	Must	FR-005, FR-009, FR-006	O4 KR1, O4 KR2	1 内 P 照 天 客 客 **出** 场 值 间 等 在 变 **性** 感 致 确 数 P R 这 物 类 遗
FR-013	PolicyBundle Versioning & Rollout （策略包版本管理与发布）	新的策略配置（规则集合，版本说明）；可选渐进发布参数	策略在系统全局生效（各模块加载新配置）；版本号、状态反馈	Must	（平台服务）	O2 KR1, O4 KR2	1 版 显 次 录 置 钟 略 已 发 > 布 策 **渐** 回 略 结 略

FR ID	Title (功能名称)	Inputs (输入)	Outputs (输出)	Priority	Dependencies	Trace to OKR	A
FR-014	Evidence Chain Enforcement （证据链强制要求）	任一面向用户的结论输出（Answer/ Insight/ Recommendation）	该输出所引用的 evidence_list 字段（证据链条）	Must	FR-006, FR-007	O2 KR1	1 论 R 段 证 检 **性** 确 2 联 为 e 义 等 a 据 高 明
FR-015	Content Credibility Scoring （内容可信度评分）	文档、账号等内容对象；上下文（时间、来源等）	credibility_score（可信度分数）；组成明细（若支持分解）	Must	FR-005, FR-009, FR-012	O4 KR1	1 a 可 篇 D 显 已 系 均 **可** H 系 ti n A ri 案 证 **更** 变 不 将 累 表 s

FR ID	Title (功能名称)	Inputs (输入)	Outputs (输出)	Priority	Dependencies	Trace to OKR	A
FR-016	Adversarial Attack Detection （对抗攻击检测与告警）	新内容集、行为模式数据	AdversarialAlert 告警（含严重级别、建议动作等）	Must	FR-012, FR-015, FR-013	O4 KR2	1 类 则 据 集 报 证 生 A a e 例 审 报 对 抗 客 除 果 显 A

FR ID	Title (功能名称)	Inputs (输入)	Outputs (输出)	Priority	Dependencies	Trace to OKR	A
FR-017	Graceful Degradation Matrix （弹性降级策略矩阵）	系统运行状态监测数据（QPS、延迟、队列长度等）	当前降级级别（L0/L1/L2/L3）；降级措施启停	Must	FR-013 (策略配置)	O1 KR4, O2 KR3	1 当 统 率 阈 > 志 别 L 理 L 各 留 暂 静 警 每 L 告 **后** 降 例 L 窃 反 **知** 在 度 告 恢 多 零

FR ID	Title (功能名称)	Inputs (输入)	Outputs (输出)	Priority	Dependencies	Trace to OKR	A
FR-018	Anomaly Alert & Trend Analysis （异常舆情告警与趋势分析）	实时内容/指标流（如话题热度、负面情感占比）；基线模型	告警事件（趋势异常）；更新的趋势报告/RecCard（如需要）	Must	FR-012, FR-016	O4 KR2, O2 KR2	1 异 报 在 警 注 告 统 面 某 定 报 告 基 动 监 口 量 证 趋 R 近 准 步

※ 注: FR-004 的 Trace-to-OKR 栏标记为持续合规目标（提升数据隔离和安全），未在OKR列表中单列，但属系统必备要求。

7. Non-functional Requirements（非功能需求）

系统的非功能需求涵盖性能、可靠性、安全、可维护性等方面。每项NFR均以**可度量**形式描述，并赋予唯一标识（Rank），按重要性全局排序。列出了目标值、服务水平（SLO）、测量方法、告警阈值、优先级（Must/Should）以及对应OKR映射。所有NFR均应被验证和持续监控。

Rank	Requirement (Measurable)	Target (目标值)	SLO (服务水平)	Measurement (度量方法)	Alert Threshold (告警阈值)	Priority	Tra OK
Must-01	**Query Latency P99** – 99% 用户查询延迟 ≤800ms。	≤ 800ms (P99)	99% queries within 0.8s (per day)	收集 MTR-002 (QueryLatency) 直方图，计算日P99。排除长报告请求。	P99 >800ms 持续10分钟（触发L2降级预案）	Must	O1 (80
Must-02	**Ingest-to-Search Latency P95** – 新内容可检索延迟。	≤ 5 min (P95)	95% new docs searchable ≤5min (per day)	收集 MTR-001 (IngestLatency)。测量 ingestion.received_at 到 index.search_ready_at 差值分布。	P95 >5min 超过连续3个小时 (数据堆积异常)	Must	O1 (5分
Must-03	**Query Success Rate** – 请求成功率。	≥ 99.5%	≥ 99.5% successful queries (per month)	监控 MTR-004 (RequestSuccess)＝成功请求数/总请求数。排除4xx用户错误。	当小时成功率 <99% 或日成功率 <99.5%	Must	O1 (99
Must-04	**Query Throughput** – 查询吞吐量峰值能力。	≥ 100 QPS (sustain)	100 QPS sustained with <5% latency degradation	定期压测：模拟100并发连续1分钟，总请求数>=6000且P99延迟增幅<5%。	若实际QPS接近100且延迟明显上升 (>10%基线)	Must	O1 (10 QP
Must-05	**Ingestion Capacity** – 内容摄取容量。	≥ 10k docs/day (peak)	Handle bursts of 100 docs/min without backlog	使用性能测试工具批量注入文档。监控 FastStream 队列长度 (MTR-007)。 10分钟平均摄取>100doc/min 时，队列积压 < 100。	队列长度 > 1000 或 ingestion 延迟 > 5min (触发降级L3)	Must	O1 (10 QP
Must-06	**Multi-store Consistency** – 文档/向量/图谱一致性。	0 critical inconsistencies	All ingested data eventually consistent (daily check)	定时运行一致性校验作业：比较 Document总数 vs 向量索引数 vs 图谱节点数。预期差异 <0.1%。有校验失败则记录。	任一一致性校验失败率 >0.1%，或连续2次出现差异	Must	O2 (证 可
Must-07	**Authentication & Session** – 身份认证与会话管理。	MFA & Session control enforced	100% users with MFA; Session idle timeout 30min	安全测试：所有账户均已启用双因素（或设备绑定）；模拟用户30分钟无操作则需重新登录。并发多登录限制3个/用户。	任一账户无MFA激活；或检测到>3并发会话/用户	Must	O3 (安 线)

Rank	Requirement (Measurable)	Target (目标值)	SLO (服务水平)	Measurement (度量方法)	Alert Threshold (告警阈值)	Priority	Tra OK
Must-08	**Authorization & RBAC** – 角色权限与隔离。	Strict tenant & role isolation	0 cross-tenant data leak incidents	渗透测试尝试越权访问他人数据全部失败。RBAC矩阵测试覆盖Viewer/Analyst/Admin权限边界无漏洞。	发现任何越权成功案例（立即严重告警）	Must	(基规
Must-09	**Rate Limiting & Anti-abuse** – 速率限制与防爆破。	Login attempt lockout ≤5; API QPS limit per key	Brute force detection in place	安全测试：尝试连续10次密码错误，第6次起返回验证码或锁定（代码1004）。API按token限流每分钟<60，超限返回429。异常地理登录检测启用（如异地短时多次登录）。	任一账户爆破尝试未被锁定；或IP请求异常无告警	Must	O4 (安健)
Must-10	**Transport Encryption** – 传输加密。	100% of external connections TLS-protected	TLS (or equivalent) enforced, no plaintext	定期扫描服务端口，验证TLS配置（最低TLS1.2，无弱算法）。抓包检查无明文敏感数据传输。	发现任何明文传输敏感数据；证书过期/弱配	Must	O2 (数规)
Must-11	**Audit Logging & Non-repudiation** – 审计日志防篡改。	100% critical ops logged w/ integrity chain	All admin actions & sensitive events auditable	检查AuditLog记录：策略发布、数据删除、权限变更等敏感操作均有日志，字段齐全【B-05】。日志存储带哈希链校验，验证最近N条日志完整性。	缺少关键操作日志；或日志篡改校验失败	Must	O2 (可
Must-12	**Sensitive Data Masking** – 日志敏感信息屏蔽。	0 plain secrets in logs	No passwords/ API keys in any log	自动扫描日志样本，如认证Token、密码等pattern无匹配。审计抽查开发日志文件。	发现敏感数据明文出现（立即安全漏洞处理）	Must	O2 (安规)
Must-13	**Tracing Coverage** – 分布式链路追踪覆盖率。	≥ 95% core transactions traced	All core flows have trace spans w/ trace_id	监控 MTR-016 (TraceCoverage)：每小时计算有完整trace_id的请求占比。核心链路（ingest, query）应≥95%请求有完整span序列（从入口到各服务）。	Trace覆盖率 <90% 持续>1小时	Must	O1 (降诊

Rank	Requirement (Measurable)	Target (目标值)	SLO (服务水平)	Measurement (度量方法)	Alert Threshold (告警阈值)	Priority	Tra OK
Must-14	**Monitoring & Alerts** – 监控与告警配置。	All SLOs monitored; alerts on breach	100% SLO metrics have alerts	核对所有NFR/SLO对应MTR指标均已在监控系统配置告警策略。如P99延迟、成功率、队列长度、存储容量等。定期演练告警触发（每季度SLA压力测试）。	发现未配置告警的关键指标；告警漏报	Must	O1 O2
Must-15	**Disaster Recovery (RPO/RTO)** – 灾备恢复目标。	RPO ≤ 1h; RTO ≤ 4h	Worst-case <1h data loss, <4h downtime	定期演练容灾：模拟数据中心故障，启动备用节点/从备份恢复数据，记录RPO/RTO。要求所有数据（数据库、索引等）按小时增量备份，备库延迟<1h。	RPO或RTO演练结果超标；未每季度执行演练	Must	O2 (可
Must-16	**Supply Chain Security** – 供应链安全合规。	SBOM for 100% components; signed releases	All deps scanned, no critical vulns at release	CI集成Dependency Check，阻止高危漏洞构建。每次发布生成SBOM清单并验证镜像签名。变更审计包含依赖新增/升级审批记录。	构建报告存在未审计依赖；已知高危漏洞未修补	Must	O2 (安 规)
Should-01	**Cold Query Performance** – 冷数据查询性能占比控制。	≤ 5% queries hitting cold tier	Cold query ratio ≤5% (monthly)	监控 MTR-015 (ColdQuery%)：根据查询时间范围标签判断命中冷存储的比例。若>5%，提示需要扩容热存储或调整留存策略。	冷查询占比连续三月>5%（影响成本或性能）	Should	O5 本
Should-02	**Mobile Web Performance** – 移动端性能。	Mobile page load ≤ 5s on 4G (P90)	P90 mobile landing page <5s	使用真实设备或Lighthouse模拟测试移动端首次加载时间。合格标准：P90 ≤ 5s，主要交互可在3s内响应。	移动端性能评分 < 80/100 或明显慢于桌面端	Should	O3 (用 验)
Should-03	**Contract Compliance** – 模块契约遵从。	0 critical contract violations	All inter-module interfaces per spec	CI静态检查与集成测试：所有微服务API/Schema按照合同定义字段，无擅自增加未记录依赖。监控运行日志，检查是否有频繁的合同字段缺失/格式错误异常。	发现未经合同定义的调用或字段异常日志	Should	O2 (可

Rank	Requirement (Measurable)	Target (目标值)	SLO (服务水平)	Measurement (度量方法)	Alert Threshold (告警阈值)	Priority	Tra OK
Should-04	**Backward Compatibility** – 向后兼容性。	0 breaking changes without versioning	Non-breaking changes or versioned updates	变更管理流程：任何对外API/DSL/数据格式变更均采用向后兼容方式或提升版本号。验证：对比v3.0用例结果与v3.1系统，旧用例依然通过率≥98%。	用户升级到新版本后出现批量兼容性错误	Should	O2 (可

8. Data Governance（数据治理）

系统需对各类数据实行**分级存储、保留与删除策略**，并确保删除可审计、可恢复（在限定范围内）。下表列出了主要数据类型在不同存储层级的保留期限、删除SLA、恢复策略等。所有删除和恢复操作均记录审计日志，包括发起者、时间、影响范围等【B-05】。

Data Type (数据类型)	Storage Tier (存储层级)	Retention Period (保留期限)	Delete SLA (删除执行时间)	Restore Policy (恢复策略)	Audit Fields (审计记录字段)	Tenant Scope (租户范围)
Document Content 文档内容及元数据	Hot (在线索引)	6 个月 (热存储，高频检索)	T+1 天内清除 (超过保留期或收到删除请求后24小时内)	不可恢复 (删除为不可逆操作，只有备份留存期限内可用于灾难恢复)	doc_id, title, delete_initiator, delete_time (删除时间), trace_id	Per-tenant（各租户互隔）
Document Content	Warm (近线压缩)	18 个月 (温存储，中频访问)	超期1周内批量删除 (定期归档作业每周清理过期温数据)	灾难恢复用 (温层数据有离线备份，可用于全库恢复，不提供单文档恢复)	job_id (归档作业ID), archived_by, archive_time (归档时间)	Per-tenant
Document Content	Cold (归档/离线)	5 年 (冷存储，低频访问，可选离线介质)	超期1月内删除 (每月归档作业检查并清理超过5年的归档)	需审批恢复 (归档数据下线后若需访问，需要治理官审批并从离线备份中人工恢复至温层)	archive_id, restore_requestor, restore_time (恢复提取时间)	Per-tenant
Search Index Structures 全文检索索引	Hot (在线)	6 个月 (与热文档同步)	文档删除后同步删除索引 (实时)	不可单独恢复 (需依赖对应Document恢复重建)	doc_id, index_segment_id, operation (delete/index), trace_id	Per-tenant

Data Type (数据类型)	Storage Tier (存储层级)	Retention Period (保留期限)	Delete SLA (删除执行时间)	Restore Policy (恢复策略)	Audit Fields (审计记录字段)	Tenant Scope (租户范围)
Vector Index 向量索引	Hot (在线)	6 个月 (同步 Document 生命周期)	文档删除后同步向量删除	不可单独恢复 (需 Document+模型重新向量化)	doc_id, vector_id, operation, trace_id	Per-tenant
Knowledge Graph Data 知识图谱数据	Hot (在线图数据库)	实时更新，逻辑删除跟随文档删除	文档删除触发相关节点/边删除 (实时或批处理)	可通过Refine重建 (如误删可跑离线重建流程恢复图谱一致性)	entity_id, edge_id, operation, trace_id	Per-tenant（注：Ontology节点为全局只读）
PersonaSnapshots 人物/账号快照	Warm (时序库 ArcticDB)	≥ 8 年 (支撑长期回溯分析)	租户注销或策略要求可删除特定Persona全序列 (<7天)	部分恢复 (如因错误删除，可从周期备份中恢复最近一次全snapshot，无法逐条恢复细节)	persona_id, snapshot_count, delete_initiator, trace_id	Per-tenant
SocialPosts 社交帖文内容	Hot (直接 Document 形式存储)	6 个月热，6-18 个月温，同 Document 策略	同 Document (贴文作为文档处理)	同Document	(同Document审计字段)	Per-tenant
AccountProfile 账号画像	Hot (文档+图谱+快照组合)	最新状态永久保留，历史指标快照≥8年	用户/租户请求删除则立即删除 (24h内)	部分恢复 (删除租户后一般不恢复，账户误删可联系管理员7天内恢复)	account_id, profile_version, delete_actor, trace_id	Per-tenant
PolicyBundle & History 策略包及历史版本	Warm (配置库)	历史版本至少保留 1 年 (便于审计和回滚)	策略版本不可删除 (除非归档超过1年，由治理官手动归档)	可恢复 (策略可随时回滚至历史版本；已归档策略需管理员导入恢复)	policy_version, changed_by, approved_by, timestamp	Global (全局统一策略)
Report Templates 报告模板	Warm (模板库)	永久保留 (除非替换/废弃)	管理员删除时立即删除 (24h内)	可恢复 (已删除模板30天内可从备份恢复)	template_id, deleted_by, delete_time, trace_id	Per-tenant (租户可有自定义模板)

Data Type (数据类型)	Storage Tier (存储层级)	Retention Period (保留期限)	Delete SLA (删除执行时间)	Restore Policy (恢复策略)	Audit Fields (审计记录字段)	Tenant Scope (租户范围)
Exported Reports 导出报告文件 (PDF)	Warm (文件存储)	90 天 (报告文件留存供下载)	到期自动删除 (每周清理超过90天文件)	可再生成 (如需旧报告，可利用报告元数据重新生成PDF)	report_id, generated_by, delete_time, trace_id	Per-tenant
Audit Logs 审计日志	Warm (审计库，不可改)	≥ 1 年 (或按合规要求，可配置)	不允许主动删除 (除非租户注销，按法规可要求删除部分记录)	不可修改或部分恢复 (日志防篡改，只可整体归档备份保留)	log_id, tenant_id, action_type, actor, timestamp, integrity_hash	Per-tenant (按租户隔离查询访问)
System Metrics 系统监控指标数据	Warm (时序数据库)	13 个月 (用于同比分析)	自动滚动删除旧指标 (超期数据自动丢弃)	无需恢复 (统计指标可不恢复)	(由监控系统自身审计)	Global (跨租户汇总)
Raw Crawl Data 原始抓取页面	Temp (临时存储)	7 天 (解析后即删除，仅短暂保留)	每日自动清理7天前raw数据	不提供恢复 (解析失败可重新抓取而非恢复raw)	source_id, crawl_id, fetched_time	Per-tenant
Prefetch Cache 翻译/分析缓存	Temp (内存/缓存)	根据LRU，约 7 天有效	内存缓存自动淘汰，不做专门删除	不适用	(无持久操作)	Per-tenant
Task Queues 任务队列持久化	Hot (消息日志)	仅实时 (任务完成即意义消失)	任务完成后立即从队列移除	不适用（未消费消息持久化日志供灾难恢复，但任务本身不恢复）	message_id, status, attempted_count, last_error	Per-tenant (队列隔离)
User Accounts & Roles 用户账号及角色	Warm (用户目录)	永久保留 (除非用户注销或租户注销)	用户主动注销后7天内删除所有个人数据	租户管理员30天内可撤销误删 (标记删除延迟30天执行)	user_id, tenant_id, delete_request_time, delete_exec_time, trace_id	Per-tenant

- **租户注销处理**：当租户合同结束或要求删除所有数据时，系统将在确认后触发**租户数据删除流程**。该流程遍历上述所有与该租户相关的数据类型，执行删除操作，并在审计日志中生成**删除证明**（Deletion Certificate），列明删除发起者、租户ID、删除的数据类别清单、完成时间等，以证明符合数据擦除要求【Fix Plan 10】。删除流程目标在7天内完成全部数据清除；删除证明将提供给租户作为合规凭证。
- **数据删除审计**：每一次人工或策略触发的数据删除操作（例如Admin删除某项目数据、用户注销）都记录在AuditLog，并包含 `trace_id` 及 `audit_id`，可用于事后核查。任何自动删除任务失败（如定时清理因服务故障未运行）将告警运维，确保不遗留超期数据。

- **数据恢复限制**：一般情况下，按设计**不支持细粒度数据恢复**（删除即不可逆）。仅在灾难恢复场景下才使用备份。对于用户请求误删的重要数据，需在备份保存期内，由超级管理员特别审批并执行全库恢复再导出所需部分，再进行局部导入等极高难度操作，流程需谨慎评估风险。

9. Acceptance Plan（验收计划）

为确保系统达到上述需求，制定以下验收测试计划。测试覆盖功能正确性、性能、故障恢复和安全等维度，分阶段进行，每阶段必须通过所有P0用例及指标验证才能进入下一阶段。

Phase 1 – Core Functionality & Performance (Alpha)

- **基本功能测试**：验证主要用例端到端流程正确。例如执行UC-001~UC-004，人工检查输出是否符合预期（结果相关性、证据链完整）。特别验证5分钟管道：采集模拟新文档，计时直到可检索，对比是否<5min。
- **性能基准测试**：对关键指标进行基准压测：100QPS查询（Mix读），100 docs/min 摄取，检查系统无错误且延迟满足NFR Must-01~05目标。若未达到，调优后重测。
- **多租户隔离用例**：设计跨租户攻击场景，用不同租户账户尝试访问彼此数据（包括直接API调用/前端绕过）。预期均失败或返回空数据（FR-004）。测试租户A高负载下租户B查询延迟不受显著影响。
- **降级演练**：人为制造超负载使系统进入L2/L3，观察降级行为：非关键功能暂停，提示信息出现，核心查询持续可用。然后解除负载，确认系统自动恢复正常。记录积压处理耗时，验证符合FR-017矩阵要求。

Phase 2 – Reliability & Security (Beta)

- **故障注入测试**：在测试环境对不同组件注入故障：如关闭向量服务、使索引服务超时。验证系统能相应降级或重试：查询有降级结果或返回明确错误码，不导致崩溃。检查对应告警是否触发（如索引失败触发运维告警）。
- **恢复能力测试**：模拟数据库或节点故障，启动灾备方案：在备机恢复数据库或切换索引备份。目标RTO<4h，RPO<1h（NFR Must-15）。演练结果出具报告，若超标需改进策略再测。
- **数据保留与删除验证**：创建测试租户插入已知数据，然后触发租户删除流程。验证7天内该租户数据全部无法访问，审计日志生成删除证书。再次尝试以trace_id找数据应无结果。对于保留期策略，修改系统日期模拟数据过期，运行清理任务，看是否如期清除。
- **安全渗透测试**：聘请安全团队对系统进行穿透测试，包括：尝试绕过身份认证、越权访问API、SQL注入、XSS等。重点验证NFR Must-07~09、12是否达标：比如连续密码猜测5次被锁定，日志无敏感信息暴露等等。所有发现的问题必须修复并再次测试确认。
- **审计与追溯测试**：随机抽取几项关键操作（如策略发布、数据删除、报告导出），在AuditLog查询记录，核对字段信息正确。如策略发布记录包含version、approver等，与实际一致。尝试篡改AuditLog（if possible），验证篡改被检测拒绝。整个审计链路应闭合可靠。

Phase 3 – Full System & Scale (Release Candidate)

- **长时间稳定性**：在接近生产的数据量和负载下跑持续72小时，观察是否有内存泄漏、队列堆积、崩溃等。要求无未处理异常日志，无服务重启。关键指标波动在正常范围（如GC引起的响应抖动<5%）。
- **全量业务场景模拟**：以真实使用方式模拟多个租户并发操作：有人发起研究（UC-001），同时爬虫在跑（UC-004），Admin发策略（UC-008），Analyst导出报告（UC-007）等。确保各模块互不干扰或死锁。系统日志trace能串起跨模块完整链路用于排障。
- **容量测试**：逐步增加负载直到系统性能接近极限，找到瓶颈点。确保在达到要求容量前系统表现线性，可用性不下降。超出能力时触发告警与降级而非无序崩溃。记录最大支持值，为弹性扩展提供依据。
- **回归验证**：针对RSv3.0的所有已通过用例再次在v3.1执行一遍，确认新版本改动未引入回归bug（NFR Should-04）。特别验证FR-008跨语言这次精细实现后，旧的单语言查询结果未受负面影响。

- **用户验收**：邀请典型Persona试用系统Alpha/Beta版本，收集反馈。确保UI语言切换、移动端使用等体验良好，无重大易用性问题。收集的改进点转为任务进一步优化后再最终发布。

每一阶段结束时，将召开ARB评审检查需求验收矩阵，核对所有 FR/NFR 是否都有对应测试通过证据。对于未通过项，进入缺陷修复和重新测试循环，直至全部指标满足。最终在Release阶段，还需进行合规审核（安全、数据隐私）和性能签-off（基于上述测试报告），然后才可上线。

10. Risks & Mitigations（风险及对策）

本章节枚举系统已识别的主要风险点及应对方案。所有风险需定期review，确保缓解措施落实并在验收和演练中验证有效。

- **R-01 数据泄露风险**：多租户数据隔离和权限控制不到位可能导致未经授权的数据访问。缓解：严格RBAC实现（FR-004/FR-008），定期进行权限渗透测试；AuditLog审计所有访问，配置异常访问告警（NFR Must-08）。一旦发现越权行为立即封禁相关账户并全面审计访问影响范围。
- **R-02 对抗攻击漏报**：高级对抗性内容手段可能绕过现有检测算法，系统未能告警。缓解：采用多模检测（文本模式+行为模式）；Low级别告警允许一定漏报，但持续优化阈值（在运营中调整KR2指标）。另外建立人工举报渠道和定期样本回顾机制，不断补充训练检测模型。
- **R-03 告警误报过多**：如果系统告警规则过于敏感，产生大量误报（尤其低级告警），可能导致用户忽略真正风险。缓解：设置告警抑制和合并策略（FR-016 Failure Handling），确保误报率<5%。引入反馈机制：GOV人员可标记误报并调整策略。对持续误报的规则暂停触发，进入策略Bundle改进循环。
- **R-04 降级策略失效**：若降级触发条件或恢复机制设计不当，可能导致高负载下系统仍崩溃或降级后无法自动恢复。缓解：严格测试FR-017矩阵在各种场景的有效性（见Acceptance Plan Phase1&3）。特别检查滞后阈值避免频繁抖动。每季度进行压力演练验证降级和恢复流程，并根据演练结果调整阈值配置。
- **R-05 关键数据丢失**：数据库或索引损坏导致无法恢复部分数据，或意外删除未备份就无法找回。缓解：实施完善备份策略（NFR Must-15），所有存储数据每日快照+增量备份。对于用户手动删除行为，设置“软删除+延迟”机制（见数据治理恢复策略），短期内可撤销。定期演练灾难恢复流程，确保备份可用且人员熟练操作。
- **R-06 第三方依赖失效**：依赖的外部组件（如翻译服务、爬虫框架）性能或可用性不达标，拖累系统。缓解：对关键依赖设定监控和fallback：如翻译服务超时则降级仅返回原文证据；爬虫框架崩溃则暂缓采集并告警。选择成熟组件并保留替代方案（例如内置基础翻译模型在外部API不可用时启用）。签订服务SLA确保外部依赖可用性，定期review版本升级。
- **R-07 隐私合规风险**：处理公众社交数据和跨境数据需遵守隐私法规。如未满足删除请求或越界收集个人敏感信息可能违法。缓解：严格执行数据治理策略，对用户/租户数据删除请求及时处理并提供证明（Fix Plan 10）。设计系统时默认不采集个人敏感数据（PII）；如必须，获取明确授权并提供数据导出/删除机制。法律团队审核采集清单，确保符合法规。
- **R-08 用户端安全风险**：包括XSS注入、点击劫持等前端安全问题。缓解：前端严格转义输出内容（特别是证据文本中包含HTML时），设置Content Security Policy (CSP) 防止外部脚本注入；关键操作（如删除数据）需二次确认和CSRF防护token。定期进行前端安全扫描。已经在NFR Must-09等覆盖登录安全，仍需注意UI层的其他攻击矢量。
- **R-09 性能瓶颈转移**：优化某部分性能可能把瓶颈转移到另一部分（例如5分钟管道达标但可能导致查询延迟上升）。缓解：全链路性能监控（Tracing + Metrics），一有瓶颈位移苗头及时发现。每次性能优化后重做全局基准测试。采用容量模型预估各组件负载平衡，不以牺牲一端性能换另一端指标，通过水平扩展整体提升。必要时调整OKR权重，务求系统均衡。
- **R-10 模型或规则偏差**：AI方法（如可信度模型、摘要算法）可能存在偏差，影响输出质量或公正性。缓解：在多语言东北亚场景下对模型进行专项评估和调优，收集不同语种/立场的样本确保公平。引入校验环节：高风险输出须人工审核；对外输出附证据让用户自行判断。长期而言建立模型反馈闭环，用用户校正不断减少偏差。策略层面，如发现模型输出系统性错误，可快速通过PolicyBundle禁用该模型并回滚上版本。

- **R-11 未知需求或超范围**：一些隐含或后期才浮现的需求没在RS中明确，导致上线后功能缺失或不满足用户期望。缓解：在Open Questions中列出不确定事项，并尽快在开发过程中澄清并纳入范围（通过CR变更流程）。在Scope明确出不做移动原生App等，以防误解。同时保持敏捷迭代，一旦发现需求缺口，以迭代方式快速补充交付，避免长期留下空白。
- **R-12 合规审核未通过**：上线前需通过安全、合规等检查，如果RS要求不全导致后期整改。缓解：在RS阶段已尽量覆盖安全审计要求（FR-004、NFR Must-07~12等），并邀请合规团队review RS。于Beta测试阶段就让安全团队进行渗透和代码审计，提前发现问题。确保所有必要文档（SBOM、安全设计、用户协议）齐备，使最终审核顺利。

11. API & Schema Contracts（契约集）

本章定义系统内外各主要接口和数据模式契约。每个契约以 **C-###** 编号表示，其字段名、类型及约束要求如下。除特别说明，每个接口响应均包含通用字段 `trace_id` 以关联日志，所有契约变更需遵循向后兼容或版本升级策略。

C-001: Document (内容文档对象)

描述系统标准化后的文档数据结构，涵盖原始内容及处理状态等字段。

Field	Type	Description (含义)	Constraints (约束)
doc_id	string	文档唯一ID（UUID）	只读，系统生成，全局唯一
source_id	string	来源标识（数据源/网站/平台 ID）	必填，指向 Source 列表的唯一值
title	string	标题	可选，对于无标题文本可为空；Max length 500 chars
author	string	作者/发布者	可选，未提取到则为空
content	string	正文全文文本	必填，UTF-8文本；若过长可截断但需保留前N字符供检索
published_time	datetime	内容发表时间	可选，格式 ISO8601；解析不到则为空但字段必须存在
lang	string	语言代码（例如 "zh", "en"）	必填，ISO-639-1代码；未知时可填 "unk"
content_hash	string	内容指纹（用于去重）	必填，SHA-256 或类似哈希；全局范围近似唯一（碰撞概率极低）
ingestion.received_at	datetime	系统接收时间戳（进入Ingestion队列时刻）	必填，记录Pipeline开始时间，ISO8601毫秒精度
index.search_ready_at	datetime	可检索就绪时间戳（完成索引写入）	可选，完成全文索引时设置；未索引则为空
analysis.ready_at	datetime	分析完成时间戳（完成向量/图谱等）	可选，完成全部analysis时设置；未完成则为空
indexed	boolean	是否已建立索引可检索	必填，true当且仅当 index.search_ready_at 非空

Field	Type	Description (含义)	Constraints (约束)
analysis_ready	boolean	是否已完成分析	必填，true当且仅当analysis.ready_at 非空
credibility_score	float	可信度评分（0~1, 1最高可信）	必填，经常用0.0表示未知；analysis阶段计算
processing_error_code	string	处理错误码	可选，若解析/索引/分析失败则记录错误码；未出错为空
retention_class	string	保留类别（例如"hot", "warm", "cold"）	必填，热温冷标记；根据创建时间系统自动设定，可用于筛选
tags	list<string>	标签列表（主题、类别）	可选，由分析生成；每项Max length 100
tenant_id	string	租户ID	必填，用于多租户隔离；系统生成绑定
trace_id	string	跟踪ID（用于关联请求链路）	可选，在上下文请求中填充；写数据库不强制

Notes: - Document 是内部统一的数据载体，也是对外搜索和导出结果的基础对象。它通常不直接通过API暴露全部字段（例如content全文仅内部存储），对外查询结果出于效率会提供摘要或高亮片段。 - `content_hash` 用于幂等：系统摄取时计算，若已有相同hash的Document（在同一租户范围），则视为重复内容（FR-005），新的不会创建。 - 时间戳字段 `ingestion.received_at` 由Ingestion服务写入；`search_ready_at` 由索引服务完成后写入；`analysis.ready_at` 由analysis流程最后一步写入。它们用于计算管道延迟（用于指标MTR-001等）。 - `credibility_score` 由可信度算法模块写入，默认0.5起步，后续演化。score分解细节不存于Document而在其他结构（如Audit或Alert中risk_factors）。 - Document 对象部分字段（title/content等）可能包含敏感信息，应遵循安全NFR，如日志不打印全文等。对外接口在返回Document内容时，必须依据权限过滤敏感字段或摘要处理。 - Document 没有版本号字段；Schema演进通过在C-001定义新字段实现，尽量向后兼容。若重大不兼容需升级API版本。 - 幂等性：重复内容通过content_hash避免重复存储。ReportJob等异步任务引用doc时可利用doc_id进行幂等处理（同一doc不会重复处理）。

C-002: Project (项目空间对象)

表示租户内的具体项目或主题空间，用于将数据/用户分隔在项目级。

Field	Type	Description	Constraints
project_id	string	项目唯一ID	必填，UUID格式，全局唯一
name	string	项目名称	必填，1-100字符；同一租户下唯一
description	string	项目描述	可选，0-500字符
tenant_id	string	所属租户ID	必填，指向Workspace租户；创建后不可更改
members	list<Object>	项目成员列表，每项包含 user_id 和 role	可选，可为空（无成员表示仅租户管理员可见）；role 必为 {"Viewer","Analyst"} 等

Field	Type	Description	Constraints
created_at	datetime	创建时间	系统自动生成，ISO8601
created_by	string	创建者 user_id	系统自动填充
last_modified	datetime	上次修改时间（包括成员/描述变更）	系统自动更新
trace_id	string	跟踪ID（操作此项目的请求链trace）	可选，由操作API携带用于审计

Notes: - Project 用于业务逻辑隔离，Persona-AN通常在某个项目下开展研究，数据（如文档、RecCard）默认归属项目。Project下的成员拥有对应角色权限。 - `members` 字段可视为Project与User的多对多关系。由于User信息主要由外部IdP管理，此处仅存引用ID及项目内角色。添加/移除成员通过专门API（Update Project Membership）。 - 项目隔离：用户查询或操作须显式或隐式限定project范围。系统会将project_id作为过滤条件应用于搜索等。多租户隔离通过项目的tenant_id进一步保证，不同租户的project不会混用数据。 - Dependencies: Workspace(tenant)在Project上层，One Workspace 可有多个 Projects。若未来有层级（如Folder），可扩展父项目ID字段，目前无。 - 幂等性：创建项目API如重复调用，需检查名称唯一性，返回已有项目或错误，以免重复。members管理操作通过 user_id 幂等（重复添加相同用户无副作用）。 - Trace: 对项目的创建/修改在AuditLog记录trace_id，便于审计谁创建了项目、何时修改成员等。

C-003: Search Result (搜索结果项)

表示搜索API返回的单条结果及相关信息。

Field	Type	Description	Constraints
doc_id	string	命中文档ID	必填，Document.doc_id
title	string	文档标题	可选，为提升性能可能预先存储或截断，不超过200字符
snippet	string	内容摘录片段，用于显示高亮	可选，通常100~200字符，包含查询关键词高亮标记
score	float	匹配分数	必填，用于排序的相关性/评分值，范围0~N（非归一）
source	string	数据源或来源标识，用于告知结果来源	可选，如 "Twitter" 或 "BBC" 等；UI可用于过滤
published_time	datetime	原文发布时间	可选，ISO8601；无则空
lang	string	文档语言	必填，同Document.lang
highlight_fields	list<string>	高亮字段列表	可选，列出在哪些字段命中查询（如["title","content"]），UI可据此决定展示策略
trace_id	string	跟踪ID	必填，传入查询请求的trace_id原样返回，以关联日志

Notes: - SearchResult 主要用作Search API响应中的 result 列表元素。它不呈现全文，仅提供基本展示需要的信息。`title`和`snippet`通常预先从索引获取（由搜索引擎返回）。 - `snippet` 字段可包含标记（例如

`<em>` 标签）突出匹配关键词。调用方UI负责渲染。若查询DSL指定只返回IDs（如用于程序用途），可以通过API参数关闭snippet，以节约带宽。 - `score` 没有绝对标准值，不同检索层的结果score不直接可比，因此EvidenceFusion对跨层结果score进行归一排序后才产生最终顺序。对于基本搜索API，score可以是全文检索的BM25值或综合分值，仅用于前端排序展示。 - `source`: 如果数据源种类繁多，此字段可帮助用户了解结果来源类别。由Document.source_id映射或截取而来。 - 执行限制（Search API QoS）: - **Timeout**: 搜索请求服务端超时时间一般设为3~5秒，超时返回错误码**5100 SearchTimeout**。同时前端查询可配置更短超时以中止等待。 - **Paging**: 为避免深分页高成本，Search API仅支持前N（如1000）条结果的分页（每页默认10或20）。如请求超过允许范围，返回错误码**1102 QueryTooBroad** 或空结果。 - **Complexity**: DSL禁止某些高成本操作，如通配符前缀搜索或正则全文扫描。若检测到，直接拒绝执行，返回错误**1101**语法错误或**1102**非法查询，提示用户简化查询。具体黑名单操作在Query DSL规范中定义。 - **Rate Limiting**: 对每个API key或用户实施QPS限制（NFR Must-09），超过则返回HTTP 429 + 错误码**1005 TooManyRequests**，`retry_after`头指示等待时间。 - 错误码方面，Search API错误主要有: - 参数无效（如不支持的filter）→ 1101/1102, - 无权限（跨租户project）→ 1003, - 内部错误如索引服务失联 → 1300 DependentServiceError, - 超时 → 5100。 这些在第13章汇总。

C-011: Query DSL Specification (检索DSL规范)

定义搜索查询DSL的语法范围和参数接口（非严格模式语法，用描述辅以示例）。

- **Basic Keyword**: 输入无特殊符号默认进行全文关键字搜索，支持空格分词+布尔操作。例如查询 `北韩 导弹` 返回含“北韩”和“导弹”的文档。默认AND关系，可用 OR/NOT 明确逻辑：`北韩 OR 朝鲜`。
- **Phrases**: 使用引号表示精确短语匹配：`"对抗 攻击"` 找包含该确切短语的文档。
- **Field Filters**: 使用 `field:value` 形式限定字段匹配。支持字段：
- `title:` 限定标题，例：`title:疫情`
- `content:` 限定正文（默认字段，一般不必显式）
- `source:` 限定来源ID/名称，例：`source:Twitter`
- `lang:` 限定语言，例：`lang:en`
- `author:` 限定作者
- `entity:` 指定必须包含某知识图谱实体（见下Graph语法）
- `date:` 时间范围筛选，格式 `date:start~end`，支持yyyy或yyyy-MM-dd。例：`date:2020-01-01~2020-12-31`
- **Cross-lingual**: 设置 `lang:` 字段或用户profile语言与文档不同，系统自动翻译查询并查询双索引。DSL层面对用户透明，无需特殊语法。用户也可明确如 `lang:zh` 来限定中文内容或force查询中文库。
- **Graph Constraints**: 提供限定需匹配知识图谱关系的语法，如：
- `entity:"金正恩"` 限定文档涉及该实体（金正恩作为图谱节点）。
- 高级：`entity:Kim-Jong-Un->EventType:MissileTest` 表示涉及金正恩且关联事件类型为导弹试射。（注：此类复杂语法需要Graph支持，目前支持简化版）。
- 如果非法或不支持（例如图谱库不含该关系），将返回DSL错误。
- **Vector Semantic**: 用户无法直接提供向量，但可使用特殊操作表示语义搜索：
- 例：在查询词前加 `~` 表示语义扩展，例如 `~网络攻击` 会在内部通过Embedding寻找语义相关内容而非字面匹配。
- 实现上Planner检测到 `~` 前缀则走向量检索，将去掉 `~` 后的词通过embedding查询，同时仍可混合其他条件。
- **Logical Grouping**: 使用括号组合布尔子表达式，如 `(北韩 AND 核) OR 朝鲜`。
- **Escape & Special**: 保留字符包含冒号、引号、波浪号等，如要搜索这些字符本身需要转义 `\:` 等。停用词（如中文的“的”，英文的“the”）默认会被搜索引擎忽略。

Illegal Syntax & Errors: - 语法解析采用自定义或Lucene标准语法，出现未闭合引号、括号不匹配、未知字段名等皆视为语法错误，抛出错误码 **1101**（Bad Query Syntax）并在 message 中指出错误位置。 - 使用不支持的字段或操作，返回 **1102 QueryNotSupported**。例如 `regex:.*abc.*`（如未开放正则）。 - 查询过于宽泛

没有任何限制（如只输入 `*` 或 `a OR b OR c ...` 匹配所有文档），可拒绝执行返回 **1102**，避免全库扫描【B-05 第3点】。 - 长查询串（超过最大长度如1000字符）拒绝，返回 **1102** 提示简化查询。

Versioning: - 当前DSL版本 v1。如将来扩展新操作（如Graph pattern），DSL字符串中可支持 `version:2` 前缀或按API参数指定version=2，确保旧客户端用旧语法请求不会误解析为新含义。 - 非兼容更改必须通过版本位控制，不静默改变既有语义。

Request/Response Structure: - Search API `GET /search?query={q}[&project_id=..][&page=..]`: - 输入参数：`query`（URL编码后的DSL字符串），`project_id` 选填（缺省则默认当前用户项目），分页参数如 `page=2` & `page_size=20`。 - 返回JSON包括：`results` 列表（SearchResult对象数组，见C-003），`total` 总命中数，`page` 当前页码，`page_size` 本页结果数，`trace_id`。 - 另有 `degrade_level` 字段当系统在L2/L3降级时提示结果可能不完整或延迟。 - Post搜索API则可在Request JSON中提供更复杂结构，但目前GET足够，如需支持，另行定义。 - **Example**: 请求：`GET /search?query=title:"网络攻击" AND date:2021~2022` 响应：

```
{
 "results": [
  {
   "doc_id": "abc123",
   "title": "2021年发生的主要网络攻击事件",
   "snippet": "...发生了<em>网络攻击</em>的事件...",
   "score": 12.5,
   "source": "GovNews",
   "published_time": "2021-12-01T...Z",
   "lang": "zh",
   "highlight_fields": ["title","content"]
  },
  ...
 ],
 "total": 42,
 "page": 1,
 "page_size": 10,
 "trace_id": "..."
}
```

- **安全**: DSL输入将进行安全过滤：防止利用DSL构造潜在开销极大的查询或调用未授权数据。已限制pattern如 `source:*`（匹配所有源）不允许；针对SQL注入等无直接关系因DSL不直通数据库，但仍会净化特殊字符避免冲击解析器。

C-012: PolicyBundle (策略包配置)

封装一组治理策略规则及元数据，用于统一发布和版本管理。采用JSON结构（或YAML）储存配置。

主要字段（示例表示）：

```
{
 "policy_version": "v3.1",
 "created_at": "2025-12-15T10:00:00Z",
 "created_by": "user_123",
```

```
  "approved_by": "user_gov1",
  "description": "调整检索过滤和告警阈值",
  "rules": {
   "search_filters": [
    {"pattern": "source:weibo", "action": "EXCLUDE", "comment": "暂不检索微博源"}
   ],
   "evidence_fusion": {
    "max_evidence": 5,
    "fulltext_verify_high_risk": true
   },
   "alert_thresholds": {
    "AdversarialAlert.LOW": 0.8,
    "AdversarialAlert.HIGH": 0.95
   },
   "degradation": {
    "L1": {"trigger": {"queue_latency_ms": 1000}, "features_off": []},
    "L2": {"trigger": {"queue_latency_ms": 5000}, "features_off": ["deep_analysis"]},
    "L3": {"trigger": {"queue_length": 10000}, "features_off": ["new_ingest","reports"],
"notify_users": true}
   }
  },
  "rollout": {
   "mode": "immediate",
   "start_time": "2025-12-15T10:05:00Z",
   "progressive_percentage": null
  }
 }
```

字段说明：

- **policy_version** (string): 策略版本号，人可读格式如 "v3.1" 或时间戳ID。必须唯一，不可更改。
- **created_at/created_by**: 创建时间及创建人（治理官）。
- **approved_by**: 审批人ID（若流程需要审批）。
- **description**: 本次策略变更描述。
- **rules**: 策略规则集合，内含若干子配置：
- `search_filters`: 检索过滤规则数组。每项可定义pattern(如source:XXX)和动作(EXCLUDE/INCLUDE/BOOST等)。用于RMS在Query Planner阶段按策略筛除或加权结果。
- `evidence_fusion`: 证据融合参数，如最大证据条数、High风险卡片是否执行fulltext verify等【B-03】。
- `alert_thresholds`: 告警阈值配置，对各类Alert定义触发分数/概率门槛。例如AdversarialAlert不同级别评分阈值。
- `degradation`: 降级策略矩阵配置。定义各L级别触发条件(trigger，可基于Metrics如队列时延/长度、CPU)、关闭的功能features_off列表以及其他行为(如是否通知用户)。对应FR-017矩阵要求，可灵活调整阈值和关停项。
- 其他可能策略：如内容保留策略(已由Data Gov定义，不在此)、或输出审计策略等，当前略。
- **rollout**: 发布选项：
- `mode`: 发布模式 ("immediate"立即全量 / "gradual"灰度 / "scheduled"定时发布)。
- `start_time`: 如果scheduled模式，则何时开始生效。
- `progressive_percentage`: 如果gradual模式，初始应用百分比，之后如何步进（可能定义步长和间隔）。
- 其他参数如`abort_on_error`: 若检测策略引发大量错误是否自动中止回滚等。当前不详尽展开。

- Constraints:
- JSON需通过模式校验：未知字段不允许（避免拼写错误无效化规则）。
- 每类规则的格式如search_filters pattern支持的DSL子集需document。
- `policy_version` 采用只读，由系统分配或唯一性检查。
- `rollout.mode` 为gradual时必须提供progressive策略。
- **Error Handling**:
- 上传策略JSON时系统将校验语法与基本逻辑冲突。如失败返回错误码 **1400 PolicyInvalid** 附详细信息。
- PolicyBundle应用过程中出现规则错误（如引用不存在的数据源ID）将记录warning，不中断发布（或按Need，若严重可中断回滚）。
- **Audit**:
- 审计日志记录策略发布事件，含policy_version、changed_by/approved_by等，以及rollout结果（成功/失败节点列表）。
- 每条策略规则变更应记录在ChangeLog供以后审计。可在PolicyBundle中增加 `prev_version` 引用以链式追踪修改差异。

C-013: AuditLog Record (审计日志记录)

定义审计日志条目数据结构。该结构保证关键信息完整、不可否认且易于查询。

Field	Type	Description	Constraints
audit_id	string	审计记录ID（UUID或递增流水号）	必填，唯一，一般后端生成
tenant_id	string	租户ID	必填，可为“system”表示全局事件
user_id	string	操作者用户ID	必填，系统自动填“system”若为自动任务
action_type	string	操作类型/事件类型代码	必填，预定义类别，如 "LOGIN", "DELETE_DOC", "PUBLISH_POLICY"
target_type	string	目标对象类型	必填，例："Document", "Project", "PolicyBundle" 等
target_id	string	目标对象ID	可选，如有具体对象则填其ID，无特定对象则可为空或none
timestamp	datetime	操作时间（UTC）	必填，ISO8601
success	boolean	操作是否成功	必填，用于记录尝试登录失败等
detail	object	操作详情字段集（根据action不同）	可选，可存放额外上下文，如删除多少条记录、策略版本号等
client_ip	string	操作者IP地址	必填，格式IPv4/IPv6，如通过代理应获取真实IP
user_agent	string	操作者User-Agent字符串	可选，web操作则记录浏览器UA
trace_id	string	关联trace ID	可选，如该操作由某请求触发则填入trace_id
integrity_hash	string	日志完整性哈希	必填，对本条关键字段和前一条hash进行SHA链式哈希

Notes: - AuditLog记录以不可变append-only形式存储。`integrity_hash` = SHA256(prev_hash + current_record核心字段串)实现防篡改链。第一条记录的prev_hash可约定为0值。 - `action_type` 会规范为固定枚举： - 安全类: LOGIN_SUCCESS, LOGIN_FAILURE, LOGOUT, PASSWORD_CHANGE, ROLE_ASSIGN 等 - 数据操作类: CREATE_DOC, DELETE_DOC, UPDATE_PROFILE 等 - 策略类: PUBLISH_POLICY, ROLLBACK_POLICY - 系统类: SCHEDULED_BACKUP, NODE_RESTART 等 - `detail` 字段根据action动态：如DELETE_DOC批量删除时detail可包含deleted_count:100, query_condition 等；PUBLISH_POLICY detail包含 new_version 和 changes 概要。 - 系统所有关键操作必须在逻辑上产生AuditLog：包括所有Admin控制台操作、用户登录/失败企图、策略发布/回滚、数据导出等。甚至自动任务如定期删除也记录为action_type=SCHEDULED_DELETE, user_id="system"。 - AuditLog访问： - Admin/GOV可以按各种字段筛选日志。如查看某user_id全部操作记录、特定时间范围等。 - AuditLog本身受保护，只读不可修改/删除（除非随租户删除要求整体删除部分日志见数据治理）。 - 提供独立查询AuditLog API给治理查看，支持分页按时间倒序等。 - 性能考虑：AuditLog可能增长很大，但主要写为顺序操作，可水平分区按日期或租户。读查询频度不高，不要求实时性，可接受秒级延迟。 - 误差来源：若系统或日志服务宕机短暂期间可能丢失少量日志，需要通过Trace和Metrics互相印证发现异常。一般用本地缓存顺序写磁盘或外部WORM存储以最大化可靠。 - 审计数据也可用于安全监测：通过实时分析AuditLog流，可以发现异常行为模式（NFR Must-09配置的告警如异常登录即基于AuditLog计算）。

C-014: RecommendationCard (推荐卡片对象)

用于输出给用户的结构化分析卡片，包含结论、证据和建议等。

Field	Type	Description	Constraints
card_id	string	卡片唯一ID	必填，UUID，生成时确定
title	string	卡片标题（简述结论或建议）	必填，最长200字符
summary	string	分析摘要/结论	必填，Markdown或纯文本，不超过1000字符
evidence_list	list<EvidenceItem>	相关证据列表，每条证据引用外部内容（Document等）	必填，至少1条；见EvidenceItem结构要求
insight	string (optional)	额外分析见解或备注	可选，用于补充背景，最长500字符
risk_level	string	风险等级/优先级 (High/Medium/Low/None)	必填，枚举值，默认None
risk_factors	list<string> (optional)	风险判断依据要点列表	可选，高风险卡片要求至少列出主要依据1-3条，每条<100字符
recommended_action	string (optional)	建议采取的行动	可选，如 "进一步监控", "人工复核内容", "通知执法部门" 等；无建议可空
timestamp	datetime	卡片生成时间	必填，ISO8601
template_id	string (optional)	使用的卡片模板ID	可选，如不同模板显示不同字段；无特别模板则空

Field	Type	Description	Constraints
trace_id	string	跟踪ID (生成此卡片流程)	必填，关联内部流程trace，用于审计
policy_version	string	策略版本ID (用于审计此卡片生成时所用策略)	必填，如 "v3.1"，对应PolicyBundle版本

EvidenceItem 子结构: （证据条目，内嵌列表）

Field	Type	Description	Constraints
id	string	证据内容ID（Document ID或外部引用）	必填，如为Document取doc_id，如为外部则提供URL
excerpt	string	证据摘录片段	必填，长度50~300字符，突出证据要点，必要时可翻译
source	string	证据来源	必填，如 Document.source 或 URL域名
url	string (optional)	原文链接	可选，若证据可公开访问则提供URL，否则留空/内部链接
relevance	float	与当前卡片主题的相关性评分（0~1）	可选，用于前端排序或标注，取EvidenceFusion输出值

Notes: - RecommendationCard 是面向Persona-DM等用户展示的主要载体，语言上应符合目标语言习惯（已由系统翻译或多语言支持）。 - `risk_level` 为High/Med/Low时，UI通常用颜色或icon突出。None表示无特别风险，仅为普通建议。 - `risk_factors` 主要在High风险卡片出现，列举判断该风险的依据，如 "账号两天新增5万粉丝", "多次发布煽动性内容" 等，让审核者快速理解理由。 - `recommended_action` 字段值建议来自预定义动作表，如 "MonitorClosely", "TemporarySuspend" 等，未来可扩展执行自动化。当前以自然语言短句表述（UI可对应翻译）。 - EvidenceItem: - `excerpt` 通常由EvidenceFusion或摘要算法生成，与查询或主题相关的片段，必要时包含高亮标记。UI应原样显示。 - `id` 是Document doc_id时，UI可提供“查看原文”链接调用检索详情或跳转内容页。如果id非本系统doc，如外部新闻链接，则用url字段供跳转外部。 - evidence_list 顺序按照EvidenceFusion综合评分排序（score可不直接呈现，但通过relevance或UI顺序体现）。 - Contract usage: - RecommendationCard 可能通过API提供给前端列表展示，也可能内嵌于Report导出。因此其字段应自描述完整，不依赖上下文额外数据。 - 生成RecCard的服务要在AuditLog记录trace和policy_version，以追溯推荐为何产生（FR-014证据链+ FR-015风险解释 部分通过risk_factors也体现）。 - Error handling: - 如果RecCard生成遇到缺失数据，例如证据不足无法满足KR1，要么不生成卡片，要么生成但risk_level=None。决策：宁缺毋滥（如果证据链不完整则不生成High风险卡片直接告警Gov人工介入）。 - RecCard内容本身非敏感但涉及决策，应确保推送渠道安全（UI走安全通道，若有邮件要加密或通过安全Portal下载）。 - Template: - `template_id` 预留可能不同展示样式模板的情况。目前大部分卡片统一，用不到。填写有助于PDF报告选择样式如有多个卡片模板存在。

C-015: AdversarialAlert (对抗攻击告警对象)

表示系统检测出的可疑对抗攻击事件，带有详细属性，用于通知治理人员和联动处置。

Field	Type	Description	Constraints
alert_id	string	告警ID（唯一）	必填，格式 "ADV-{日期}-{序号}" 或UUID，一经生成不变

Field	Type	Description	Constraints
alert_type	string	告警类型	必填，枚举："AdversarialPattern", "CoordinatedBehavior", 等
severity	string	严重程度等级	必填，Low/Medium/High
description	string	告警简述	必填，对可疑情况的描述，最长500字符
detected_at	datetime	检测时间	必填，ISO8601
affected_entities	list<string>	受影响对象列表	可选，如相关的Persona ID列表或涉及的主题关键字等
evidence_list	list<EvidenceItem>	证据列表 (例证可疑行为/内容)	必填，至少包含1条典型可疑内容证据，结构同RecommendationCard
confidence_score	float	置信度/置信评分 (0~1)	必填，用于辅助判断误报，越高表示系统越确定有不良行为
status	string	告警状态	必填，"New", "Acknowledged", "Mitigated", "FalsePositive" 等
recommended_action	string	建议处理措施 (机器建议)	可选，如 "IsolateContent", "SuspendAccounts", "ReviewManually"
policy_version	string	所用策略版本	必填，确保审计可知此告警依据哪版策略规则
trace_id	string	触发检测流程的trace ID	必填
dedup_key	string	去重键	必填，规则：可由 alert_type + 主要对象 标识唯一事件，用于避免重复告警
resolved_by	string	处理人用户ID	可选，当status更新为Mitigated/FalsePositive时填写
resolved_at	datetime	处理时间	可选，同上
resolution_notes	string	处理备注	可选，处理人填写的备注，如采取措施或判断误报原因

Notes: - AdversarialAlert 通过告警系统推送给Gov/Admin，也存入AuditLog（action_type=ALERT_RAISED等）。与RecommendationCard不同，它更偏内部安全通知，但也可生成RecCard用于决策跟进。 - `alert_type` 细分类别：例如 "Coordinated Posting"（协调发布攻击）、"Fake News Campaign"（假新闻活动）、"Malware Link Spread" 等，可扩展。策略规则可以调整各类对应的confidence计算。 - `affected_entities`: 可能是涉及的用户账号ID列表、或涉及的知识图谱实体（如被抹黑的人物）。以类型+ID方式表示，如 ["Persona:P-123","Topic:COVID"]。 - `evidence_list`: 列举典型证据，例如多个账号同步发的相似帖子片段。结构同EvidenceItem，加上source表明来自哪账号等。必要的话source里面包含账号ID或名称以便直观。 - `confidence_score`: 例如0.95表示几乎肯定恶意。可与NFR对照，≥某阈值才High severity。 - `status` 流转： - New: 刚产生未处理 - Acknowledged: 有人已查看 - Mitigated: 已采取应对措施 - FalsePositive: 判定为误报 - Closed: 关闭 之类。修改status时写resolved_by/at/notes。 - `recommended_action`: 由系统给出建议，如发现大量僵号则建议 "Suspend these accounts". Admin可作为参

考。并不自动执行，除非策略bundle指定High级别自动处理。 - `dedup_key`: 关键避免多次触发。设计如: - 对于协调攻击，可用 attack signature (如相似hash) + date/day 作为key; - 对于同一批账号的事件，用 sort(账号列表) hash 等。 系统检测模块生成dedup_key，用于告警服务查重：若相同dedup_key最近已产生告警未关闭，不再新建，而是更新存在告警的detected_at或计数。 - 关联关系： - 一个AdversarialAlert可能对应一个RecommendationCard (risk_level一般High)，建议动作也同步。但不总是：RecCard更多给决策看，Alert偏给治理处理技术细节。二者字段重复但面向不同对象。 - PolicyBundle中的alert_thresholds可调整生成Alert的confidence阈值，对于低Confidence可能仅观察不报。 - `resolution_notes`: 供治理记录处理经过，如"已封禁5账号，内容删除" 或 "经查为误报，原因...". 这个在审计和改进策略时重要。 - 安全: AdversarialAlert数据对一般Analyst不可见，仅Admin/GOV可访问。API权限要控制。日志也分类存储或标记机密。 - 处理流程: - GOV处理后一般会有后续action，如隔离内容（Document打特殊标记excluded），需在Document或Profile等对象打上标签以防继续扩散。此与Alert resolution联动：标记Mitigated意味着已采取了action，这里notes要写明例如"Documents [X,Y] removed, Accounts [A,B] suspended". - 如果Alert持续满足条件（威胁未消除），系统可能在某时间后重新New一个alert。如果已Mitigated但恶意者换新手法，又会新alert，dedup_key不同则会报。 - 监控: - MTR指标会统计alert count, false positive count等以评估算法效果（NFR O4 KR2相关）。 - 所有Alert 24x7通知可能接入SIEM安管平台或邮件群组。

C-016: ReportTemplate (报告模板契约)

描述用于导出报告的模板结构和规则。

Field	Type	Description	Constraints
template_id	string	模板ID（唯一标识）	必填，简短字符串或UUID；系统预置模板ID固定如 "DEFAULT"
name	string	模板名称	必填，1-100字符
description	string	模板描述说明	可选
format	string	模板格式（如 "Markdown", "HTML", "LaTeX" 等）	必填，用于渲染引擎识别
content	string	模板内容主体	必填，模板文件内容（带占位符）
placeholders	list<string>	占位符变量列表，用于说明模板中可替换内容名	必填，如 ["TITLE","SUMMARY","CARD_LIST","FOOTER"]
sample_output	string	示例输出预览（可选）	可选，用示例数据渲染的输出PDF链接或截图
created_at	datetime	创建时间	必填
created_by	string	创建者用户ID	必填
tenant_id	string	所属租户ID	必填，若为系统全局模板则填 "system"
version	int	模板版本号（针对修改迭代）	必填，初始1，每次修改递增
is_active	boolean	是否可用	必填，false表示已弃用不应使用该模板

Field	Type	Description	Constraints
policy_version	string	创建时策略版本	可选，指模板内容受哪些策略限制（如水印样式）主要审计用
trace_id	string	跟踪ID	可选

Notes: - Template `content` 一般为带占位符的Markdown或HTML字符串。占位符格式例如 `{{TITLE}}`, `{{EVIDENCE_LIST}}` 等。渲染引擎会将RecommendationCard列表等插入对应位置。 - `placeholders` 列出可用占位符键，便于前端/用户选择性填内容。例如在UI导出对话框，显示当前模板需要填哪些部分信息，如报告标题（TITLE）等。 - 模板中某些占位符系统自动替换： - 标准的如 {{DATE}}, {{REPORT_ID}}, {{PAGE_NUM}} 可能全局支持。 - 证据列表可能需要特殊格式（如附录形式），渲染逻辑会处理对象列表占位符如 {{CARD_LIST}} 或 {{EVIDENCE_SECTION}} 等。 - 模板可以按租户定制（比如含租户Logo）。`tenant_id` 区分作用域：租户自己的模板其他租户不可见。系统global模板 tenant_id="system"。 - **Error cases**: - 如果导出使用的template_id不存在或is_active=false，ReportJob将失败，返回错误**2401 TemplateNotFound** 或 **2402 TemplateInactive**。 - 模板content里占位符若未被提供内容替换，渲染后应自动去除占位符标记留空或fallback默认文本。尽量不要输出裸占位符字符串。 - 模板格式如果渲染引擎不支持，ReportJob时立即fail，错误**2400 ReportGenError** mention不支持格式。 - **Security**: - 模板content中不允许嵌入未经转义的用户数据以防注入攻击。渲染引擎对插入的所有字段都应做安全转义或在受控环境渲染成PDF而不会执行任意代码。 - 管理员可通过配置文件或UI上传新的模板文件。系统验证模板语法和格式是否正确（比如Jinja2模板是否可compile）。 - **Watermark & audit**: - Report export模块统一加的审计水印（租户名+report_id）通常不在模板里，由系统在生成PDF阶段统一套用在每页背景或页眉。模板无需考虑水印逻辑，但可以留空间或占位符{{WATERMARK}}如需灵活控制位置。 - `audit_id` 也一般直接加在封面或页脚，不由模板决定，但模板可包含{{AUDIT_ID}}如需自行显示更显眼处。 - **Versioning**: - 模板编辑后版本+1，旧版本可存历史但对外一般不提供用旧版功能（report模板不像策略需要旧版），仅审计留痕。除非业务要按报告日期回溯用当时模板渲染，可通过report记录的template_id+version实现。 - **Examples**: - Default Markdown模板 content 可能包含:

```
# {{TITLE}}
_Generated on {{DATE}} by {{AUTHOR}} (Tenant: {{TENANT_NAME}})_
{{#each CARD_LIST}}
## {{this.title}}
{{this.summary}}
**Evidence:**
{{#each this.evidence_list}}
- {{this.source}}: "{{this.excerpt}}"
{{/each}}
{{/each}}
```

placeholders: ["TITLE","CARD_LIST","DATE","AUTHOR","TENANT_NAME"] - System渲染时提供TITLE等=用户输入/上下文数据，然后使用markdown->PDF引擎输出成文件。 - **Audit**: - 创建/更新模板记AuditLog（action_type=TEMPLATE_CREATE/UPDATE）。ReportJob用哪个template版在report metadata (report_id->ReportTemplate.version)有记录，以便重现当时报告。

C-017: Workspace (租户工作区对象)

顶层租户容器，组织多个Project并管理租户用户和配置。

Field	Type	Description	Constraints
workspace_id	string	租户ID（Workspace唯一ID）	必填，全局唯一，如 "tenant_abc"
name	string	组织/租户名称	必填，1-100字符
admin_user_ids	list<string>	工作区管理员用户ID列表	必填，至少1个；这些用户拥有该租户下所有项目的Admin权限
created_at	datetime	创建时间	系统填写
plan_level	string	租户计划级别（比如 "Free","Enterprise"）	可选，用于功能/配额管理，默认Standard
preferences	object	租户级配置项（JSON）	可选，如自定义配色、默认语言等；键值根据产品定义
status	string	状态 ("Active","Suspended","Deleted")	必填，用于停用或标记删除租户
delete_requested_at	datetime	租户注销请求时间（若有）	可选，如已提交删除流程则记录，用于完成后物理删除
trace_id	string	跟踪ID（创建该租户的操作trace）	可选

Notes: - Workspace 主要用来隔离租户上下文，在用户登录后会绑定一个workspace_id，以便后续操作都限定此租户。 - `admin_user_ids`: 列表中的用户被授予租户Admin角色，可管理该Workspace下所有项目、用户。应该与User Directory集成（User本身也有租户关联属性）。 - 在Access Control模型中，除了Project成员权限之外，还可能有Workspace-level角色（如租户审计员Gov角色），但User存储不在此合同内，而是在IdP/AD系统。不过可通过preferences或其他映射来赋予租户级别角色Mapping。 - `plan_level`: 用于控制配额或开启的模块，比如Free版无高级功能Enterprise有。系统在关键路径会检查此字段以决定是否允许某些操作。比如report导出上限页数等。 - `status`: Suspended时用户还能登录吗？可配置为只能只读访问或登陆受限。Deleted表示已执行删除但保留记录（maybe ghost for referential integrity），之后可能彻底移除（可从DB删除或status=Deleted保留一段时间）。 - 租户注销流程（见数据治理）： - 当租户提出销毁数据，一般由admin_user触发，系统将status标记 "DeletionRequested" （或通过 delete_requested_at != null 标识）。然后异步执行删除Data Gov表列出该tenant数据。完成后可以: - 软删除Workspace (status="Deleted")，保留壳以防ID重用或审计需要。 - 也可能物理删除行，AuditLog留证（一般我们保留软删除比较安全）。 - `preferences`: JSON例如 {"language":"en","logo_url": "..."}。无固定schema，扩展性字段。 - **Dependencies**: - Projects有workspace_id外键指向Workspace。 - User管理系统应该记录每user归属一个workspace，多租户场景通常user只在一个租户，若有跨租户admin则另行处理。 - Removing a workspace should ideally cascade remove or detach all child objects (projects, docs, users etc) with audit logged. - **Audit**: - 创建租户由运营或系统自动触发，AuditLog记录（action_type="WORKSPACE_CREATE"）。 - 租户Admin变更在AuditLog (WORKSPACE_UPDATE)。 - 删除租户须多人确认并记录DeletRequest (action_type="WORKSPACE_DELETE_REQUEST")、完成时 (WORKSPACE_DELETED)。 - **Security**: - 每个请求上下文必须有workspace_id，不允许跨workspace操作除非超级管理员（系统管理所有租户）。 - 绝大多数API实现上要根据当前用户session关联的workspace_id过滤数据查询（NFR Must-08）。 - 如果发生跨租户数据合并场景（通常没有），务必Explicitly Check. - **Example**:

```
{
  "workspace_id": "tenant_001",
```

```
  "name": "Acme Corp Threat Intel",
  "admin_user_ids": ["user_123","user_789"],
  "created_at": "2025-10-01T12:00:00Z",
  "plan_level": "Enterprise",
  "preferences": {"default_language":"en","enable_beta":true},
  "status": "Active"
}
```

C-018: DegradationStatus API (降级状态接口)

提供系统当前降级状态信息的查询结构，用于前端或监控展示和逻辑判断。

Field	Type	Description	Constraints
level	int	当前降级等级 (0/1/2/3)	必填，0表示正常无降级
level_name	string	降级级别名称 ("Normal","L1","L2","L3")	必填，与level对应
since	datetime	当前级别生效开始时间	必填，ISO8601
trigger_metric	string	触发该级别的主要指标名称	可选，例如 "ingest_queue_latency_ms" 或 "cpu_utilization"
trigger_value	float	触发时该指标的数值	可选，用于事后分析
features_disabled	list<string>	当前关闭或降级的功能列表 (Feature Flags)	必填，例如 ["new_ingest","deep_analysis"]，无则空数组
user_message	string	面向用户的降级提示语	必填，例如 "系统繁忙，部分功能暂不可用" (可多语言)
exempt_slo	list<string>	降级状态下豁免的SLO或调整的目标清单	可选，如 ["NewContentAnalysisTime"] 表示新内容分析延迟指标暂不考核
last_updated	datetime	状态最后更新时间戳	必填
trace_id	string	关联trace ID (如最近一次level变更事件)	可选

Notes: - DegradationStatus 由后台全局状态维护（可能在Ops服务或配置中心），每当降级level变化或关键信息变化更新值。提供只读API `GET /degradation_status` 返回上述结构，以供： - 前端页面决定是否显示降级横幅和说明（使用user_message字段内容）。 - 租户Admin查看当前系统健康状态。 - 测试或监控自动化依据exempt_slo调整告警策略（如L3时暂停某些告警）。 - `features_disabled`: 可能对应FR-017矩阵features_off。需要与PolicyBundle.degradation配置保持一致。系统应用PolicyBundle后更新DegradationStatus.features_disabled。 - `user_message`: 多语言支持，可根据Accept-Language返回对应语言短句。如何存多语言？可以store多个message_xx字段或通过前端i18n。简化起见存在English为key、前端自行翻译或后台根据配置语言模板。目前可放中文默认，前端写死几种mapping也可。 - `exempt_slo`: 提示在当前降级下哪些SLO不再严格满足也不算违约。例如L3时"NewContentIndexing5min"暂不保证。监控可据此抑制相关告警。此字段PolicyBundle策略可配置。 - 调用者权限： - 此接口对所有已登录用户可读，但普通用户只需要user_message即可提示，不需要敏感细节如触发指标。因而前端应用对普通用户可能只用level和

user_message。Admin/SRE控制台才显示trigger_metric等详情。 - 实现可根据角色过滤字段，或前端调用不同API获取详情。 - **Cache**: - 降级状态变化不频繁，但接口可1秒缓存甚至subscribe推送。实时性对通知重要，即level变化最好推送UI。 - 低频查询影响可忽略，可每5秒前端轮询。也可采用WebSocket/ServerSentEvents broadcast level变化事件。 - **Example**: 正常：

```
{"level":0,"level_name":"Normal","since":"2025-12-18T12:00:00Z",
 "features_disabled":[],"user_message":"系统正常","last_updated":"2025-12-18T12:00:00Z"}
```

降级L2：

```
{"level":2,"level_name":"L2","since":"2025-12-18T14:05:30Z",
 "trigger_metric":"ingest_queue_latency_ms","trigger_value":7800.5,
 "features_disabled":["deep_analysis"],"user_message":"系统繁忙，已暂停高级分析功能",
 "exempt_slo":["NewContentAnalysisTime"],"last_updated":"2025-12-18T14:07:00Z"}
```

- **Integration**: - FE: 检查level>0显示顶部banner: e.g. "【降级提示】系统繁忙，部分功能暂不可用" (取user_message) + tooltip "暂停功能:深度分析; 待恢复". - BE: 监控服务subscribe此并调整告警规则阈值(embedding). - **Trace**: - trace_id标识触发level变更事件的trace，可在监控Span中检索上下文，比如那个具体告警或异常leading to degrade。 - **Testing**: - 模拟升降级事件后，调用API检查字段更新及时准确。 - UI手工触发降级levels, 检查banner内容是否符合exempt features. - **Sec**: - 不涉及敏感数据，不严格鉴权无妨，但最好仅内部调用或登录用户使用，防扫描就不返回一些内部指标。lowest risk.

C-019: ErrorEnvelope (统一错误响应结构)

当API发生错误时返回的标准格式，用于封装错误详情。

Field	Type	Description	Constraints
error	object	错误主体对象	必填
error.code	int	应用错误代码（自定义）	必填，自定义错误码，如 1001, 2101 等（见第13章）
error.message	string	错误描述信息（面向开发者）	必填，简短说明错误原因，可为多语言（通常英语开发描述）
error.details	object	详细信息（可选）	可选，提供附加错误上下文，如字段验证错误列表
error.retryable	boolean	是否建议重试	必填，true表示该错误为暂时性可重试（如超时），false为逻辑错误
error.retry_after	int (optional)	重试等待秒数	可选，当retryable=true且有建议等待时间时提供，以秒为单位
trace_id	string	对应请求的trace ID，用于问题排查	必填，与请求中trace_id一致

Notes: - 所有API出现错误时（HTTP状态通常用4xx/5xx）响应体应遵循此结构，顶层是 `error` 对象而不是data。这样前端可统一处理error。 - `code` 为应用内统一错误码（见第13章表），便于客户端程序化处理。与HTTP status无严格一一对应，但一般4xx系列对应1xxx/2xxx，5xx对应5xxx等。 - `message` 主要给开发者/管

理员调试，不建议直接暴露给终端用户（若需国际化错误提示，由前端根据code映射友好文案）。message避免泄露敏感信息，例如权限错误不会暴露存在资源与否，只说"Access denied"。 - `details` 用于复杂错误情况： - 例如字段校验错误，可包含一个错误数组，每项指出字段名和问题，如 `"details": {"fields": [{"name":"email","problem":"Invalid format"}]}`。 - 再如查询语法错误，可包含 `position` 指针如 `"details": {"position": 5}` 指出错误位置。 - Not all errors have details, optional. - `retryable`: - True例：超时、依赖服务暂时不可用（用户稍后可重试或自动重试），前端可据此决定是否提示用户重试或自动重试。 - False例：权限错误、参数错误，不管重试多少次不改变结果，应提示用户修改或联系管理员。 - `retry_after`: 典型用于429 Too Many Requests，告知多少秒后可重试。如Rate Limit返回429和error.retryable=true, retry_after=60。 - HTTP Status vs error.code: - 错误包通常配合HTTP status，例如: - 400 Bad Request -> error.code 1101 (语法错误)或1100 (通用参数无效) - 401 Unauthorized -> code 1001, message "Authentication required" - 403 Forbidden -> code 1003, "Access denied" - 404 Not Found -> code 1200, "Resource not found" - 409 Conflict -> code 1400, "Resource already exists" etc - 429 Too Many -> code 1005, "Rate limit exceeded" - 500 Internal -> code 1500, "Internal server error" - 503 Service Unavailable (降级) -> code 5403, "Service overloaded" - 客户端可同时利用HTTP status和error.code双重判断。 - 安全: - 错误消息不会泄露内部敏感实现。例如db错误不会把SQL露出，只给"Internal error". - 对认证/权限错误，信息模糊化：不区分用户不存在还是密码错统一返回认证失败。 - 例子: - **权限错误**:

```
{
 "error": {
  "code": 1003,
  "message": "Access denied: you do not have permission to perform this action",
  "retryable": false
 },
 "trace_id": "abcd1234"
}
```

HTTP 403. - **查询语法错误**:

```
{
 "error": {
  "code": 1101,
  "message": "Query syntax error: unexpected token 'AND' at position 5",
  "details": {"position": 5},
  "retryable": false
 },
 "trace_id": "efgh5678"
}
```

HTTP 400. - **服务超时**:

```
{
 "error": {
  "code": 5100,
  "message": "Search service timeout",
  "retryable": true,
  "retry_after": 5
 },
```

```
  "trace_id": "ijkl9012"
}
```

HTTP 504 Gateway Timeout. - Implementation: - 错误处理中间件统一封装任何未捕获异常为code 1500, message "Internal server error". - 各业务代码Throw的自定义错误包含code & message, 中间件捕获用来构造error结构。 - trace_id由请求context注入, attaches to error response automatically. - 客户端: - 前端统一解析response.error，如存在则弹错误。对常见code可定制友好提示; 其它显示error.message或通用"操作失败，请稍后重试". - 根据retryable决定是否提供"重试"按钮等UX。 - 对retry_after, Rate limit类前端可倒计时再自动重试请求。

12. Metrics & Observability（指标与可观测性）

系统埋点一系列监控指标（Metrics），并结合分布式追踪（Tracing）实现端到端可观测性。以下给出核心指标清单（以 **MTR-###** 编号）以及跟踪要求。

12.1 Metrics Catalog（指标目录）

每个指标定义ID、名称、类型/单位、标签维度、采集点和用途：

Metric ID	Name & Definition	Type (Unit)	Labels (关键维度)	Source & Collection (采集位置 率)
MTR-001	NewContentPipelineLatency – 新内容从接收至可检索延迟的分布 (Ingest→SearchReady end-to-end latency)	Histogram (seconds)	tenant_id; source_id;	Ingestion服务记录每个Docum 的 `index.search_ready_at - received_at`，更新直方图。指 按租户/数据源标签细分。OpenTelemetry计时span结束时 入。
MTR-002	QueryLatency – 用户查询端到端处理延迟 (Search request round-trip latency)	Histogram (milliseconds)	tenant_id; project_id; query_type (simple/advanced); lang	API Gateway或Search服务在发 响应前记录延迟。使用OpenTelemetry trace数据计算 以定时汇报直方图。标签区分项 和查询类型。
MTR-003	QueryThroughput – 查询请求吞吐率 (Queries per second)	Counter (requests) + Rate	tenant_id; project_id	Search服务为每个完成的查询请 递增Counter。Grafana等基于Counter求Rate per second。
MTR-004	RequestSuccessRatio – 请求成功率 (% of requests without error)	Ratio (%)	tenant_id; api_name	由API网关统计每种API的成功(2 总请求数。在PromQL用两个Counter计算或Gauge。
MTR-005	IngestionRate – 内容摄取速率 (Docs ingested per minute)	Counter + Rate (docs/min)	tenant_id; source_id	Ingestion服务Counter每新增Document递增1。再计算每分钟 率。
MTR-006	DuplicateDropCount – 去重丢弃文档数 (Duplicate docs not ingested)	Counter	tenant_id; source_id	Ingestion阶段检测重复时递增。 为质量指标监控某来源重复。

Metric ID	Name & Definition	Type (Unit)	Labels (关键维度)	Source & Collection (采集位置 率)
MTR-007	IngestQueueLength – 摄取队列长度 (Pending ingest events)	Gauge (count)	tenant_id	FastStream/消息队列暴露topic 度，或Ingestion服务定期报告 pending任务数。用于降级触发
MTR-008	DegradeLevel – 当前降级级别指示 (Current system degrade level)	Gauge (level)	N/A (global metric)	由Ops服务或监控组件每分钟设 前level (0-3)。可用于告警（level≥1触发通知）。
MTR-009	AdversarialAlertsCount – 对抗告警次数 (Number of adversarial alerts)	Counter	severity; alert_type	告警服务每产生一条 AdversarialAlert即递增。可细分 同级别/类型数量。
MTR-010	FalsePositiveAlerts – 误报告警计数 (Alerts marked false positive)	Counter	alert_type	Gov人员在AuditLog标记 FalsePositive时触发递增。用于 踪算法质量。
MTR-011	TranslationLatency – 查询翻译耗时 (CLIR translation time)	Histogram (ms)	target_lang	CLIR模块记录翻译API调用耗时。 target_lang标签区分zh->en等方 向。
MTR-012	TranslationCacheHitRatio – 翻译缓存命中率 (% queries using cached translation)	Ratio (%)	source_lang→target_lang	计算翻译缓存命中次数/总翻译请 次数。CLIR服务维护counter或 输出gauge。
MTR-013	ColdQueryPortion – 冷数据查询占比 (% queries hitting cold storage)	Ratio (%)	tenant_id	Search模块根据查询时间范围判 是否访问冷索引。如果查询超出 数据范围则CounterCold++，任 查询CounterAll++。比率=Cold/ All。
MTR-014	PersonaChangeEvents – 人物异动事件次数 (Persona change detected count)	Counter	severity (High/Med); persona_type (Person/ Org)	Persona监控模块每触发 PersonaChangeDetected事件递 增。按严重程度标签。
MTR-015	PipelineFailCount – 管道处理失败计数 (Failed ingestion/analysis count)	Counter	stage (parse/index/ analysis)	Document.processing_error_c 每出现一次对应阶段Counter++ 于监控异常上升。
MTR-016	TraceCoverage – 关键链路Trace覆盖率 (% of requests with full trace spans)	Gauge (percentage)	flow_type (ingest/query)	监控系统计算每5分钟内trace完 率：例如对于查询请求，检查us >search->db->response span是 闭合。结果以Gauge%上报。
MTR-017	ContentCountByTier – 各存储层文档数量 (Documents count per tier)	Gauge (count)	tenant_id; tier (hot/ warm/cold)	数据治理模块每日统计各租户各 文档数。如Arctic/索引文档总数 用于容量跟踪。

Metric ID	Name & Definition	Type (Unit)	Labels (关键维度)	Source & Collection (采集位置 率)
MTR-018	SLA Breach Count – SLA违约次数 (Count of SLO breaches)	Counter	slo_name	每检测到SLO未达标一次（超出 阈值）递增。例如每日5min管 P95超标一次即计数。运维每天 查。

注: 上述并非全量指标，预期还包括各服务CPU/内存/线程等基础指标采用底层平台(Ops)采集，不在此详述。表侧重应用SLO相关指标。所有指标都遵循**租户隔离**：标签带tenant_id的，可用于过滤单租户视图；全局指标不会混淆租户数据。

Alert Rules: 每条关键指标都会配置告警规则（已在NFR Alert Threshold列示），简要示例： - MTR-001 新内容延迟：P95>5min连续超过10分钟 -> 警告告警（Level1）；持续30分钟以上 -> 严重告警并可能触发降级L3。 - MTR-003 查询QPS 达到90%上限（90 QPS持续5分钟） -> 预警（建议扩容）。 - MTR-008 降级Level≥2 -> 立即高优告警（通知所有相关人员）。 - MTR-016 TraceCoverage <90%持续15分钟 -> 一般告警给开发检查埋点问题。

SLO绑定关系可在文档或监控系统中表格列出，如: - O1.KR1 (5min新鲜度) <- MTR-001 (IngestLatency P95) – 警戒阈值4.5min，SLA阈值5min。 - O1.KR2（800ms查询）<- MTR-002（QueryLatency P99）– 警戒700ms, SLA800ms。 - O4.KR2 (告警误报<5%) <- MTR-010/(MTR-009) – 计算Low告警占比>5%则告警调整策略。

12.2 Distributed Tracing（分布式追踪）

系统采用OpenTelemetry (OTel)实现全链路追踪，要求：

- **核心链路覆盖**：对以下关键流程的每个服务调用打Trace span，确保trace完整：
- Ingestion Pipeline: span序列示例: `IngestService.receive` -> `ParseService.parseDoc` -> `IndexService.addDocument` -> `AnalysisService.analyzeDoc` -> ... 每步span带trace_id相传。最终在Document.analysis_ready时一个trace闭合。
- Search Query: span序列: `API Gateway ingress` -> `SearchService.queryPlanner` -> `FulltextEngine.search` -> `VectorEngine.search` -> `GraphEngine.query` -> `SearchService.fusion` -> `API Gateway egress`。包含外部调用(如翻译API)也纳入span。
- Report Export: span: `UserRequestExport` -> `ReportService.assembleData` -> `TemplateEngine.render` -> `FileStorage.savePDF` -> etc。时间长操作可标记异步span或单独trace关联。
- **Span 标准**：所有span命名遵循 `系统.模块.动作` 格式，如 `SearchService.queryPlanner`。每span附加属性：tenant_id, user_id（如有），trace_id在所有span共享。
- **日志关联**：将trace_id注入常规应用日志，方便从日志跳转trace。在error情况下errorEnvelope亦返回trace_id（C-019）。
- **百分比采样**：预设对所有请求采样trace（1.0采样率）至少在QA/Stage环境。生产可根据流量调整如10%采样，但对涉及降级、错误的trace强制采样（通过OTel配置Based on attributes，如error=true则采样）。
- **Trace 完整性**：定义衡量指标MTR-016。具体：
- 对每类核心链路，设定必要span列表。例如Ingestion至少应有 `Ingest.receive` 和 `Index.addDocument` 两大span；Search至少有 `Gateway` 和 `SearchService` 两span。如果trace缺少这些关键span则视为不完整。
- 通过定时作业扫描当period内trace数据，如发现<95% trace包含完整span序列，则发告警（NFR Must-13).
- **Propagation**：采用W3C TraceContext，通过HTTP headers (`traceparent` 等)传递trace上下文。各服务需配置OTel SDK自动继承和传递header。对异步队列（FastStream），在消息中附trace context

（如属性字段trace_id）或者通过OTel instrumentation确保关联span（OTel对Kafka/AMQP有instrument）。
- **Span attributes**：除trace_id，还记录关键业务属性，例：
- user_id（除匿名外），tenant_id（所有span都可加方便筛选租户慢请求）。
- 对DB/query span记录`db.statement`（或参数化后的安全SQL）、对外HTTP调用span记录`http.url`等。
- 对长任务span可拆子span标记阶段，用`span.kind`明确client/server/internal等。
- **ID 一致性**：errorEnvelope、AuditLog、trace span中的trace_id统一。当从UI问题报告拿到trace_id，可在Tracing系统检索完整调用流。
- **可视化 & 存储**：部署OTel Collector，将trace发送至可视化工具（如 Jaeger/Zipkin 或商业APM）。SRE可以根据trace快速诊断瓶颈。保留期1周以上方便排查间歇性问题。
- **安全**：trace里不记录敏感数据内容（如不把用户输入的密码当属性记录）。只记录必要标识ID/摘要。遵守日志脱敏NFR Must-12。
- **演练**：团队定期（每冲刺）做trace检查，确保新功能有正确span。通过Span浏览器查看任一关键流程trace，确认Span完整率=100%。若缺失则补埋点。
- **特殊场景**：对并行异步任务，trace可能fork出子trace:
- 例如L3降级时新ingest任务延后，需要把原trace拆分：或在DegradationStatus中把关联trace_id写出。可以接受后续处理不在同一trace，但AuditLog和errorLog要能追溯链条。尽量在trace span里标注"deferred".
- **前端Transaction**：若使用前端监控，可以将用户浏览器的动作Trace通过TraceContext关联后端trace，这样从用户点击->后端->DB->响应整个路径都有。视监控工具支持情况定夺。
- 综上，分布式追踪将成为运维调优和故障分析的重要手段，与Metrics、AuditLog互为补充（trace快速定位调用链，metrics量化频率，audit提供安全合规痕迹）。

12.3 Logging & Monitoring Integration

（简述日志与指标/追踪的集成）

- **日志级别**：应用日志按INFO/WARN/ERROR分级。INFO记录关键业务事件（某些模块处理完成），WARN记录非致命异常（如某文档分析失败），ERROR记录严重错误。Debug日志可在调试环境打开，生产默认OFF以降低噪音。
- **日志格式**：采用结构化日志(JSON)或统一模式，至少包含timestamp, level, trace_id, logger_name, message, tenant等。方便ELK等集中收集过滤。敏感字段如User输入要mask或不记录(Must-12)。
- **日志与trace关联**：trace_id放入每条日志属性。这样从监控告警可通过trace_id跨系统关联日志+trace+AuditLog。
- **指标-日志**：关键异常场景通过日志触发与Metrics/告警联动（如ERROR日志自动触发或计数MTR-015 PipelineFailCount++可能由logger hook实现）。
- **监控仪表板**：为主要OKR/SLO建立Dashboard：
- 5分钟新内容延迟曲线、P95线，带分位/目标线标识；
- 查询延迟Heatmap + P99刻度；
- QPS和成功率曲线叠加；
- 降级状态时间线（某时刻level变化标注在其他曲线上作为注释）；
- 告警统计(Adversarial高风险告警数by day)等。
- **巡检和演练**：SRE每日巡检Dashboard/NFR指标。每月一次故障演练验证降级告警pipeline。定期更新报警接收人名单，确保响应及时。
- **数据持久期**：Metrics全量保留至少13个月（NFR Must-02/Should-01需要同比），trace视容量保留7-14天原始。
- **调整**：根据实战数据，可能调整监控阈值或添加指标。例如如果trace负载过高可调采样降低MTR-016精度。or if find some stage not covered by metrics,补充MTR-X。
- **文档**：最终SRE手册里会包含所有Metrics和告警规则表，方便运营。开发在Feature交付时也需更新此列表（Metrics Contract or Code).

- **Tooling**：使用Prometheus收集metrics、Grafana显示，Alertmanager或OpsGenie发告警。Tracing用Jaeger/Tempo等。

13. Error Codes & Exception Handling（错误码及异常处理）

系统统一采用自定义错误码（error.code）格式，用于标识各种错误情况。错误码通常为4位数字，以模块区段划分：

- **1xxx** 系列：身份/权限/请求类错误（Client Error）
- **1001** 未认证（需要登录） – 对应HTTP 401。用户凭证缺失或失效。
- **1002** 认证失败 – HTTP 401。用户名或密码错误、MFA校验失败等。
- **1003** 权限不足 – HTTP 403。已认证用户无权访问资源或操作。
- **1004** 会话失效 – HTTP 401。用户长时间无操作需重新登录（Idle Timeout）。
- **1005** 请求过于频繁 – HTTP 429。触发速率限制，应根据 `retry_after` 重试。
- **11xx** 系列：请求参数或语法错误（Client Input Error）
- **1100** 参数无效 – HTTP 400。泛指请求中参数不符合要求（缺必填、格式错误等）。
- **1101** 查询语法错误 – HTTP 400。DSL解析失败或语法不支持，details可指示错误位置【B-06】。
- **1102** 非法查询/不支持操作 – HTTP 400。使用了禁用或不支持的查询功能（如全库扫描、正则）【B-05】。
- **1103** 数据格式错误 – HTTP 400。提交数据(JSON/XML)无法解析或字段类型错误。
- **12xx** 系列：资源查找及冲突错误
- **1200** 资源未找到 – HTTP 404。请求的实体不存在（如文档ID不存在或已删除）。
- **1201** 部分内容缺失 – HTTP 404或206。用于报告部分结果缺失，如导出报告某内容找不到。
- **1202** 资源已存在 – HTTP 409。试图创建已存在的实体（如重复的项目名）。
- **1203** 依赖资源未找到 – HTTP 424。操作依赖的相关资源不存在（如删除租户时某project没找到）。
- **14xx** 系列：请求冲突或业务规则错误
- **1400** 业务规则冲突 – HTTP 409。如违反唯一约束、策略冲突【B-05】。
- **1401** 不支持的操作 – HTTP 400。如对不可修改资源进行修改或当前状态不允许此操作。
- **1402** 请求内容过大 – HTTP 413。如上传文件或查询字符串长度超限。
- **1403** 阶段状态错误 – HTTP 409。如请求在错误的系统阶段调用（例如降级L3状态下禁止某操作）。
- **21xx** 系列：内容处理/管道错误（Ingestion/Parsing）
- **2100** 采集失败 – HTTP 500。外部数据源无法访问或抓取失败（重试策略通常已有）。
- **2101** 解析失败 – HTTP 422。文档内容无法解析（格式损坏等），Document.processing_error_code记此。
- **2102** 重复内容 – HTTP 200 (特殊非错误)。指提交内容已存在，系统未重复处理（通常不报错，只在返回中说明）。
- **2103** 内容过期 – HTTP 410。数据源内容已被删除或过期无法获取。
- **22xx** 系列：索引/搜索引擎错误

- **2200** 索引写入失败 – HTTP 500。写入全文或向量索引失败（如索引服务异常）。
- **2201** 检索服务不可用 – HTTP 503。搜索引擎模块不可用，触发降级。
- **2202** 查询超时 – HTTP 504。搜索未在规定时间返回【B-03】。
- **2203** 查询结果过大 – HTTP 400。分页超范围或请求返回条数过多被拒绝（见C-003执行限制）。
- **23xx** 系列：分析/生成错误
- **2300** 内容分析失败 – HTTP 500。通用分析步骤失败，没有细分类时使用。
- **2301** 分析超时 – HTTP 500/504。分析方法（如摘要生成）超出时限，analysis.ready_at未设。
- **2302** 模型调用失败 – HTTP 500。内部AI模型服务错误（如可信度模型异常）。
- **2303** 证据融合失败 – HTTP 500。EvidenceFusion异常未产生结果。
- **24xx** 系列：导出/文件处理错误
- **2400** 报告生成失败 – HTTP 500。报告导出过程中发生未分类异常。
- **2401** 模板未找到 – HTTP 404。导出使用的ReportTemplate不存在或不可用。
- **2402** 模板格式错误 – HTTP 500。模板解析失败（语法错误等）。
- **2403** 文件存储失败 – HTTP 500。PDF文件存储或读取失败。
- **2404** 文件不存在/过期 – HTTP 404。下载请求的报告已被清理或无效。
- **25xx** 系列：策略/发布类错误
- **2500** 策略发布失败 – HTTP 500。新策略应用未成功，系统已回滚。
- **2501** 策略冲突错误 – HTTP 400。提交的策略规则内部冲突【B-05】。
- **2502** 策略审批拒绝 – HTTP 403。尝试发布未审批策略包。
- **2503** 策略回滚失败 – HTTP 500。回滚动作未能完成，需人工介入。
- **51xx** 系列：系统依赖/降级错误（Server Errors）
- **5100** 搜索服务超时 – HTTP 504。Search请求超出内部服务超时限制【B-03】。
- **5101** 分析服务超时 – HTTP 504。同上，对应UC-002/003等长分析超时场景。
- **5102** 报告导出超时 – HTTP 504。超出异步导出预期时间。
- **5200** 外部服务错误 – HTTP 502/503。调用外部API（翻译等）返回错误/不可用。
- **5300** 数据库错误 – HTTP 500。数据库执行失败（如死锁，连接失败）。
- **5400** 未知系统错误 – HTTP 500。通用内部错误，用于未分类异常fallback。
- **5401** 内存不足 – HTTP 500。操作因内存不足失败（可建议减小请求）。
- **5403** 服务过载 – HTTP 503。系统处于降级L3，拒绝服务【FR-017】。
- **9xxx** 系列：占位保留，用于未来扩展。

Exception Handling Strategy: - 所有API在出现异常时，将根据异常类型映射上述错误码，通过ErrorEnvelope返回，HTTP状态码遵循惯例： - 客户端错误（1000-1499、21xx参数问题等）用4xx。 - 服务端错误（1500+, 2200+, 2300+, 5100+）用5xx。 - 未预料异常默认作为**5400 UnknownError** 处理，message泛化为"Internal server error"，避免泄露堆栈。 - 开发需在代码中使用统一的错误抛出机制： - 对可预见业务错误，抛出自定义Exception含错误码，统一异常中间件捕获封装。 - 对外部库异常，在边界catch并转换为内部错误码（如SQL异常转5300，HTTP调用异常转5200）。 - 降级状态时，主动检查在入口，如当level=3拒绝新报告导出，直接返回5403而不是尝试执行再失败。 - 客户端应参考error.retryable： - retryable=true时，可以

自动或提示用户稍后重试。false则应提示修改请求或联系支持。 - 所有错误均记录AuditLog（action_type可设如 "ERROR_1003_ACCESSDENIED" 或统一 "ERROR_OCCURRED" 结合trace_id查询具体日志）。特别安全相关错误 (1002/1003 login失败/权限) 需要审计追踪频度。 - 文档将随API文档列出主要错误码说明，以便调用方处理。如Search API文档包含1101,1102,5100等错误解释；Auth API包含1001,1002等。

以上定义确保错误响应一致、可预测，有助于前后端解耦调试，也方便集中分析系统故障模式（通过统计各error.code频次来改进系统，如2101解析失败多则改进parser）。

注：RSv3.1到此结束。以上修订已根据《Review Findings》全面补充了关键交付结构（Overview/Acceptance/Risks等）、完善了FR/NFR表字段、统一了用例格式和Failure Handling，并扩充了契约包C-011至C-019等，确保需求规格自洽完整、可验证可追溯。